

โครงการทางสถิติ 1

เว็บแอปพลิเคชันทำนายราคาทองคำรายวันแบบเรียลไทม์

Real-time daily gold price prediction web application

นำเสนอโดย

นายคณิศร กุดกลาง 653020202-7

นายปณัฏย์ โรจน์พัฒนเดชา 653020210-8

อาจารย์ที่ปรึกษา

ผู้ช่วยศาสตราจารย์ ดร.พลากร สีน้อย ที่ปรึกษาหลัก

อาจารย์ ดร.ธนวรรณ ประชาดไชย ที่ปรึกษาร่วม

เค้าโครงนี้เป็นส่วนหนึ่งของรายวิชา SC 664 774

โครงการทางสารสนเทศสถิติและวิทยาการข้อมูล 1

ปีการศึกษา 2568

สารบัญ

เรื่อง	หน้า
สารบัญ	ก
สารบัญภาพ	ค
สารบัญตาราง	ง
บทที่ 1 บทนำ	1
1.1 ที่มาและความสำคัญ	1
1.2 วัตถุประสงค์	4
1.3 ประโยชน์ที่คาดว่าจะได้รับ	4
1.4 ขอบเขตงานวิจัย	4
1.5 นิยามศัพท์เฉพาะ	6
บทที่ 2 ทฤษฎีและงานวิจัยที่เกี่ยวข้อง	9
2.1 งานวิจัยที่เกี่ยวข้อง	9
2.1.1 ความรู้พื้นฐานเกี่ยวกับทองคำและตลาดทองคำ	9
2.1.2 ปัจจัยที่มีผลกระทบต่อราคาทองคำ	10
2.2 ผลงานวิจัยที่เกี่ยวข้อง	11
2.2.1 ตารางเปรียบเทียบผลงานวิจัยที่เกี่ยวข้อง	13
2.3 กรอบแนวคิดการวิจัย	16
2.4 ทฤษฎีที่เกี่ยวข้อง	17
2.4.1 ตัวแบบการเรียนรู้ของเครื่อง (Machine Learning Models)	17
2.4.2 ตัวชี้วัดประสิทธิภาพของตัวแบบ	19
2.4.3 การอธิบายตัวแบบ	22
2.5 การทำตรวจสอบแบบไขว้ (Cross Validation) สำหรับข้อมูลอนุกรมเวลา (Time Series)	23
2.5.1 Walk-Forward Validation	23

2.6 ค่าสังเกตย้อนหลัง (Lag Feature)	25
2.6.1 ความสำคัญของ Lag Feature ในข้อมูลทางการเงิน	25
บทที่ 3 ระเบียบวิธีวิจัย	26
3.1 แบบแผนการวิจัย	26
3.2 แหล่งข้อมูลและช่วงเวลาศึกษา	26
3.3 การเข้าถึงข้อมูลและการสมัคร API	27
3.4 การสมัครใช้งาน GitHub และการจัดเก็บซอร์สโค้ดด้วย VS Code	27
3.5 การเตรียมสภาพแวดล้อมและเครื่องมือ	29
3.6 การออกแบบตัวแปรและช่วงเวลา	30
3.7 ขั้นตอนการพัฒนาโปรแกรมดึงข้อมูล	30
3.8 การเตรียมข้อมูล (Data Preprocessing)	33
3.9 การเตรียมข้อมูลก่อนทำตัวแบบและการคัดเลือกตัวแปรที่เหมาะสมสำหรับแต่ละตัวแบบ	35
3.10 การสร้างคุณลักษณะ Lag	36
3.11 การกำหนดตัวแปรเป้าหมาย	36
3.12 การจัดการข้อมูลสูญหาย	36
3.13 การแบ่งชุดข้อมูล (Train/Validation/Test)	37
3.14 การฝึกและปรับแต่งตัวแบบ (Training and Hyperparameter Tuning)	37
3.15 การประเมินตัวแบบด้วย Walk-Forward Validation	39
3.16 การเลือกตัวแบบที่ดีที่สุดและอธิบายด้วย SHAP	40
3.17 การฝึกตัวแบบสุดท้ายเพื่อนำไปใช้งาน	41
3.18 การพัฒนาเว็บแอปพลิเคชันสำหรับการพยากรณ์ราคาทองคำแบบอัตโนมัติ	41
3.19 การประเมินผลการใช้งานเว็บแอปพลิเคชัน	44
อ้างอิง	46
ภาคผนวก	49

สารบัญภาพ

ภาพที่	หน้า
1 กรอบแนวคิดการวิจัย	16
2 Walk Forward Analysis (Rolling Out-of-Sample)	24

สารบัญตาราง

ตารางที่	หน้า
1 ตัวแปรที่ใช้ในการวิเคราะห์และพยากรณ์ราคาทองคำ	4
2 สรุปและเปรียบเทียบผลงานวิจัยที่เกี่ยวข้องกับการพยากรณ์ราคาทองคำ	13

บทที่ 1

บทนำ

1.1 ที่มาและความสำคัญ

ทองคำถูกยอมรับอย่างกว้างขวางว่าเป็นสินทรัพย์ปลอดภัย (Safe-Haven) ที่นักลงทุนใช้ป้องกันความเสี่ยงจากภาวะเงินเฟ้อและความไม่แน่นอนทางเศรษฐกิจ โดยงานวิจัยของธนาคารกลางชิคาโก (Federal Reserve Bank of Chicago, 2013) ระบุว่าทองคำเป็นเครื่องมือ "ป้องกันเงินเฟ้อ" (Hedge) มีความไวต่ออัตราดอกเบี้ยระยะยาว และเป็นสินทรัพย์ที่นักลงทุนถือไว้ในช่วงสถานการณ์เศรษฐกิจแย่ ข้อมูลเชิงเศรษฐกิจต่าง ๆ ที่ส่งผลต่อราคาทองคำ ได้แก่ ราคาน้ำมันเป็นปัจจัยสำคัญเพราะสะท้อนต้นทุนพลังงานในระบบเศรษฐกิจ เมื่อราคาน้ำมันสูงขึ้น มักทำให้ต้นทุนการผลิตและค่าขนส่งเพิ่มขึ้น ส่งผลให้ระดับเงินเฟ้อเร่งตัว นักลงทุนจึงมักหันไปลงทุนในทองคำเพื่อป้องกันความเสี่ยงจากเงินเฟ้อ งานวิจัยของ Zhang and Li (2022) และ Wang et al. (2023) พบความสัมพันธ์เชิงบวกระหว่างราคาน้ำมันและราคาทองคำอย่างมีนัยสำคัญ เช่น ในปี 2022 ที่ราคาน้ำมันโลกพุ่งสูงจากวิกฤตรัสเซีย-ยูเครน ราคาทองคำก็ปรับตัวขึ้นตามไปด้วย อัตราเงินเฟ้อเป็นตัวชี้วัดการเปลี่ยนแปลงของราคาสินค้าและบริการ หากเงินเฟ้อเพิ่มสูงขึ้น กำลังซื้อของเงินตราจะลดลง นักลงทุนจึงเพิ่มการถือครองทองคำเพื่อรักษามูลค่า งานของ Jabeur et al. (2024) พบว่าอัตราเงินเฟ้อเป็นหนึ่งในปัจจัยที่มีผลต่อราคาทองคำมากที่สุด โดยเฉพาะในช่วงที่เศรษฐกิจสหรัฐฯ เติบโตเงินเฟ้อสูงหลังโควิด-19 ราคาทองคำเพิ่มขึ้นอย่างต่อเนื่อง สะท้อนบทบาทของทองคำในฐานะสินทรัพย์ป้องกันเงินเฟ้อ (Hedge Against Inflation) ทองคำซื้อขายในตลาดโลกด้วยสกุลดอลลาร์ ดังนั้นค่าดอลลาร์ที่แข็งค่าหรืออ่อนค่าจึงมีผลโดยตรง หากดอลลาร์แข็งค่า ราคาทองคำจะดูแพงขึ้นสำหรับผู้ถือสกุลเงินอื่น ทำให้ความต้องการทองคำลดลง และราคาทองคำมีแนวโน้มปรับตัวลง งานวิจัยของ Jabeur et al. (2024) และ Wang et al. (2023) สนับสนุนความสัมพันธ์เชิงผกผันนี้ ตัวอย่างเช่น ในปี 2018 ที่ดัชนีดอลลาร์แข็งค่าต่อเนื่อง ราคาทองคำปรับตัวลดลงอย่างชัดเจน ดัชนีหุ้นสะท้อนความเชื่อมั่นของนักลงทุน หากตลาดหุ้นอยู่ในช่วงขาลง นักลงทุนมักย้ายเงินไปลงทุนในทองคำในฐานะสินทรัพย์ปลอดภัย งานวิจัยของ Zhang and Li (2022) พบว่าช่วงตลาดหุ้นตก ราคาทองคำมีแนวโน้มปรับขึ้น ตัวอย่างเช่น ในวิกฤตการเงินโลกปี 2008 S&P 500 ร่วงลงอย่างรุนแรง ขณะที่ราคาทองคำพุ่งขึ้นอย่างมีนัยสำคัญ ทองคำเป็นสินทรัพย์ที่ไม่มีดอกเบี้ยตอบแทน เมื่ออัตราผลตอบแทนพันธบัตรสูงขึ้น ความน่าสนใจของการลงทุนในทองคำย่อมลดลง งานวิจัยของ Jabeur et al. (2024) ยืนยันความสัมพันธ์เชิงลบ (Negative Relationship) กล่าวคือ เมื่อ Bond Yield ปรับตัวสูงขึ้น นักลงทุนมีแนวโน้มเลือกลงทุนในพันธบัตรมากกว่าทองคำ เนื่องจากพันธบัตรให้ดอกเบี้ยตอบแทน ในขณะที่ทองคำไม่มีผลตอบแทนลักษณะดังกล่าว ส่งผลให้ความต้องการทองคำลดลงและราคาทองคำถูกกดดันให้ปรับตัวลง โดยเฉพาะในปี 2023 ที่ระบบธนาคารกลางสหรัฐฯ (Federal Reserve System) ปรับขึ้นอัตราดอกเบี้ยต่อเนื่อง ส่งผลให้ผลตอบแทนพันธบัตรสหรัฐฯ อายุ 10 ปี (Bond Yield) สูงขึ้น ราคาทองคำถูกกดดันให้ปรับตัวลง ราคาทองคำและเงินมักเคลื่อนไหวในทิศทางเดียวกัน เนื่องจากนักลงทุนมองว่าเป็นโลหะมีค่าที่มีคุณสมบัติใกล้เคียงกัน งานวิจัยของ Zhang and Li (2022) แสดงว่าราคาเงินมีความสัมพันธ์สูงกับ

ราคาทองคำ เช่น ในช่วงปี 2020–2021 ที่เศรษฐกิจโลกเผชิญโควิด-19 ทั้งราคาทองคำและเงินปรับตัวขึ้นพร้อมกันอย่างรุนแรง และราคาแร่เหล็ก (Iron Ore Price) ก็เป็นอีกหนึ่งปัจจัยที่สะท้อนกิจกรรมทางเศรษฐกิจโลก โดยเฉพาะในภาคอุตสาหกรรมเหล็กและการก่อสร้าง ซึ่งเป็นภาคส่วนสำคัญที่ใช้แร่เหล็กเป็นวัตถุดิบหลัก เมื่อราคาของแร่เหล็กปรับตัวเพิ่มขึ้น มักบ่งชี้ถึงการขยายตัวของเศรษฐกิจและความต้องการวัตถุดิบที่สูงขึ้น ซึ่งอาจส่งผลให้ราคาทองคำเคลื่อนไหวในทิศทางเดียวกันจากแรงเก็งกำไรและการคาดการณ์เงินเฟ้อ งานวิจัยของ Zhang and Li (2022) พบว่าราคาแร่เหล็กมีความสัมพันธ์เชิงบวกในระดับปานกลางกับราคาทองคำ สะท้อนว่าการขยายตัวของภาคอุตสาหกรรมและต้นทุนการผลิตที่สูงขึ้นสามารถผลักดันให้ราคาทองคำเพิ่มขึ้นได้เช่นกัน นอกจากนี้ปัจจัยเศรษฐกิจมหภาคแล้ว ยังมีตัวแปรราคาทองคำรายวันที่สะท้อนพฤติกรรมการซื้อขายจริงในตลาด ได้แก่ ราคาเปิด (Open) ราคาสูงสุด (High) ราคาต่ำสุด (Low) ราคาปิด (Close) และ ปริมาณการซื้อขาย (Volume) ซึ่งเป็นชุดข้อมูลมาตรฐานที่ใช้กันอย่างแพร่หลายในการสร้างแบบจำลองพยากรณ์อนุกรมเวลา โดยช่วง High–Low ใช้เป็นตัวแทนความผันผวนภายในวันและเป็นฐานของตัวประมาณความผันผวนช่วงจริงที่มีประสิทธิภาพ ขณะที่ส่วนต่าง Open–Close สะท้อนแรงซื้อขายสุทธิและแนวโน้มในวันนั้น ซึ่งสัมพันธ์กับโมเมนตัมระยะสั้นของราคา (Jegadeesh & Titman, 1993) ส่วน Volume บ่งชี้ความเข้มข้นของสภาพคล่องและการไหลของข้อมูลข่าวสารในตลาด ซึ่งมีความสัมพันธ์เชิงประจักษ์กับขนาดการเปลี่ยนแปลงของราคาและความผันผวน (Karpoff, 1987; Campbell et al., 1993) นอกจากนี้ OHLCV ยังเป็นฐานในการคำนวณตัวแปรอนุพันธ์ที่ช่วยเพิ่มศักยภาพการพยากรณ์ เช่น ผลตอบแทน (returns) และ ความผันผวนช่วงจริง (realized volatility) ซึ่งได้รับการใช้อย่างกว้างขวางในวรรณกรรมด้านอนุกรมเวลาทางการเงินสมัยใหม่ (Andersen et al., 2003) ตลอดจนตัวแปรเชิงเทคนิคอย่าง ช่วงแท่งเทียน (candlestick ranges) ค่าเฉลี่ยเคลื่อนที่ (moving averages) และโมเมนตัม (momentum) ที่ช่วยสะท้อนพฤติกรรมฝูงชนและจังหวะตลาดได้ดียิ่งขึ้น (Jegadeesh & Titman, 1993; Andersen et al., 2003) ด้วยคุณสมบัติข้างต้น ราคาทองคำจึงมีผลโดยตรงต่อการตัดสินใจลงทุนของนักลงทุนรายย่อยและนโยบายของหน่วยงานภาครัฐ การมีระบบพยากรณ์ราคาทองคำที่แม่นยำและทันการณ์ จึงจำเป็นต่อการบริหารความเสี่ยงและวางกลยุทธ์การลงทุนอย่างยั่งยืนในยุคข้อมูลข่าวสาร

แม้ปัจจุบันจะมีแพลตฟอร์มหลายแห่งที่ให้ข้อมูลราคาทองคำแบบเรียลไทม์พร้อมเครื่องมือวิเคราะห์เชิงเทคนิค เช่น Investing.com, TradingView หรือ Yahoo Finance ที่ใช้ ค่าเฉลี่ยเคลื่อนที่ (Moving Average), ดัชนีความแข็งแกร่งสัมพัทธ์ (Relative Strength Index: RSI) หรือ ค่าเฉลี่ยเคลื่อนที่แบบบรรจบ-แยก (Moving Average Convergence Divergence: MACD) (Investing, 2024; TradingView, 2024; Yahoo Finance, 2024) แต่เครื่องมือเหล่านี้มักอาศัยข้อมูลราคาในอดีตของทองคำเพียงปัจจัยเดียว ทำให้ไม่สามารถสะท้อนความสัมพันธ์เชิงลึกกับปัจจัยเศรษฐกิจมหภาคอื่น ๆ ได้อย่างเพียงพอ โดยเฉพาะในช่วงที่ความผันผวนทางเศรษฐกิจสูง เช่น ภาวะเงินเฟ้อกดดันให้นักลงทุนเผชิญความไม่แน่นอนมากขึ้น ประสิทธิภาพการพยากรณ์ของวิธีเดิมจึงลดลง จึงมีความจำเป็นต้องปรับปรุงวิธีการพยากรณ์ให้รวมข้อมูลหลากหลายมิติ (Jabeur et al., 2024; Shafiee & Topal, 2010; Zhang & Li, 2022) นอกจากนี้ เว็บไซต์ WalletInvestor.com เป็นอีกหนึ่งแพลตฟอร์มยอดนิยมที่ให้บริการการพยากรณ์ราคาทองคำและสินทรัพย์ทางการเงิน โดยใช้ Machine Learning เพื่อสร้างแบบจำลองคาดการณ์แนวโน้มราคาของทองคำและสินทรัพย์ประเภทอื่นๆ เช่น Crypto Currency, หุ้น และอัตราแลกเปลี่ยน (WalletInvestor, 2025) ระบบของเว็บไซต์สามารถแสดงแนวโน้มราคา (Trend Forecast) ได้ทั้งรายวัน รายเดือน และรายปี พร้อมแสดงกราฟ เพื่อช่วยผู้ใช้งานประเมิน

ทิศทางตลาดและประกอบการตัดสินใจลงทุนในระยะสั้น แต่ WalletInvestor ใช้ตัวแบบที่ไม่เปิดเผยและขาดการอธิบายผล ข้อจำกัดเหล่านี้สร้างความเสี่ยงในการตัดสินใจลงทุนโดยเฉพาะในช่วงที่ตลาดผันผวนสูง แม้เว็บไซต์จะเตือนว่าไม่ควรใช้ผลลัพธ์เพื่อการตัดสินใจทางการเงิน แต่การใช้ตัวแบบ AI แบบปิด (Black-Box) ที่ขาดการอธิบายผล อาจทำให้ผู้ลงทุนที่นำไปใช้จริงตัดสินใจผิดพลาดได้ง่ายเมื่อสถานการณ์เปลี่ยนอย่างกะทันหัน การปฏิบัตินี้ก่อให้เกิดความเสี่ยงเชิงระบบ (Systemic Risk) และความเสี่ยงของตัวแบบจำลอง (Model Risk) ซึ่งสอดคล้องกับข้อเตือนของ WalletInvestor เองที่ระบุว่าไม่รับประกันความแม่นยำของผลลัพธ์

การพัฒนาทางด้านการเรียนรู้ของเครื่อง (Machine Learning: ML) สามารถยกระดับประสิทธิภาพการพยากรณ์ราคาทองคำได้ เช่น Weng et al. (2020) ใช้ตัวแบบ GA-ROSELM รวมราคาน้ำมันดิบและเงิน (Silver) เป็นข้อมูลนำเข้า ได้ผลดีกว่า ตัวแบบบูรณาการถดถอยอัตโนมัติและค่าเฉลี่ยเคลื่อนที่ (Autoregressive Integrated Moving Average: ARIMA) เครื่องเวกเตอร์สนับสนุน (Support Vector Machine: SVM) และ เครื่องเรียนรู้เชิงสุดขีด (Extreme Learning Machine: ELM) แบบเดิมๆ รวมทั้ง Chandar et al. (2020) พบว่า ELM ที่รวมข้อมูลราคาทองคำ เงินค่า น้ำมัน และดัชนี S&P 500 ให้ผลแม่นยำกว่าการวิเคราะห์เชิงอนุกรมแบบดั้งเดิม อีกทั้งการเปรียบเทียบระหว่างตัวแบบต่างๆ พบว่าหน่วยความจำระยะยาวแบบลำดับ (Long Short-Term Memory: LSTM) ซึ่งเป็นโครงข่ายประสาทเทียมแบบวนซ้ำ (Recurrent Neural Network: RNN) มักให้ผลลัพธ์ที่ดี เนื่องจากสามารถจัดการเปลี่ยนแปลงตามเวลาในข้อมูลชุดย้อนหลังได้ดีกว่า

นอกจากนี้ยังมีการใช้ตัวแบบ XGBoost ซึ่งเป็น Algorithm การเพิ่มประสิทธิภาพแบบขั้นบันได (Gradient Boosting Algorithm) ข้อมูลที่มีโครงสร้าง เช่น Yixian and Li, (2024) พบว่า XGBoost เป็นตัวแบบที่มีความแม่นยำสูงและให้ผลลัพธ์ที่เสถียรสำหรับการพยากรณ์ราคาทองคำ และเมื่อผสมผสานเทคนิคอธิบายตัวแบบอย่าง SHAP (SHapley Additive exPlanations) เข้าด้วยกัน งานวิจัยของ Jabeur et al. (2024) แสดงให้เห็นว่าปัจจัยทางเศรษฐกิจ เช่น อัตราเงินเฟ้อและอัตราดอกเบี้ย มีบทบาทสำคัญอย่างชัดเจนในการขับเคลื่อนราคาทองคำ ช่วยให้การอธิบายผลลัพธ์โปร่งใสยิ่งขึ้น เพิ่มความเชื่อมั่นในการนำผลลัพธ์ไปใช้งาน

จากข้อจำกัดของวิธีการเดิมและช่องว่างขององค์ความรู้ดังกล่าว งานวิจัยนี้จึงมุ่งพัฒนาเว็บแอปพลิเคชันสำหรับทำนายราคาทองคำรายวันแบบเรียลไทม์ โดยจะพยากรณ์ข้อมูลสำคัญครบถ้วน ทั้ง ราคาสูงสุด (High) ราคาต่ำสุด (Low) และราคาปิด (Close) ประจำวัน โดยบูรณาการข้อมูลจากหลายแหล่งรวมทั้งตัวชี้วัดเศรษฐกิจมหภาคสำคัญ นำมาประมวลผลด้วยตัวแบบ ML ได้แก่ Linear Regression CatBoost XGBoost LightGBM และ LSTM เพื่อเปรียบเทียบว่าตัวแบบไหนดีที่สุดในการพยากรณ์ราคาทองคำ พร้อมกับใช้เทคนิค SHAP เพื่ออธิบายผลการทำนายให้โปร่งใส ผู้ใช้งานจึงสามารถเข้าถึงผลลัพธ์การพยากรณ์ที่เชื่อถือได้ ช่วยให้นักลงทุนรายย่อยและนักเทรดระยะสั้น (Short-term Traders) สามารถเข้าถึงการพยากรณ์ราคาทองคำรายวันได้แบบเรียลไทม์เข้าใจแนวโน้มตลาดจากข้อมูลจริง เพื่อช่วยในการตัดสินใจซื้อขายในจังหวะที่เหมาะสม ลดความเสี่ยงจากความผันผวนของตลาด และเพิ่มโอกาสสร้างผลตอบแทน

1.2 วัตถุประสงค์

1.2.1 เพื่อสร้างตัวแบบการพยากรณ์ราคาทองคำแบบเรียลไทม์โดยใช้ข้อมูลที่มีการอัปเดตอย่างต่อเนื่องจากหลายแหล่งข้อมูลที่สามารถใช้ได้

1.2.2 เพื่อพัฒนาเว็บแอปพลิเคชันสำหรับนำเสนอผลการพยากรณ์ราคาทองคำในรูปแบบที่เข้าใจง่าย

1.3 ประโยชน์ที่คาดว่าจะได้รับ

1.3.1 ได้ตัวแบบการพยากรณ์ราคาทองคำที่มีความทันสมัย ที่ใช้ข้อมูลแบบเรียลไทม์

1.3.2 ได้เว็บแอปพลิเคชันที่สามารถนำเสนอข้อมูลและผลการทำนายราคาทองคำล่วงหน้าแบบเรียลไทม์ที่เข้าใจง่าย ซึ่งผู้ใช้งานสามารถเข้าถึงได้สะดวกทั้งบนคอมพิวเตอร์และอุปกรณ์พกพา

1.4 ขอบเขตงานวิจัย

งานวิจัยนี้มุ่งศึกษาการพยากรณ์ ราคาทองคำต่ำสุด-สูงสุดรายวันและราคาปิดรายวัน (USD/oz) แบบเรียลไทม์ โดยประยุกต์ใช้เทคนิคการเรียนรู้ของเครื่อง (Machine Learning) ในการพยากรณ์ โดยอาศัยข้อมูลย้อนหลัง 10 ปี นับตั้งแต่วันที่ปัจจุบัน จาก Yahoo Finance และ Federal Reserve Economic Data (FRED) ซึ่งเป็นฐานข้อมูลมาตรฐานสากล

1.4.1 ขอบเขตของข้อมูลและการจัดการความถี่

ข้อมูลด้านการเงินและสินค้าโภคภัณฑ์ใช้ความถี่รายวัน ส่วนข้อมูลเศรษฐกิจมหภาคที่เผยแพร่เป็นรายเดือนจะถูกจัดให้อยู่ในรอบรายวันด้วยวิธี forward fill เพื่อความสอดคล้องในการวิเคราะห์ หน่วยอ้างอิงผลการพยากรณ์เป็น ดอลลาร์สหรัฐต่อทรอยออนซ์ (USD/oz) และกำหนดขอบเขตของการพยากรณ์เป็นล่วงหน้า 1 วัน

ตารางที่ 1 ตัวแปรที่ใช้ในการวิเคราะห์และพยากรณ์ราคาทองคำ

ลำดับ	ชื่อตัวแปร (Variable)	คำอธิบาย	หน่วย (Unit)	แหล่งข้อมูล (Data Source)
1	ราคาเปิดทองคำ (Gold Open Price: Open)	ราคาทองคำ ณ เวลาเปิดการซื้อขายของแต่ละวัน	ดอลลาร์สหรัฐต่อทรอยออนซ์ (USD/Oz)	Yahoo Finance (XAUUSD=X)
2	ราคาสูงสุดทองคำ (Gold High Price: High)	ราคาทองคำสูงสุดที่เกิดขึ้นระหว่างวัน	ดอลลาร์สหรัฐต่อทรอยออนซ์ (USD/Oz)	Yahoo Finance (XAUUSD=X)
3	ราคาต่ำสุดทองคำ (Gold Low Price: Low)	ราคาทองคำต่ำสุดที่เกิดขึ้นระหว่างวัน	ดอลลาร์สหรัฐต่อทรอยออนซ์ (USD/Oz)	Yahoo Finance (XAUUSD=X)
4	ราคาปิดทองคำ (Gold Close Price: Close)	ราคาทองคำ ณ เวลาปิดการซื้อขายของแต่ละวัน	ดอลลาร์สหรัฐต่อทรอยออนซ์ (USD/Oz)	Yahoo Finance (XAUUSD=X)

5	ปริมาณการซื้อขายทองคำ (Gold Trading Volume)	จำนวนสัญญาซื้อขายที่เกิดขึ้นในวันนั้น (วัดสภาพคล่อง/แรงส่งของแนวโน้ม)	ดอลลาร์สหรัฐต่อทรอยออนซ์ (USD/Oz)	Yahoo Finance (GC=F)
6	ราคาเงิน (Silver Price)	ราคาของโลหะเงินต่อหนึ่งทรอยออนซ์	ดอลลาร์สหรัฐต่อทรอยออนซ์ (USD/Oz)	Yahoo Finance (SI=F)
7	ราคาน้ำมันดิบ (Crude Oil Price)	ราคาน้ำมันดิบในตลาดโลกต่อหนึ่งบาร์เรล	ดอลลาร์สหรัฐต่อบาร์เรล (USD/Barrel)	Yahoo Finance (CL=F)
8	ราคาแร่เหล็ก (Iron Ore Price)	ราคาแร่เหล็ก	ดอลลาร์สหรัฐต่อเมตริกตัน (USD/MT)	Yahoo Finance (TIO=F)
9	ดัชนีตลาดหุ้น S&P 500 (S&P 500 Index)	ดัชนีราคาหุ้นของบริษัทขนาดใหญ่ในสหรัฐอเมริกา 500 แห่ง	ดัชนี (Index Points)	Yahoo Finance (^GSPC)
10	อัตราผลตอบแทนพันธบัตรรัฐบาลสหรัฐฯ อายุ 10 ปี (10-Year US Treasury Yield)	อัตราผลตอบแทนจากพันธบัตรรัฐบาลสหรัฐฯ อายุ 10 ปี	เปอร์เซ็นต์ต่อปี (%) per annum)	Yahoo Finance (^TNX)
11	ดัชนีดอลลาร์สหรัฐ (US Dollar Index)	ดัชนีที่วัดค่าเงินดอลลาร์สหรัฐเมื่อเทียบกับตะกร้าสกุลเงินหลัก	ดัชนี (Index Points)	Yahoo Finance (DX-Y.NYB)
12	อัตราเงินเฟ้อ (Inflation Rate: CPI, YoY Change)	อัตราการเปลี่ยนแปลงของดัชนีราคาผู้บริโภคเมื่อเทียบกับช่วงเดียวกันของปีก่อน	เปอร์เซ็นต์เมื่อเทียบกับช่วงเดียวกันของปีก่อน (% Year-over-Year)	FRED (CPIAUCSL)

1.4.2 ขอบเขตการดำเนินการของงานวิจัย

กระบวนการวิจัยหลักจะเริ่มต้นด้วยการสร้างและเปรียบเทียบตัวแบบหลายชนิด ได้แก่ Linear Regression CatBoost XGBoost LightGBM และ LSTM ภายใต้การประเมินผลเดียวกันคือการตรวจสอบไขว้ข้อมูลอนุกรมเวลาแบบ walk-forward เพื่อคัดเลือกตัวแบบที่ให้ผลการพยากรณ์แม่นยำที่สุด จากนั้นเพื่อให้ตัวแบบที่เลือกมามีความโปร่งใสและสามารถตีความได้ งานวิจัยนี้จะประยุกต์ใช้เทคนิค SHAP เพื่ออธิบายความสำคัญของตัวแปรและกลไกการตัดสินใจของตัวแบบ ทั้งในระดับภาพรวมและรายกรณี ในท้ายที่สุดทั้งผลการพยากรณ์จากตัวแบบและผลการอธิบายตัวแบบจาก SHAP จะถูกนำไปพัฒนาเป็นเว็บแอปพลิเคชัน เพื่อนำเสนอผลลัพธ์ทั้งหมดในรูปแบบเรียลไทม์ที่ผู้ใช้ทั่วไปสามารถเข้าถึงและทำความเข้าใจได้ง่าย

1.5 นิยามศัพท์เฉพาะ

1.5.1 ราคาเปิดทองคำ (Gold Open Price: Open)

หมายถึง ราคาซื้อขายครั้งแรกของคาบเวลาที่ศึกษา ในกรณีนี้คือ รายวัน อันเป็นจุดเริ่มต้นของการก่อตัวของช่วงราคาในคาบนั้น สำหรับตลาดแลกเปลี่ยนที่มีเวลาทำการชัดเจน ราคาเปิดจะอ้างอิงถึงครั้งแรกหลังเปิดตลาด ส่วนตราสารที่ซื้อขายเกือบตลอดเวลา ผู้ให้บริการข้อมูลจะกำหนดจุดเริ่มต้นวันตามเกณฑ์ของตนเพื่อระบุราคาเปิด การวิเคราะห์เชิงประจักษ์นิยมใช้ส่วนต่างระหว่างราคาเปิดและราคาปิดของวันเดียวกันเพื่อสะท้อนแรงซื้อขายสุทธิและแนวโน้มเบื้องต้นของตลาดในวันนั้น

1.5.2 ราคาสูงสุดทองคำ (Gold High Price: High)

หมายถึง ราคาสูงสุดที่มีการซื้อขายสำเร็จภายในคาบเวลา ทำหน้าที่เป็นขอบบนของช่วงการแกว่งราคาและใช้ประกอบการคำนวณตัวชี้วัดความผันผวนที่อาศัยช่วงราคา (range-based volatility) ตลอดจนเป็นข้อมูลตั้งต้นของการวิเคราะห์เชิงเทคนิคเกี่ยวกับแนวโน้ม

1.5.3 ราคาต่ำสุดทองคำ (Gold Low Price: Low)

หมายถึง ราคาต่ำสุดที่มีการซื้อขายสำเร็จภายในคาบเวลา ทำหน้าที่เป็นขอบล่างของช่วงการแกว่งราคา ใช้ร่วมกับราคาสูงสุดเพื่อคำนวณช่วง High-Low และตัวประมาณความผันผวนที่มีประสิทธิภาพในเชิงสถิติ

1.5.4 ราคาปิดทองคำ (Gold Close Price: Close)

หมายถึง ราคาอย่างเป็นทางการเมื่อสิ้นสุดวันตามข้อกำหนดของตลาด ทั้งนี้ แหล่งข้อมูลทั่วไปมักรายงานราคาปิดเป็นราคาซื้อขายสุดท้ายในคาบเวลา โดยราคาปิดเป็นฐานสำคัญของการคำนวณผลตอบแทน และเป็นตัวแปรหลักของอินดิเคเตอร์ทางเทคนิคจำนวนมาก

1.5.5 ปริมาณการซื้อขาย (Volume)

หมายถึง จำนวนธุรกรรมที่เกิดขึ้นจริงภายในคาบเวลา ใช้เป็นตัวแทนสภาพคล่องและความเข้มข้นของการมีส่วนร่วมในตลาด โดยมีนัยสำคัญต่อการประเมินแรงส่งของแนวโน้ม (trend strength) กล่าวคือ การเคลื่อนไหวของราคาที่มาพร้อมปริมาณซื้อขายสูงมักมีความน่าเชื่อถือเชิงสถิติมากกว่า

1.5.6 อัตราผลตอบแทนพันธบัตรรัฐบาลสหรัฐฯ อายุ 10 ปี (10-Year US Treasury Yield)

หมายถึง ผลตอบแทนประจำปีของพันธบัตรรัฐบาลสหรัฐฯ ที่มีอายุครบกำหนด 10 ปี มีหน่วยเป็นเปอร์เซ็นต์ต่อปี (% per annum) ใช้เป็นตัวแทนของอัตราดอกเบี้ยในตลาดการเงินที่มีผลต่อการตัดสินใจลงทุนในทองคำ

1.5.7 ดัชนีดอลลาร์สหรัฐฯ (US Dollar Index)

หมายถึง ดัชนีที่แสดงความแข็งแกร่งหรืออ่อนค่าของเงินดอลลาร์สหรัฐฯ เมื่อเทียบกับตะกร้าสกุลเงินหลัก เช่น ยูโร เยน ปอนด์ เป็นต้น มีหน่วยเป็นค่าดัชนี (Index Points) โดยปกติแล้วจะมีความสัมพันธ์ผกผันกับราคาทองคำ

1.5.8 ราคาน้ำมันดิบ (Crude Oil Price)

หมายถึง ราคาน้ำมันดิบต่อหนึ่งบาร์เรลในหน่วยดอลลาร์สหรัฐฯ (USD/Barrel) ซึ่งส่งผลกระทบต่อความผันผวนทางเศรษฐกิจ และอาจมีผลกระทบทางอ้อมต่อราคาทองคำ

1.5.9 ราคาเงิน (Silver Price)

หมายถึง ราคาของโลหะเงินต่อหนึ่งทรอยออนซ์ (USD/Oz) ซึ่งมักมีแนวโน้มเคลื่อนไหวในทิศทางเดียวกันกับราคาทองคำ เนื่องจากเป็นโลหะมีค่าเช่นเดียวกัน

1.5.10 ดัชนี S&P 500 (S&P 500 Index)

หมายถึง ดัชนีราคาหุ้นที่แสดงถึงสภาพตลาดหุ้นสหรัฐฯ โดยอิงจากมูลค่าหุ้นของบริษัทจดทะเบียนขนาดใหญ่ 500 แห่ง เป็นตัวแทนของภาวะเศรษฐกิจและสภาพคล่องของตลาดการเงินโดยรวม

1.5.11 อัตราเงินเฟ้อ (Inflation Rate)

หมายถึง อัตราการเปลี่ยนแปลงของระดับราคาสินค้าและบริการทั่วไปเมื่อเทียบกับช่วงเวลาเดียวกันของปีก่อน มีหน่วยเป็นเปอร์เซ็นต์ (% YoY) เป็นตัวชี้วัดภาวะเศรษฐกิจที่มีผลต่อความต้องการลงทุนในสินทรัพย์ปลอดภัย เช่น ทองคำ

1.5.14 สินทรัพย์ปลอดภัย (Safe Haven Asset)

หมายถึง สินทรัพย์ที่นักลงทุนมักถือครองในช่วงเศรษฐกิจผันผวนหรือเกิดวิกฤติ เช่น ทองคำ ซึ่งคาดว่าจะรักษามูลค่าและลดความเสี่ยงได้ดีกว่าสินทรัพย์ประเภทอื่น

1.5.15 Yahoo Finance API

หมายถึง บริการจาก Yahoo Finance ที่ให้ข้อมูลด้านการเงินและตลาดหุ้นแบบออนไลน์ ซึ่งสามารถเข้าถึงผ่านไลบรารี yfinance ในภาษา Python เพื่อดึงข้อมูลราคาสินทรัพย์และดัชนีการเงินแบบอัตโนมัติ

1.5.12 FRED (Federal Reserve Economic Data)

หมายถึง ฐานข้อมูลเศรษฐกิจและการเงินของธนาคารกลางสหรัฐฯ (Federal Reserve Bank of St. Louis: St. Louis Fed) ที่เผยแพร่ข้อมูลอนุกรมเวลาของตัวชี้วัดทางเศรษฐกิจ เช่น CPI, GDP, และอัตราดอกเบี้ย เพื่อใช้วิเคราะห์แนวโน้มเศรษฐกิจ

1.5.13 กล่องดำ (Black-Box)

หมายถึง แบบจำลองหรือระบบวิเคราะห์ที่ไม่เปิดเผยกลไกภายในอย่างเพียงพอ ผู้ใช้รับรู้ได้เพียงอินพุตและเอาต์พุต โดยไม่สามารถตรวจสอบเหตุผลเชิงขั้นตอนที่ทำให้เกิดคำทำนายได้ ความโปร่งใสต่ำดังกล่าวทำให้ตรวจหาความลำเอียงของข้อมูล (data bias) ความผิดพลาดของแบบจำลอง หรือขอบเขตการใช้งานที่เหมาะสมได้ยาก (SHapley Additive Explanations) เพื่อให้ผู้ใช้เข้าใจว่าปัจจัยใดมีส่วนผลักดันการพยากรณ์ในแต่ละช่วงเวลา

1.5.14 นักเทรดระยะสั้น (Short-term Traders)

หมายถึง ผู้ซื้อขายที่มุ่งทำกำไรจากการแกว่งตัวในช่วงเวลาสั้นตั้งแต่นาที ชั่วโมง วัน จนถึงไม่กี่สัปดาห์ กลยุทธ์มักอาศัยสัญญาณความถี่สูงและตัวแปรจากชุดข้อมูลราคาและปริมาณ (OHLCV) เช่น ช่วง High-Low โมเมนตัม ค่าเฉลี่ยเคลื่อนที่ และบริบทสภาพคล่อง (Volume) ผู้ใช้กลุ่มนี้ต้องการข้อมูลอัปเดตแบบใกล้เคียงเวลาจริง

บทที่ 2

ทฤษฎีและงานวิจัยที่เกี่ยวข้อง

2.1 งานวิจัยที่เกี่ยวข้อง

2.1.1 ความรู้พื้นฐานเกี่ยวกับทองคำและตลาดทองคำ

ทองคำ (Gold) นับเป็นโลหะมีค่าที่มีบทบาทสำคัญทั้งในการแลกเปลี่ยน บันทึกราคา และใช้ในอุตสาหกรรมเครื่องประดับรวมถึงอิเล็กทรอนิกส์บางประเภทด้วย นอกจากนั้น ทองคำยังได้รับการยอมรับว่าเป็น สินทรัพย์ปลอดภัย (Safe Haven Asset) สำหรับนักลงทุนในช่วงวิกฤตเศรษฐกิจ เช่น วิกฤตการเงินโลกปี 2008 (Baur & McDermott, 2010) และช่วงการแพร่ระบาดของ COVID-19 (Akhtaruzzaman et al., 2021), รวมถึงการใช้ข้อมูลความถี่สูงในช่วงวิกฤต COVID-19 ที่ยืนยันว่าทองคำทำหน้าที่เป็นที่หลบภัยเมื่อเทียบกับตลาดหุ้น (Ji et al., 2020)

นอกจากบทบาทของทองคำในฐานะสินทรัพย์ปลอดภัยแล้ว การศึกษาด้านข้อมูลราคาทองคำยังให้ความสำคัญกับชุดข้อมูลราคาที่เกิดขึ้นในแต่ละวัน ซึ่งเรียกว่า ข้อมูลราคาแบบ OHLCV ได้แก่ ราคาเปิด (Open), ราคาสูงสุด (High), ราคาต่ำสุด (Low), ราคาปิด (Close) และ ปริมาณการซื้อขาย (Volume) ข้อมูลเหล่านี้ถือเป็นรากฐานของการวิเคราะห์แนวโน้มราคาและความผันผวนในตลาดทองคำ รวมถึงใช้กันอย่างแพร่หลายในการพัฒนาแบบจำลองการพยากรณ์ราคาด้วยวิธีเชิงสถิติและการเรียนรู้ของเครื่อง (Machine Learning) (Andersen et al., 2003; Karpoff, 1987)

ราคาเปิด (Open) หมายถึงราคาซื้อขายครั้งแรกของคาบเวลานั้น เช่น ราคาทองคำที่เริ่มต้นการซื้อขายในแต่ละวัน ซึ่งสะท้อนจิตวิทยาและความคาดหวังของนักลงทุนในช่วงเริ่มต้นของตลาด ส่วน ราคาสูงสุด (High) คือราคาที่สูงที่สุดที่เกิดขึ้นระหว่างวัน ซึ่งมักใช้เป็นตัวแทนของแรงซื้อสูงสุดและใช้ร่วมกับราคาต่ำสุดในการวัดช่วงความผันผวนของตลาด (Parkinson, 1980; Garman & Klass, 1980) ขณะที่ ราคาต่ำสุด (Low) หมายถึงราคาที่ต่ำที่สุดที่เกิดขึ้นในช่วงเวลาการซื้อขายเดียวกัน แสดงถึงแรงขายสูงสุดของนักลงทุนในวันนั้น การเปรียบเทียบส่วนต่างระหว่าง High และ Low (High-Low range) จึงใช้ในการคำนวณ “ความผันผวนช่วงจริง” (realized volatility) ซึ่งเป็นตัวชี้วัดที่นิยมในงานวิจัยทางการเงิน (Andersen et al., 2003)

และราคาปิด (Close) คือราคาซื้อขายครั้งสุดท้ายของคาบเวลา ซึ่งมักใช้เป็นราคามาตรฐานในการคำนวณผลตอบแทนและใช้สร้างสัญญาณการซื้อขาย เช่น เส้นค่าเฉลี่ยเคลื่อนที่ (Moving Average) โดยส่วนต่างระหว่างราคาเปิดและราคาปิด (Open-Close) สามารถสะท้อนแรงซื้อขายสุทธิและแนวโน้มของตลาดในวันนั้นได้อย่างชัดเจน (Jegadeesh & Titman, 1993) ส่วน ปริมาณการซื้อขาย (Volume) หมายถึงจำนวนธุรกรรมหรือสัญญาที่เกิดขึ้นจริงในช่วงเวลานั้น ซึ่งเป็นตัวบ่งชี้ระดับสภาพคล่องและแรงส่งของแนวโน้ม (trend strength) การเปลี่ยนแปลงของปริมาณการซื้อขายมักมีความสัมพันธ์กับขนาดการเปลี่ยนแปลงของราคา กล่าวคือ การเพิ่มขึ้นของปริมาณการซื้อขายมักเกิดควบคู่กับความผันผวนที่สูงขึ้นในตลาด (Campbell et al., 1993; Karpoff, 1987)

2.1.2 ปัจจัยที่มีผลกระทบต่อราคาทองคำ

ราคาทองคำได้รับอิทธิพลจากหลายปัจจัย ทั้งด้านเศรษฐกิจมหภาค ตลาดการเงิน และพฤติกรรมของนักลงทุน งานวิจัยหลายชิ้นได้ระบุปัจจัยสำคัญที่ส่งผลต่อการเปลี่ยนแปลงของราคาทองคำอย่างมีนัยสำคัญ

ปัจจัยแรกคือ ราคาน้ำมันดิบ (Crude Oil Price) Zhang and Li, (2022) ศึกษาความสัมพันธ์เชิงโครงสร้างระหว่างราคาสินค้าโภคภัณฑ์หลักกับราคาทองคำ โดยใช้ตัวแบบเชิงเศรษฐมิติ พบว่าราคาน้ำมันมีความสัมพันธ์เชิงบวกกับราคาทองคำอย่างมีนัยสำคัญ เนื่องจากราคาน้ำมันเป็นตัวสะท้อนต้นทุนพลังงานและแรงกดดันเงินเฟ้อ เช่นเดียวกับ Wang et al., (2023) ที่ใช้ตัวแบบการทดสอบเชิงเวลา พบว่าช่วงวิกฤติรัสเซีย-ยูเครนปี 2022 การพุ่งสูงของราคาน้ำมันนำไปสู่การปรับตัวขึ้นของราคาทองคำ

อีกปัจจัยหนึ่งคือ อัตราเงินเฟ้อ (Inflation Rate) Jabeur et al., (2024) ได้ศึกษาผลกระทบของปัจจัยเศรษฐกิจมหภาคต่อราคาทองคำ โดยใช้ Machine Learning พบว่าเงินเฟ้อเป็นตัวแปรที่ส่งผลต่อราคาทองคำมากที่สุด โดยเฉพาะในช่วงที่เศรษฐกิจสหรัฐเผชิญเงินเฟ้อสูงหลังการแพร่ระบาดของโควิด-19 ราคาทองคำปรับตัวเพิ่มขึ้นต่อเนื่อง แสดงบทบาทของทองคำในฐานะสินทรัพย์ป้องกันเงินเฟ้อ (Hedge Against Inflation)

นอกจากนี้ ดัชนีดอลลาร์สหรัฐ (US Dollar Index) ก็เป็นอีกหนึ่งปัจจัยสำคัญ งานของ Jabeur et al., (2024) และ Wang et al., (2023) ศึกษาความสัมพันธ์ระหว่างค่าเงินดอลลาร์กับราคาทองคำ โดยใช้การวิเคราะห์เชิงเวลา พบความสัมพันธ์เชิงลบอย่างมีนัยสำคัญ กล่าวคือเมื่อค่าเงินดอลลาร์แข็งค่า ราคาทองคำจะปรับตัวลดลง เช่น ในปี 2018 ที่ดัชนีดอลลาร์แข็งค่าต่อเนื่อง ราคาทองคำลดลงตามไปด้วย

ในด้านของ ดัชนีตลาดหุ้น S&P 500 Zhang and Li, (2022) ได้ศึกษาความสัมพันธ์ระหว่างตลาดหุ้นกับทองคำ พบว่าช่วงที่ตลาดหุ้นปรับตัวลดลง นักลงทุนหันไปลงทุนในทองคำเพื่อป้องกันความเสี่ยง ข้อค้นพบนี้สอดคล้องกับ Guo et al., (2024) ที่ขยายการวิเคราะห์ไปยังดัชนี Nasdaq และราคาสินทรัพย์ทางการเงินอื่น ๆ ซึ่งยืนยันว่าการเคลื่อนไหวของตลาดทุนมีบทบาทสำคัญต่อราคาทองคำสำหรับ ผลตอบแทนพันธบัตรรัฐบาลสหรัฐฯ อายุ 10 ปี ซึ่งสะท้อนอัตราดอกเบี้ยระยะยาว มีความสัมพันธ์เชิงลบกับราคาทองคำ โดยเมื่อผลตอบแทนพันธบัตรสูงขึ้น ความน่าสนใจของทองคำจะลดลง เนื่องจากทองคำไม่ให้ดอกเบี้ยตอบแทน งานของ Jabeur et al., (2024) สนับสนุนข้อสรุปนี้

และอัตราผลตอบแทนพันธบัตรรัฐบาลสหรัฐฯ อายุ 10 ปี (US 10Y Treasury Yield) Jabeur et al., (2024) ได้ศึกษาผลกระทบของ Bond Yield ต่อราคาทองคำ พบความสัมพันธ์เชิงลบ โดยเมื่อผลตอบแทนพันธบัตรสูงขึ้น ความน่าสนใจของการถือครองทองคำลดลง เนื่องจากทองคำไม่ให้ดอกเบี้ยตอบแทน

สุดท้ายคือ ราคาของโลหะมีค่าอื่น (Silver Price) Zhang and Li, (2022) ศึกษาการเคลื่อนไหวร่วมกันของโลหะมีค่า พบว่าราคาเงินมีความสัมพันธ์สูงกับราคาทองคำในเชิงบวก ขณะที่ Kushwaha et al., (2023) และ Nagata et al., (2024) ศึกษาความผันผวนของสินทรัพย์ทางการเงินและค่าเงินในระยะสั้น พบว่าการเคลื่อนไหวของโลหะเงินและปัจจัยทางการเงินอื่น ๆ สามารถเป็นตัวชี้้นำราคาทองคำในช่วงเวลาต่าง ๆ ได้

2.2 ผลงานวิจัยที่เกี่ยวข้อง

Jabeur et al. (2024) มุ่งเน้นการพยากรณ์ราคาทองคำโดยให้ความสำคัญทั้งความแม่นยำเชิงทำนาย และความโปร่งใสของตัวแบบ เพื่อให้ผลลัพธ์สามารถนำไปใช้ตัดสินใจเชิงปฏิบัติได้จริง ผู้วิจัยออกแบบการศึกษาในกรอบข้อมูลอนุกรมเวลาแบบหลายตัวแปร (Multivariate) โดยคัดเลือกตัวแปรเศรษฐกิจมหภาคและตัวชี้วัดตลาดการเงินที่เกี่ยวข้องกับราคาทองคำ เช่น ค่าเงินอัตราผลตอบแทนพันธบัตรสหรัฐฯ ราคาน้ำมัน และดัชนีตลาดหุ้น จากนั้นเปรียบเทียบตัวแบบหลายชนิดและพบว่าตัวแบบ XGBoost มีสมรรถนะโดดเด่นที่สุดในชุดข้อมูลที่ทดลอง โดยรายงานความแม่นยำระดับสูง เช่น $R^2 \approx 0.994$ บ่งชี้ถึงความสามารถในการจับความสัมพันธ์ที่ไม่เป็นเชิงเส้นและปฏิสัมพันธ์ระหว่างตัวแปรได้ดี นอกจากนี้ ผู้วิจัยประยุกต์ใช้วิธีการอธิบายแบบเชิงบวกด้วยค่า Shapley เพื่ออธิบาย “สัดส่วนการมีส่วนร่วม” ของแต่ละปัจจัยต่อผลการพยากรณ์ ทำให้ทราบอย่างชัดเจนว่าปัจจัยใดผลักดันราคาทองคำในช่วงเวลาต่าง ๆ จุดเด่นของงานชิ้นนี้อยู่ที่การผสานความแม่นยำกับความอธิบายได้เข้าด้วยกัน ช่วยเพิ่มความน่าเชื่อถือและความยอมรับต่อผลลัพธ์ในบริบทการใช้งานจริง ทั้งในเชิงการลงทุนและเชิงนโยบาย

Wang et al. (2023) พัฒนาระบบพยากรณ์ราคาทองคำโดยเน้นพลวัตเชิงเวลา ของข้อมูล จึงเลือกใช้ LSTM Neural Network ซึ่งเป็นสถาปัตยกรรมโครงข่ายประสาทแบบ โครงข่ายประสาทแบบเวียนซ้ำ (Recurrent Neural Network) ที่ออกแบบมาเพื่อแก้ปัญหการพึ่งพาข้อมูลระยะยาว (Long-Term Dependency) และปัญหาการหายไปของค่าเกรเดียนต์ (Vanishing gradient) ของข้อมูลลำดับเวลา งานวิจัยกำหนดกรอบปัญหาในลักษณะการนำข้อมูลที่เป็น ลำดับ (Sequence) เช่น ข้อความสัญญาณเวลา (Time-Series) หรือเสียง มาประมวลผล แล้วทำนายผลลัพธ์เพียง หนึ่งค่า (One output) โดยสร้างหน้าต่างข้อมูล (Sliding Window) เช่น ใช้ราคาย้อนหลัง 30–60 วันเป็นอินพุตเพื่อทำนายราคาวันถัดไป และบูรณาการตัวแปรมหภาค เช่น ดัชนีค่าเงินและอัตราดอกเบี้ย ร่วมกับข้อมูลราคา เพื่อเพิ่มพลังอธิบายของตัวแบบ กระบวนการทดลองประกอบด้วยการสเกลข้อมูล การแบ่งชุดฝึก ตรวจสอบ ทดสอบตามลำดับเวลา การใช้การหยุดการฝึกเมื่อถึงจุดที่เหมาะสมและการปรับค่าความซับซ้อน (Early Stopping/Regularization) เพื่อลดการเรียนรู้เกินความเหมาะสม (Overfitting) และประเมินผลด้วยตัวชี้วัด ผลการทดลองชี้ว่า LSTM สามารถจับรูปแบบเชิงเวลาและความสัมพันธ์ระยะยาวได้ดี ให้ผลพยากรณ์ที่เสถียรมากกว่าวิธีเชิงสถิติในหลายสถานการณ์ โดยเฉพาะเมื่อมีการผนวกตัวแปรมหภาคเข้ามาร่วมวิเคราะห์ นัยสำคัญของงานนี้คือการยืนยันศักยภาพของโครงข่ายประสาทเชิงลำดับสำหรับสินทรัพย์การเงินที่มีโครงสร้างเวลาเด่นชัดอย่างราคาทองคำ

Zhang and Li, (2022) มุ่งเปรียบเทียบสมรรถนะของตัวแบบการเรียนรู้ของเครื่องในการพยากรณ์ราคาโลหะมีค่า (รวมถึงทองคำ) โดยออกแบบการทดลองให้เป็นธรรมและเที่ยงตรงต่อทุกตัวแบบ ผู้วิจัยคัดเลือกตัวแปรนำเข้าในกรอบเดียวกันและใช้แนวทางประเมินที่คำนึงถึงลำดับเวลา (Time-aware Validation) เช่น การแบ่งชุดข้อมูลแบบ Walk-forward จากนั้นทดสอบ Random Forest LightGBM และ XGBoost โดยควบคุมและปรับจูนพารามิเตอร์สำคัญอย่างเป็นระบบ (เช่น จำนวนต้นไม้ ความลึก อัตราเรียนรู้ อัตราการสุ่มตัวแปร ผลลัพธ์พบว่า XGBoost ให้ผลโดยรวมดีกว่า RF และ LightGBM ในหลายตัวชี้วัดข้อผิดพลาดสะท้อนข้อได้เปรียบของวิธี Gradient Boosting ซึ่งโครงสร้างที่จัดการความไม่เชิงเส้นและปฏิสัมพันธ์ระหว่างตัวแปรได้อย่างมีประสิทธิภาพ อีกทั้งมีกลไก Regularization และ Early Stopping ช่วยควบคุมความซับซ้อนของตัวแบบ การศึกษานี้จึงสนับสนุนการเลือกใช้ XGBoost เป็น Baseline สำคัญเมื่อเป้าหมายคือความแม่นยำเชิงทำนายในบริบทข้อมูลการเงินหลายตัวแปร

Guo et al. (2024) งานวิจัยนี้พัฒนาตัวแบบไฮบริดชื่อ *VMD-RES-CEEMDAN-WOA-XGBoost* ซึ่งรวมเทคนิคการแยกสัญญาณ Variational Mode Decomposition และ CEEMDAN เพื่อลดสัญญาณรบกวนในข้อมูล ก่อนจะใช้ (Whale Optimization Algorithm: WOA) ปรับค่าพารามิเตอร์ของ XGBoost ให้เหมาะสมที่สุด จากนั้นจึงใช้ SHAP เพื่ออธิบายผลลัพธ์ว่าตัวแปรใดมีผลต่อราคาทองคำมากที่สุด เช่น ดัชนี (National Association of Securities Dealers Automated Quotations: Nasdaq) และอัตราผลตอบแทนพันธบัตร 10 ปี ผลการทดลองยืนยันว่าตัวแบบนี้สามารถทำนายราคาทองคำได้แม่นยำและโปร่งใส งานนี้ชี้ให้เห็นว่าการใช้ XGBoost ร่วมกับ SHAP สามารถเพิ่มทั้งความแม่นยำและความเข้าใจ ซึ่งเป็นแนวทางเดียวกับงานวิจัยปัจจุบันที่มุ่งเน้นการพยากรณ์และอธิบายผลลัพธ์ในเวลาเดียวกัน

Kushwaha et al. (2023) ศึกษาการสร้างตัวแบบการรวมตัวแบบ (Ensemble Learning) โดยนำผลลัพธ์จาก Random Forest และ XGBoost มารวมกันผ่านการถดถอยเชิงเส้น (Linear Regression) ทำหน้าที่เป็น Meta Model เพื่อปรับสมดุลระหว่างตัวแบบทั้งสอง ผลการทดลองพบว่าตัวแบบ Ensemble มีความแม่นยำสูงมาก โดยได้ค่า R^2 มากกว่า 0.99 และค่า MAE ต่ำกว่าตัวแบบเดี่ยวอย่างมีนัยสำคัญ การศึกษานี้ชี้ให้เห็นว่า การรวมตัวแบบหลายชนิดสามารถเพิ่มประสิทธิภาพในการพยากรณ์ได้จริง ซึ่งสอดคล้องกับโครงการนี้ที่ทดสอบหลายตัวแบบและเปรียบเทียบเพื่อเลือกตัวแบบที่ดีที่สุดสำหรับการพยากรณ์ราคาทองคำ

Nagata et al. (2024) นำเสนอการใช้ตัวแบบ LSTM ซึ่งเป็นโครงข่ายประสาทเทียมที่เหมาะสมกับข้อมูลอนุกรมเวลา เนื่องจากสามารถจดจำข้อมูลในอดีตและเรียนรู้ความสัมพันธ์ตามลำดับเวลาได้ การทดลองกับข้อมูลราคาทองคำรายวัน รายสัปดาห์ และรายเดือนพบว่า LSTM สามารถจับรูปแบบการเคลื่อนไหวของราคาได้อย่างมีประสิทธิภาพ โดยให้ค่า RMSE ประมาณ 21.27 สำหรับข้อมูลรายวัน และ 107.93 สำหรับข้อมูลรายเดือน อย่างไรก็ตาม การใช้ LSTM ต้องการข้อมูลจำนวนมากและพลังการประมวลผลสูง จึงมีข้อจำกัดในแง่การใช้งานจริง งานวิจัยนี้สะท้อนให้เห็นถึงทางเลือกที่แตกต่างจาก Tree-Based Models ที่โครงการปัจจุบันเลือกใช้ ซึ่งแม้ไม่ซับซ้อนเชิงโครงสร้างเท่า แต่มีความแม่นยำและตีความได้ง่ายกว่า

Dalimunthe et al. (2025) เสนอระบบพยากรณ์ราคาทองคำด้วย LSTM โดยใช้ข้อมูลรายวันจาก Yahoo Finance (Open, High, Low, Close) ครอบคลุม 2022–2024 และปรับสเกลด้วย MinMaxScaler ก่อนฝึกแบบจำลอง ผลการประเมินรายงาน MAE เฉลี่ย 19.81 และ MAPE เฉลี่ย 0.83% แสดงถึงความแม่นยำสูง ทั้งนี้ ผู้วิจัยต่อยอดเป็นเว็บแอปเชื่อมต่อข้อมูลแบบเรียลไทม์ ช่วยให้ผู้ใช้งานโต้ตอบและมองเห็นผลทำนายผ่านกราฟ/ตารางได้ทันที ซึ่งชี้ให้เห็นถึงศักยภาพของ LSTM สำหรับงานพยากรณ์อนุกรมเวลาของราคาทองคำในสภาพตลาดที่ผันผวน

Nurjananti (2025) นำเสนอระบบพยากรณ์การเคลื่อนไหวราคาทองคำด้วย LSTM โดยใช้ข้อมูล Yahoo Finance รายวันช่วงปี 2015–2025 (Open, High, Low, Close, Volume) ทำ Min-Max Scaling และทดสอบสัดส่วน train:test แบบ 70:30 และ 80:20 พร้อมจูนไฮเปอร์พารามิเตอร์ผ่าน Grid Search และ Bayesian Optimization ผลที่ดีที่สุดให้ MAE \approx 19.55, RMSE \approx 26.53 และ MAPE \approx 0.93% (split 70:30, Grid Search) จากนั้นพัฒนาระบบเว็บ (Flask) ที่ดึงข้อมูลล่าสุด แสดงแดชบอร์ด และอัปเดตตัวแบบอัตโนมัติด้วยตัวดึงข้อมูลและตัวตั้งเวลาใน Python ตอกย้ำความเหมาะสมของ LSTM สำหรับอนุกรมเวลาราคาทองคำทั้งในเชิงความแม่นยำและความพร้อมใช้งานจริง

2.2.1 ตารางเปรียบเทียบผลงานวิจัยที่เกี่ยวข้อง

ตารางที่ 2 สรุปและเปรียบเทียบผลงานวิจัยที่เกี่ยวข้องกับการพยากรณ์ราคาทองคำ

ผู้วิจัย/ปี	วิธีการที่ใช้	ตัวแปร/ข้อมูลที่ศึกษา	ผลลัพธ์หลัก	ความแตกต่างเชิงระเบียบวิธี
Jabeur et al. (2024)	XGBoost พร้อมการตีความด้วย SHAP	ปัจจัยเศรษฐกิจมหภาค (เงินเฟ้อ, ดัชนีดอลลาร์, Bond Yield ฯลฯ)	$R^2 \approx 0.994$, ตัวแบบแม่นยำสูงและอธิบายผลลัพธ์ได้	งานของ Jabeur โฟกัสที่ตัวแบบ XGBoost ตัวเดียวเลย แต่โครงงานของเราจะทดสอบตัวแบบหลายๆ แบบ (มีทั้ง Linear, Tree-based, LSTM) มาเทียบกันว่าตัวไหนดีที่สุด โดยใช้กติกา (walk-forward) เดียวกัน และทำายที่สุดผลลัพธ์ของโครงงานเราคือเว็บแอปพลิเคชัน
Wang et al. (2023)	LSTM Neural Network	ราคาทองคำย้อนหลังและตัวแปรเศรษฐกิจมหภาค ได้แก่: ดัชนีสินค้าโภคภัณฑ์ (CRB Index), ดัชนีดอลลาร์ (USD Index), และสเปรด CDS พันธบัตรสหรัฐฯ	RMSE, MAE ต่ำกว่า ARIMA: จับรูปแบบเวลาได้ดี	Wang และคณะ เลือกใช้ LSTM เป็นหลักเพราะเป็นข้อมูลเวลา แต่โครงงานเราไม่ได้ยึดติดกับตัวแบบเดียว เราเอาตัวแบบตระกูลอื่น มาเทียบกับ LSTM ด้วย และทำายที่สุดผลลัพธ์ของโครงงานเราคือเว็บแอปพลิเคชัน
Zhang and Li (2022)	Random Forest, LightGBM, XGBoost	ราคาโลหะมีค่า (รวมทองคำ) และปัจจัยที่เกี่ยวข้อง ได้แก่: ราคาน้ำมันดิบ (Crude Oil), ดัชนีหุ้น (Stock Index), ราคาเงิน (Silver Price), และ ราคาแร่เหล็ก (Iron Ore Price)	XGBoost ดีกว่า RF/LGBM ในหลาย metric	งานวิจัยนี้เทียบ 3 ตัวหลัก (RF, LGBM, XGBoost) โครงงานของเราทำคล้ายกัน แต่เพิ่มตัวเทียบเข้าไปอีก คือ CatBoost และ LSTM เพื่อให้เห็นภาพกว้างขึ้น และเรายังใช้ SHAP อธิบายผลด้วยว่าทำไมตัวแบบถึงทำนายแบบนั้น และนำมาทำเว็บแอปพลิเคชัน

Guo et al. (2024)	Hybrid (VMD + CEEMDAN + WOA + XGBoost) + SHAP	ราคาทองคำ (COMEX Gold Futures) และ ปัจจัยขับเคลื่อนหลัก 2 ตัวคือ: ดัชนี Nasdaq และ อัตราผลตอบแทนพันธบัตร 10 ปี (10Y Bond Yield)	ความแม่นยำสูงและอธิบายตัวแปรได้	งานของ Guo ขึ้นตอนซับซ้อนมาก (มีการแยกสัญญาณ VMD, CEEMDAN) ซึ่งอาจจะทำตามได้ยาก โครงงานของเราจะเน้นกระบวนการที่ตรงไปตรงมา และทำซ้ำได้ง่ายกว่า แต่ยังคงใช้ SHAP เพื่ออธิบายผลเหมือนกัน ทำ्यที่สุดผลลัพธ์ของโครงงานเราคือเว็บแอปพลิเคชัน
Kushwaha et al. (2023)	Ensemble (RF + XGBoost + Linear Regression)	ข้อมูลเศรษฐกิจมหภาค (น้ำมัน, ดอลลาร์ ฯลฯ)	$R^2 > 0.99$, MAE ต่ำกว่าตัวแบบเดี่ยว	งานวิจัยนี้ใช้วิธีเอาตัวแบบ 2 ตัว (RF + XGBoost) มารวมกัน (Ensemble) เพื่อให้แม่นยำขึ้น แต่โครงงานเราจะเน้น 'เปรียบเทียบ' ตัวแบบแต่ละตัวก่อนแล้ว 'เลือก' ตัวที่ดีที่สุดเพียงตัวเดียวไปใช้งานจริง เพื่อให้ระบบไม่ซับซ้อนและอธิบายผลได้ง่าย และพัฒนาเป็นเว็บแอปพลิเคชัน
Nagata et al. (2024)	LSTM (time series, multi-frequency)	ข้อมูลราคาทองคำ (Gold Price) เพียงอย่างเดียว แต่ทดสอบในหลายความถี่ (รายวัน, รายสัปดาห์, และรายเดือน)	RMSE: รายวัน ~21.27, รายเดือน ~107.93	Nagata และคณะ เน้นทดสอบ LSTM กับข้อมูลหลายช่วงเวลา (รายวัน/สัปดาห์/เดือน) แต่โครงงานเราจะโฟกัสที่เป้าหมายเดียว คือ 'ทำนายล่วงหน้า 1 วัน' (1-step ahead) ของราคาทองคำต่ำสุด สูงสุด และราคาปิดรายวัน แล้วพัฒนาเป็นเว็บแอปพลิเคชัน
Dalimunte et al. (2025)	LSTM + เว็บแอป (Streamlit)	ข้อมูลราคาทองจาก Yahoo Finance (2022-2024) โดยใช้: Open, High, Low, Close (OHLC)	MAE \approx 19.81; MAPE \approx 0.83%	งานนี้ใช้ LSTM เป็นตัวหลักในการสร้างเว็บแอป แต่โครงงานเราจะเปรียบเทียบตัวแบบหลายตัว แล้วค่อยเลือกตัวที่ดีที่สุด และเรายังเพิ่มการอธิบายตัวแบบด้วย SHAP เข้าไปด้วย

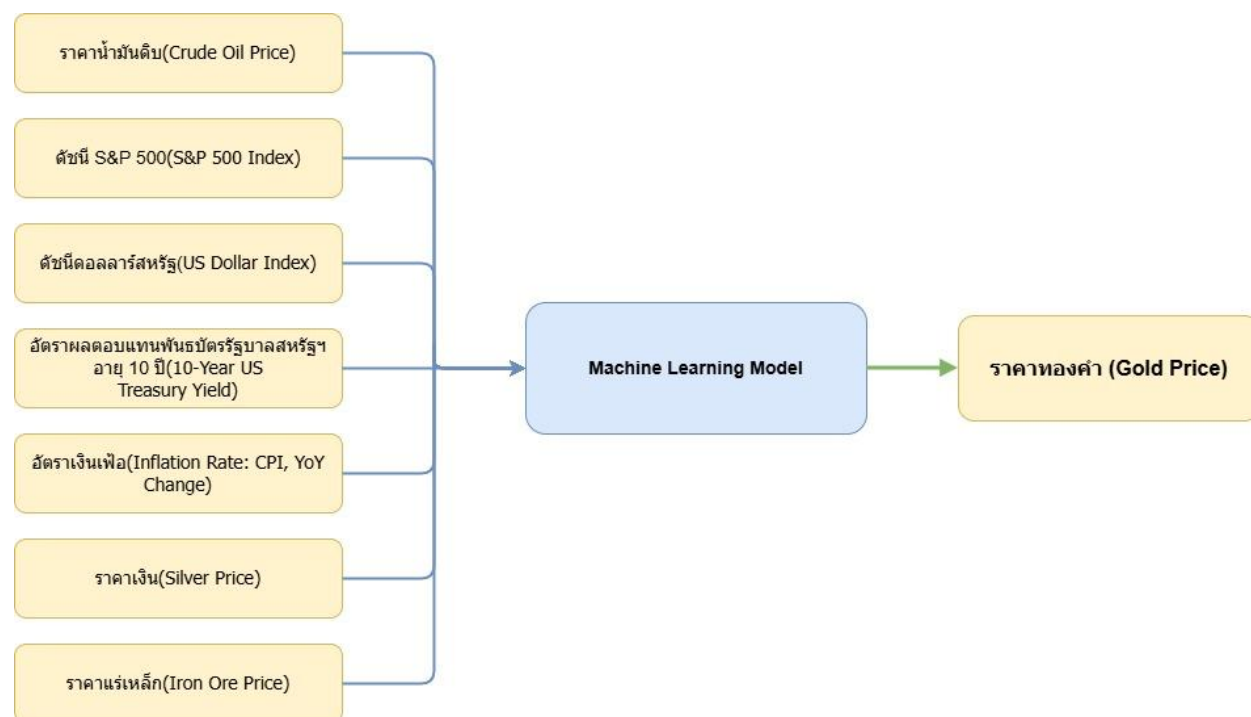
Nurjananti (2025)	LSTM + ระบบเว็บ (Flask) พร้อมปรับปรุง Grid Search/Bayesian	Yahoo Finance 10 ปี (2015-2025) โดยใช้: Open, High, Low, Close, Volume (OHLCV)	ดีที่สุดที่ 70:30 ด้วย Grid Search: MAE = 19.5470, RMSE = 26.5331, MAPE = 0.93%; ระบบอัปเดตตัวแบบรายวันด้วย web-scraping + scheduler และมีแดชบอร์ดโต้ตอบได้	งานวิจัยนี้เน้นไปที่การปรับปรุง LSTM ให้ได้ผลดีที่สุด แต่โครงการเราจะตั้งกติกากำหนด (walk-forward) ขึ้นมา 1 ชุดแล้วใช้กติกานี้ทดสอบกับตัวแบบทุกตัวอย่างเท่าเทียมกัน เพื่อหาว่าตัวแบบไหนเหมาะกับข้อมูลของเราที่สุดจริงๆ และเรายังเพิ่มการอธิบายตัวแบบด้วย SHAP เข้าไปด้วย
-------------------	--	--	---	--

จากตารางที่ 2 งานก่อนหน้าใช้ระเบียบวิธีตั้งแต่เชิงสถิติ (เช่น Multiple Regression, ARIMA) ไปจนถึง Machine Learning/Deep Learning (เช่น Random Forest, LightGBM, XGBoost, LSTM) โดยมีรายงานผลเชิงตัวเลขที่หลากหลาย เช่น Jabeur et al. (2024) รายงานความสอดคล้องเชิงอธิบายสูงของ XGBoost ($R^2 \approx 0.994$); Nagata et al. (2024) แสดงค่า RMSE สำหรับซีรีส์หลายความถี่ (≈ 21.27 รายวัน; ≈ 107.93 รายเดือน); งานเชิงระบบเว็บ-การปรับปรุงด้วย LSTM อาทิ Nurjananti (2025) รายงานผลที่ดีที่สุด MAE = 19.5470, RMSE = 26.5331, MAPE = 0.93%; และ Dalimunthe et al. (2025) รายงาน MAE ≈ 19.81 และ MAPE $\approx 0.83\%$ ขณะที่แนวทางแบบผสม/เอนเซมเบิล (เช่น Guo et al., 2024; Kushwaha et al., 2023) มุ่งเพิ่มความแม่นยำผ่านการรวมแบบจำลองหลายชนิด

เมื่อเทียบกับงานดังกล่าว การศึกษานี้กำหนด “กรอบประเมินเดียวกัน” สำหรับหลายตระกูลตัวแบบ (เชิงเส้น, tree-based, และ neural networks) ภายใต้กระบวนการ walk-forward เดียวกัน รายงานเมตริกมาตรฐาน (RMSE, MAE, MAPE, R^2) และใช้ SHAP เพื่ออธิบายบทบาทของตัวแปรอย่างเป็นระบบ นอกจากนี้ยังเตรียมผลเพื่อการใช้งานจริงในรูปแบบเว็บแอปพลิเคชันแบบเรียลไทม์ แนวทางดังกล่าวจึงต่างจากงานที่เลือกเพียงตัวแบบเดียว (เช่น LSTM หรือ XGBoost) หรือพึ่งพาโครงสร้างแบบผสมที่ซับซ้อน โดยมุ่งเน้น “ความเปรียบเทียบที่เป็นธรรม” และ “ความโปร่งใสในการตีความ” ภายใต้เงื่อนไขข้อมูลชุดเดียวกัน

ในทางปฏิบัติ แม้ผลจากวรรณกรรมจะชี้ว่า XGBoost และ LSTM มักทำผลงานเด่น การศึกษานี้กำหนดให้การคัดเลือกตัวแบบอ้างอิง (baseline) และตัวแบบหลัก พิจารณาจากผลทดสอบบนข้อมูลศึกษาเดียวกันตามกรอบข้างต้น โดยรายงานค่าเมตริกเชิงประจักษ์จากการทดลองของตนเองในหมวดผลการวิจัย และอภิปรายเหตุผลเชิงสาเหตุด้วยค่า SHAP เพื่อยืนยันความเหมาะสมของตัวแบบที่เลือกใช้งานจริงในระบบพยากรณ์ราคาทองคำแบบเรียลไทม์ของ การศึกษานี้

2.3 กรอบแนวคิดการวิจัย



ภาพที่ 1 กรอบแนวคิดการวิจัย

2.4 ทฤษฎีที่เกี่ยวข้อง

2.4.1 ตัวแบบการเรียนรู้ของเครื่อง (Machine Learning Models)

2.4.1.1 การวิเคราะห์ถดถอยเชิงเส้น

การวิเคราะห์ถดถอยเชิงเส้น (Linear Regression) ถือกำเนิดมาตั้งแต่ศตวรรษที่ 19 จากผลงานของ Francis Galton ผู้ใช้คำว่า Regression เพื่ออธิบายความสัมพันธ์ระหว่างลักษณะทางพันธุกรรม ต่อมา Karl Pearson ได้พัฒนาต่อยอดและสร้างกรอบแนวคิดสถิติใหม่ ๆ พร้อมทั้งเสนอค่าสหสัมพันธ์ (Correlation) ในต้นศตวรรษที่ 20 ซึ่งเป็นพื้นฐานสำคัญของการวิเคราะห์เชิงปริมาณ ทั้งนี้ โดยหลักการของการถดถอยเชิงเส้นคือการใช้สมการเชิงเส้นตรงเพื่ออธิบายความสัมพันธ์ระหว่างตัวแปรต้น (Independent Variables) และตัวแปรตาม (Dependent Variable) เพื่อคาดการณ์หรืออธิบายพฤติกรรมของข้อมูล

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p + \epsilon$$

โดยที่

y คือ ตัวแปรตาม

x_i คือ ตัวแปรอิสระ

β_i คือ ค่าสัมประสิทธิ์ถดถอย

ϵ คือ ค่าคลาดเคลื่อน

2.4.1.2 LightGBM

ขั้นตอนวิธีการเสริมแรงแบบเกรเดียนต์ที่มีน้ำหนักเบา LightGBM (Light Gradient Boosting Machine) ถูกพัฒนาโดย Microsoft Research Asia และเปิดตัวในปี ค.ศ. 2017 โดยทีมวิจัยที่นำโดย Guolin Ke ซึ่งได้เผยแพร่บทความในการประชุมวิชาการ *NeurIPS 2017* (Ke et al., 2017) โดยเสนอ LightGBM ให้เป็น Gradient Boosting Framework ที่มีความโดดเด่นในด้านความเร็วในการประมวลผลและประสิทธิภาพในการใช้หน่วยความจำ หลักการสำคัญของ LightGBM คือการใช้ Histogram-Based Algorithm ซึ่งแปลงค่าคุณลักษณะ (Features) เป็น Bin และใช้ Histogram ในการเลือก Split Point ทำให้สามารถฝึกตัวแบบได้รวดเร็วขึ้น ลดการใช้หน่วยความจำ และยังสามารถรองรับข้อมูลขนาดใหญ่ได้ดีกว่า Gradient Boosting แบบดั้งเดิม

$$\text{Obj}(\theta) = \sum_{i=1}^n l(y_i, \hat{y}_i) + \Omega(f)$$

โดยที่

l คือ ฟังก์ชัน loss เช่น Mean Squared Error

$\Omega(f)$ คือ เทอมสำหรับควบคุมความซับซ้อนของตัวแบบ

2.4.1.3 XGBoost

การเสริมแรงแบบเกรเดียนต์ขั้นสูง XGBoost (Extreme Gradient Boosting) ถือกำเนิดขึ้นราวปี ค.ศ. 2014–2016 จากการพัฒนาของ Tianqi Chen ภายใต้การดูแลของ Carlos Guestrin แห่งมหาวิทยาลัยวอชิงตัน โดยผลงานนี้ถูกเผยแพร่ครั้งแรกในที่ประชุมวิชาการ *KDD 2016* (Chen and Guestrin, 2016) และได้รับความนิยมอย่างกว้างขวางในวงการ Data Science เนื่องจาก XGBoost ถูกนำไปใช้เป็นตัวแบบหลักในการแข่งขัน Kaggle จำนวนมากในช่วงเวลานั้น

$$\text{Obj}(\theta) = \sum_{i=1}^n l(y_i, \hat{y}_i) + \sum_{k=1}^K \Omega(f_k)$$

โดยที่

$$\Omega(f) = \gamma T + \frac{1}{2} \lambda |w|^2$$

T คือ จำนวน leaf nodes

w คือ ค่าน้ำหนักของ leaf

γ, λ คือ ค่าพารามิเตอร์ควบคุมความซับซ้อน

2.4.1.4 CatBoost

อัลกอริทึมแบบ Gradient Boosting ที่ออกแบบมาเพื่อจัดการกับข้อมูลแบบ Categorical ได้อย่างมีประสิทธิภาพ (Dorogush et al., 2018) หลักการทำงานคือการสร้างตัวแบบแบบต่อเนื่องหลายตัว (ensemble) โดยในแต่ละรอบ ตัวแบบใหม่จะเรียนรู้จาก ข้อผิดพลาด (residual) ของตัวแบบก่อนหน้า CatBoost มีจุดเด่นคือใช้เทคนิค Ordered Boosting เพื่อลดปัญหา Target Leakage และ Overfitting ทำให้มีประสิทธิภาพสูงกว่าการบูสต์ทั่วไป เช่น XGBoost หรือ LightGBM ในข้อมูลบางประเภท

$$F_t(x) = F_{t-1}(x) + \eta \cdot h_t(x)$$

โดยที่

$F_t(x)$ คือ ตัวแบบที่รอบที่ t

η คือ อัตราการเรียนรู้ (learning rate)

$h_t(x)$ คือ ตัวแบบย่อย (weak learner) ซึ่งมักเป็น Decision Tree

L คือ ฟังก์ชันการสูญเสีย (Loss Function) ที่ CatBoost พยายามลดค่าลงในแต่ละรอบ

$$L = \sum_{i=1}^n l(y_i, F_{t-1}(x_i) + \eta \cdot h_t(x_i))$$

2.4.1.5 LSTM

Long Short-Term Memory Network สถาปัตยกรรมของโครงข่ายประสาทเทียมแบบ Recurrent Neural Network (RNN) ที่ถูกพัฒนาโดย Hochreiter และ Schmidhuber (1997) เพื่อแก้ปัญหา Vanishing Gradient ที่มักเกิดใน RNN แบบดั้งเดิม LSTM ประกอบด้วยหน่วยความจำ (Cell State) ที่สามารถ “จดจำ” หรือ “ลืม” ข้อมูลในลำดับเวลาได้โดยใช้ประตู (Gates) 3 ชนิด ได้แก่ Forget Gate Input Gate Output Gate จึงทำให้ LSTM ถูกใช้กันอย่างแพร่หลายในงาน Time Series Forecasting, NLP, Speech Recognition และงานที่ต้องประมวลผลข้อมูลตามลำดับเวลา

$$\begin{aligned}
 f_t &= \sigma(W_f[h_{t-1}, x_t] + b_f) && \text{(Forget Gate)} \\
 i_t &= \sigma(W_i[h_{t-1}, x_t] + b_i) && \text{(Input Gate)} \\
 \tilde{C}_t &= \tanh(W_C[h_{t-1}, x_t] + b_C) && \text{(Candidate Cell State)} \\
 C_t &= f_t * C_{t-1} + i_t * \tilde{C}_t && \text{(Cell State Update)} \\
 o_t &= \sigma(W_o[h_{t-1}, x_t] + b_o) && \text{(Output Gate)} \\
 h_t &= o_t * \tanh(C_t) && \text{(Hidden State Output)}
 \end{aligned}$$

2.4.2 ตัวชี้วัดประสิทธิภาพของตัวแบบ

2.4.2.1 ค่าความคลาดเคลื่อนสัมบูรณ์เฉลี่ย

ค่าความคลาดเคลื่อนสัมบูรณ์เฉลี่ย Mean Absolute Error (MAE) ใช้แพร่หลายในงานวิจัยด้านสถิติและการพยากรณ์ ตั้งแต่ทศวรรษ 1950 (Willmott and Matsuura, 2005) ใช้ในการคำนวณค่าความคลาดเคลื่อนแบบสัมบูรณ์ระหว่างค่าจริงกับค่าทำนาย โดยเฉลี่ย ีความง่ายว่า “โดยเฉลี่ยแล้วทำนายผิดพลาดกี่หน่วย”

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

โดยที่

y_i คือ ค่าจริง (Observed value)

\hat{y}_i คือ ค่าที่ตัวแบบพยากรณ์ได้ (Predicted value)

n คือ จำนวนข้อมูลทั้งหมด

2.4.2.2 ค่าความคลาดเคลื่อนกำลังสองเฉลี่ย

ค่าความคลาดเคลื่อนกำลังสองเฉลี่ย (Mean Squared Error: MSE) เป็นตัวชี้วัดที่ใช้กันอย่างแพร่หลายในการประเมินตัวแบบ Regression และ Forecasting โดยจะวัด “ระยะห่างเฉลี่ยกำลังสอง” ระหว่างค่าจริง y_i กับค่าที่ตัวแบบทำนาย \hat{y}_i เนื่องจากมีการ “ยกกำลังสอง” ของความคลาดเคลื่อน ทำให้ MSE มีความไวต่อค่าผิดปกติ (outlier) มากกว่าเมตริกอื่น เช่น MAE (Mean Absolute Error) ดังนั้นจึงเหมาะสำหรับใช้ตรวจสอบว่ามีการทำนายที่ผิดมากหรือน้อยเพียงใดในภาพรวมของตัวแบบ (Chai and Draxler, 2014)

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

โดยที่

n คือ จำนวนข้อมูลทั้งหมด

y_i คือ ค่าจริง (Actual value)

\hat{y}_i คือ ค่าที่ตัวแบบทำนาย (Predicted value)

2.4.2.3 ค่ารากที่สองของความคลาดเคลื่อนกำลังสองเฉลี่ย

ค่ารากที่สองของความคลาดเคลื่อนกำลังสองเฉลี่ย Root Mean Squared Error (RMSE) ถูกใช้ในงาน Regression และ Forecasting อย่างกว้างขวาง โดยเฉพาะในสถิติประยุกต์ (Chai and Draxler, 2014) เป็นการวัดความคลาดเคลื่อนที่เน้น “ความผิดพลาดขนาดใหญ่” เพราะมีการยกกำลังสอง เหมาะสำหรับตรวจสอบว่ามีค่าผิดปกติ (outlier) หรือค่าทำนายที่ผิดมากน้อยแค่ไหน

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

โดยที่

y_i คือ ค่าจริง (Observed value)

\hat{y}_i คือ ค่าที่ตัวแบบพยากรณ์ได้ (Predicted value)

n คือ จำนวนข้อมูลทั้งหมด

2.4.2.4 ค่าสัมประสิทธิ์แสดงการตัดสินใจ

ค่าสัมประสิทธิ์แสดงการตัดสินใจ Coefficient of Determination (R^2) ถูกเสนอโดย Karl Pearson, (1909) และต่อมาพัฒนาโดยนักสถิติหลายคน เช่น Wright, (1921) ใช้วัดว่าสัดส่วนความแปรปรวนของข้อมูลจริงสามารถอธิบายได้ด้วยตัวแบบมากน้อยเพียงใด ค่า R^2 ใกล้ 1 หมายถึงตัวแบบอธิบายข้อมูลได้ดี

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

โดยที่

y_i คือ ค่าจริง (Observed value)

\hat{y}_i คือค่าที่ตัวแบบพยากรณ์ได้ (Predicted value)

\bar{y} คือ ค่าเฉลี่ยของค่าจริงทั้งหมด

n คือ จำนวนข้อมูลทั้งหมด

2.4.2.5 ค่าเฉลี่ยของเปอร์เซ็นต์ความผิดพลาดสัมบูรณ์

ค่าเฉลี่ยของเปอร์เซ็นต์ความผิดพลาดสัมบูรณ์ Mean Absolute Percentage Error (MAPE) นิยมใช้ในงานพยากรณ์ด้านเศรษฐศาสตร์และวิศวกรรม (Armstrong, 1985) ใช้วัดความคลาดเคลื่อนในรูปแบบร้อยละ (% error) ทำให้เข้าใจง่าย เช่น MAPE = 5% หมายถึงโดยเฉลี่ยตัวแบบพยากรณ์คลาดเคลื่อน 5% ของค่าจริง

$$MAPE = \frac{100}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right|$$

โดยที่

y_i คือ ค่าจริง (Observed value)

\hat{y}_i คือ ค่าที่ตัวแบบพยากรณ์ได้ (Predicted value)

n คือ จำนวนข้อมูลทั้งหมด

MAPE < 2% การพยากรณ์มีความคลาดเคลื่อนน้อยมาก ถือว่าแม่นยำสูงและน่าเชื่อถือ

MAPE 3% - 5% การพยากรณ์มีความแม่นยำในระดับดีและเป็นที่ยอมรับได้สำหรับการตัดสินใจส่วนใหญ่

MAPE 5% - 10% การพยากรณ์มีความคลาดเคลื่อนอยู่บ้าง

MAPE > 10% การพยากรณ์มีความคลาดเคลื่อนสูงมาก

2.4.3 การอธิบายตัวแบบ

2.4.3.1 SHAP (Shapley Additive Explanations)

Machine Learning มีศักยภาพอย่างมากในการพยากรณ์ข้อมูลอนุกรมเวลา แต่โดยทั่วไปนักวิจัยมักไม่ได้อธิบายเหตุผลเบื้องหลังการคาดการณ์ของตัวแบบ เพื่อแก้ปัญหานี้ Lundberg and Lee, (2017) ได้เสนอแนวทาง SHAP สำหรับตีความผลการทำนายของตัวแบบต่าง ๆ SHAP ช่วยให้ผู้ใช้สามารถตีความการทำนายของตัวแบบที่ซับซ้อนได้ แนวทางนี้ถูกเสนอครั้งแรกโดย Shapley ในปี 1953 และมีพื้นฐานมาจากทฤษฎีเกม วิธีนี้ทำให้เราสามารถอธิบายการทำนายของข้อมูลเฉพาะจุด ได้โดยการคำนวณอิทธิพลของแต่ละคุณลักษณะที่มีต่อการทำนายนั้น ค่า Shapley ที่ประมาณค่าได้คำนวณดังนี้

$$\phi_i(f, x) = \sum_{S \subseteq F} \frac{|S|! (M - |S| - 1)!}{M!} (f_{S \cup \{i\}}(x_{S \cup \{i\}}) - f_S(x_S)) \text{ with } i \notin S$$

โดยที่

f คือ ตัวแบบพยากรณ์ที่เรากำลังอธิบาย

x คือ จุดข้อมูลที่ต้องการอธิบายค่าทำนาย

F คือ เซตของตัวแปรทั้งหมดในตัวแบบ

M คือ จำนวนตัวแปรทั้งหมด ($M = |F|$)

i คือ ดัชนีของตัวแปรที่กำลังคำนวณค่า SHAP

$S \subseteq F \setminus \{i\}$ คือ เซตย่อยของตัวแปรที่ยังไม่รวม i

$|S|$ คือ จำนวนสมาชิกของเซต S

$\frac{|S|! (M - |S| - 1)!}{M!}$ คือ ค่าน้ำหนักแบบ *Shapley* เฉลี่ยผลส่วนเพิ่มอย่างยุติธรรมในทุกลำดับการเข้าร่วม

$f_S(x_S)$ คือ ค่าทำนายที่คาดหวังเมื่อเปิดใช้เฉพาะตัวแปรของตัวแบบเมื่อเปิดใช้เฉพาะตัวแปรใน S สำหรับค่า x_S

$f_{S \cup \{i\}}(x_{S \cup \{i\}})$ คือ ค่าทำนายที่คาดหวังเมื่อ “เพิ่มตัวแปร i ” เข้าไปในเซต S แล้วพิจารณาค่า $x_{S \cup \{i\}}$

$\phi_i(f, x)$ คือ ค่า SHAP ของตัวแปร i สำหรับกรณี x

2.5 การทำตรวจสอบแบบไขว้ (Cross Validation) สำหรับข้อมูลอนุกรมเวลา (Time Series)

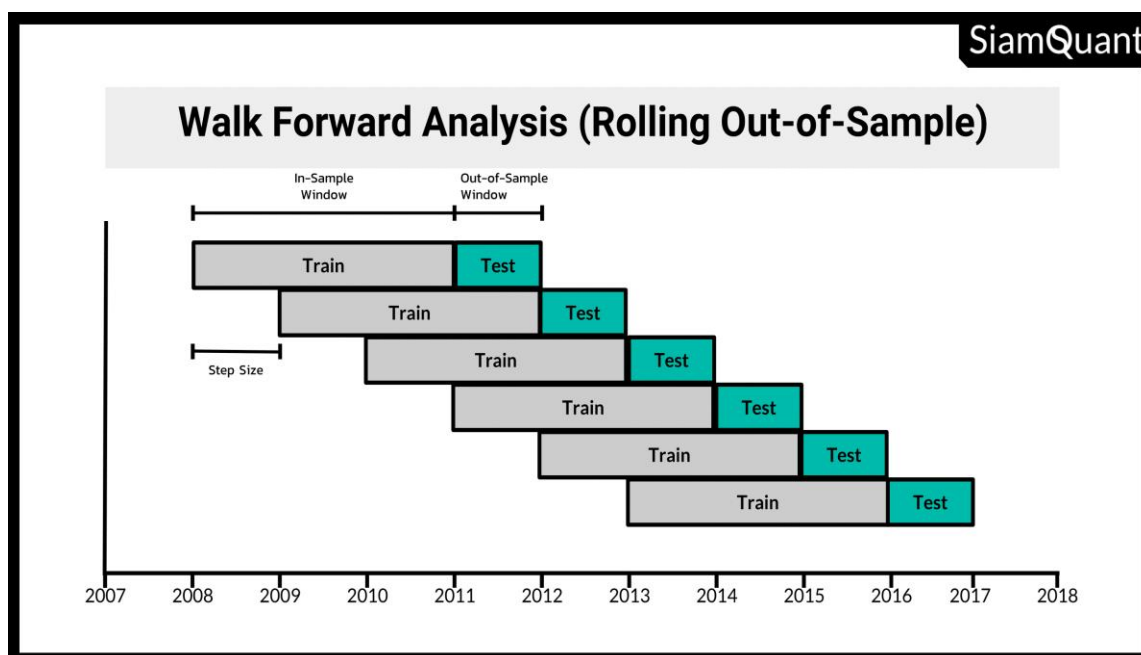
การตรวจสอบแบบไขว้ (Cross Validation) เป็นเทคนิคสำหรับประเมินความสามารถของตัวแบบในการทำนายข้อมูลใหม่ โดยการแบ่งข้อมูลออกเป็นส่วนสำหรับฝึก (Training Set) และทดสอบ (Test Set) หลายๆ แบบ และวัดค่าความผิดพลาด (error) เฉลี่ยของตัวแบบในแต่ละแบบ (dev.to, 2023) ในกรณีของ ข้อมูลอนุกรมเวลา (Time Series) การทำ Cross Validation ต้องระมัดระวังเรื่องลำดับเวลาด้วย เนื่องจากข้อมูลมีความสัมพันธ์ตามเวลา การสุ่มแบ่งข้อมูลแบบทั่วไปอาจทำให้เกิด การรั่วไหลของข้อมูลในอนาคต (Data Leakage) และทำให้การประเมินตัวแบบผิดพลาดได้ (medium.com, 2022)

โดยทั่วไป ค่าความผิดพลาดจาก Cross Validation จะคำนวณโดยเฉลี่ยจากความผิดพลาดในแต่ละรอบของการแบ่งข้อมูล ตัวอย่างเช่น หากใช้การแบ่งข้อมูลเป็น K กลุ่ม (Fold) จะได้ค่าความผิดพลาดเฉลี่ย $E_{CV} = \frac{1}{K} \sum_{i=1}^K E_i$ โดยที่ E_i คือค่าความผิดพลาดของตัวแบบเมื่อทดสอบบนชุดข้อมูลชุดที่ i ในขณะที่ตัวแบบถูกฝึกด้วยข้อมูลชุดอื่นๆ นอกเหนือจากชุดที่ i ทั้งหมด ด้านล่างนี้เป็นเทคนิคการทำ Cross Validation แบบต่าง ๆ ที่นิยม พร้อมคำอธิบายและตัวอย่างการแบ่งชุดข้อมูล Train/Test แต่ละแบบ โดยเน้นการประยุกต์ใช้กับ ข้อมูลอนุกรมเวลา เป็นหลัก

2.5.1 Walk-Forward Validation (Expanding Window)

Walk-Forward Validation เป็นวิธีการตรวจสอบตัวแบบสำหรับอนุกรมเวลาที่ รักษาลำดับเวลา อย่างเคร่งครัด โดยใช้แนวคิดการทดสอบแบบเลื่อนหน้าต่าง (Forward Chaining) แต่เพิ่มขนาดชุดฝึกตลอดเวลา (Expanding Window) ในการทำ Walk-Forward เราจะแบ่งข้อมูลออกเป็นหลาย ช่วงเวลา ตามลำดับ เช่น กำหนดช่วงเริ่มต้นสำหรับ ชุดฝึก (In-sample) และช่วงถัดไปสำหรับ ชุดทดสอบ (Out-of-sample) จากนั้นในรอบถัดไป เราจะ ขยับกรอบเวลาไปข้างหน้า โดยการนำข้อมูลช่วงทดสอบก่อนหน้า “ไปรวมเข้ากับ” ชุดฝึก (ทำให้ชุดฝึกขยายมากขึ้น) แล้วเลื่อนชุดทดสอบไปยังช่วงเวลาถัดไป ทำซ้ำเช่นนี้เรื่อย ๆ จนครอบคลุมทั้งชุดข้อมูล (lengyi.medium.com, 2022; otexts.com, 2022)

คุณสมบัติสำคัญ ของ Walk-Forward คือ แต่ละรอบการทดสอบ ตัวแบบจะถูกฝึกด้วย ข้อมูลที่เกิดขึ้นก่อนหน้าเท่านั้น ไม่มีการใช้ข้อมูลในอนาคตของช่วงที่ทดสอบมาฝึกตัวแบบ ดังนั้นจึงไม่เกิดการรั่วไหลของข้อมูลเวลา (Temporal Leakage) วิธีนี้จำลองสถานการณ์จริงที่เมื่อเวลาผ่านไป เรามีข้อมูลเพิ่มขึ้นและสามารถอัปเดตตัวแบบได้ต่อเนื่อง



ภาพที่ 2 Walk Forward Analysis (Rolling Out-of-Sample)

ภาพ กราฟ Walk Forward Analysis (Rolling Out-of-Sample) (SiamQuant, n.d.) แสดงไทม์ไลน์ที่แกนนอนเป็นปี และซ้อนทับด้วยแถบสีเหลี่ยมหลายชั้นซึ่งแต่ละชั้นคือ รอบการประเมินหนึ่งครั้ง ส่วนสีเทาในแต่ละชั้นคือช่วง Train (In-Sample Window) ที่ใช้ข้อมูลอดีตเพื่อเทรนและจูนตัวแบบ ส่วนสีเขียวถัดท้ายคือช่วง Test (Out-of-Sample Window) ที่เป็นข้อมูลอนาคตจริงของรอบนั้นสำหรับวัดผล เมื่อจบรอบหนึ่งหน้าต่างทั้งหมดจะเลื่อนไปข้างหน้า ตาม Step Size แล้วทำซ้ำหลายรอบ ทำให้เราได้ชุดผลทดสอบนอกตัวอย่างต่อเนื่องตลอดแกนเวลาภาพนี้ยังสื่อว่า Train มีลักษณะขยายสะสม (expanding window) เพราะความยาว Train ในแต่ละรอบยาวขึ้นเรื่อย ๆ ก่อนจบด้วย Test ขนาดเท่าเดิม ส่งผลให้การประเมินสะท้อนการใช้งานจริงมากกว่า split เดียว ตัวแบบถูกฝึกด้วยข้อมูลที่มีอยู่ ณ ขณะนั้น แล้วจึงทดสอบกับอนาคตถัดไปจริง ๆ หลายครั้ง ช่วยลด look-ahead bias และตรวจความ เสถียรของสมรรถนะ เช่น RMSE MAE R^2 MAPE ข้ามสภาวะตลาดที่เปลี่ยนไปตามช่วงเวลา

การประเมินตัวแบบจะทำโดยนำ ค่าผิดพลาดจากการพยากรณ์หลายช่วงเวลา นี้มาเฉลี่ยรวมกัน (เช่น ค่าเฉลี่ย MSE หรือ MAE ของการทำนายในแต่ละช่วง) เพื่อดูภาพรวมว่าตัวแบบจะทำนายอนาคตได้ดีเพียงใดเมื่อเวลาผ่านไป นอกจากนี้ เราสามารถ ปรับวิธี Walk-Forward สำหรับการพยากรณ์ระยะยาวได้ เช่น ทดสอบทีละหลายก้าว (multi-step) ด้วยการเว้นระยะชุดทดสอบ ให้ครอบคลุมหลายจุด แล้วเลื่อน origin ไปตามลำดับ

ข้อดี Walk-Forward ใช้ข้อมูลฝึกเพิ่มขึ้นเรื่อยๆ ทำให้ตัวแบบได้เรียนรู้จากประวัติย้อนหลังมากขึ้น และการทดสอบแต่ละครั้งก็สะท้อนสถานการณ์ทำนายอนาคตจริงๆ จึงถือว่าเป็นมาตรฐานทองคำในการประเมินตัวแบบอนุกรมเวลา (machinelearningmastery.com, 2021: medium.com, 2022)

ข้อควรระวัง วิธีนี้ต้องฝึกตัวแบบหลายรอบตามจำนวนการเลื่อน จึงใช้เวลาคำนวณมากขึ้น และช่วงแรกๆ ที่ข้อมูลยังน้อย ตัวแบบอาจยังแม่นยำไม่ดี

2.6 ค่าสังเกตย้อนหลัง (Lag Feature)

ค่าสังเกตย้อนหลัง (Lag Feature) คือเทคนิคการสร้างตัวแปรใหม่จากค่าของข้อมูลในอดีต เพื่อใช้ทำนายค่าปัจจุบันหรืออนาคต เช่น การนำค่าราคาทองคำของวันก่อนหน้าหรือหลายวันก่อนหน้ามาเป็นข้อมูลอธิบายสำหรับทำนายราคาทองคำในวันถัดไป หลักการนี้สอดคล้องกับแนวคิดของแบบจำลองอัตถิภาวะ (Autoregressive Models) ซึ่งเชื่อว่าค่าปัจจุบันของอนุกรมเวลาขึ้นอยู่กับค่าในอดีต (Hyndman & Athanasopoulos, 2021) ในทางปฏิบัติ การสร้างตัวแปรล่าช้ามักทำร่วมกับการคำนวณ สถิติเคลื่อนที่ (Rolling Statistics) เช่น ค่าเฉลี่ยเคลื่อนที่ (Moving Average) หรือส่วนเบี่ยงเบนมาตรฐานเคลื่อนที่ (Rolling Standard Deviation) เพื่อสรุปแนวโน้มและความผันผวนในช่วงระยะเวลาสั้น ๆ ซึ่งช่วยให้โมเดลเรียนรู้รูปแบบการเคลื่อนไหวของข้อมูลได้อย่างมีประสิทธิภาพ (Andersen et al., 2003)

2.6.1 ความสำคัญของ Lag Feature ในข้อมูลทางการเงิน

ข้อมูลทางการเงิน เช่น ราคาทองคำ มักมีลักษณะขึ้นอยู่กับอดีต (time dependence) และมีรูปแบบการเคลื่อนไหวที่ต่อเนื่องกัน การนำข้อมูลในอดีตมาช่วยในการทำนายจึงมีประโยชน์อย่างมาก โดยเฉพาะในประเด็นต่อไปนี้

2.6.1.1 การสะท้อนโมเมนตัมของราคา (Price Momentum)

การเปลี่ยนแปลงของราคาทองคำในอดีตมักส่งผลต่อแนวโน้มราคาในอนาคต เช่น หากราคาทองคำปรับตัวขึ้นต่อเนื่องในช่วง 5 วันล่าสุด ราคาวันถัดไปมักมีแนวโน้มเพิ่มขึ้นในทิศทางเดียวกัน การใช้ตัวแปรล่าช้าของราคา จึงช่วยให้โมเดลสามารถจับ Momentum ของตลาดได้ (Jegadeesh & Titman, 1993)

2.6.1.2 การคงอยู่ของความผันผวน (Volatility Clustering)

ตลาดการเงินมักมีช่วงที่ความผันผวนสูงต่อเนื่องกัน เช่น ช่วงที่ราคาทองคำผันผวนแรงในวันหนึ่ง มักมีแนวโน้มผันผวนในวันถัดไปด้วย ดังนั้นการสร้างตัวแปรล่าช้าจากค่าความผันผวน เช่น ค่าความผันผวนที่คำนวณจากสูตรของ Parkinson (1980) จะช่วยให้โมเดลเข้าใจลักษณะของความไม่แน่นอนในตลาดได้ดีขึ้น (Andersen et al., 2003)

2.6.1.3 ปริมาณการซื้อขายและแรงตลาด (Volume Effect)

การเปลี่ยนแปลงของปริมาณการซื้อขาย (Volume) มักสัมพันธ์กับความรุนแรงของการเคลื่อนไหวของราคา ตัวอย่างเช่น ช่วงที่มี Volume สูงมักเป็นช่วงที่ตลาดตอบสนองต่อข่าวสำคัญ การสร้างตัวแปรล่าช้าของ Volume หรือการเปลี่ยนแปลงของ Volume ช่วยให้โมเดลจับพฤติกรรมของแรงซื้อแรงขายได้อย่างแม่นยำ (Karpoff, 1987; Campbell et al., 1993)

บทที่ 3

ระเบียบวิธีวิจัย

3.1 แบบแผนการวิจัย

การวิจัยนี้เป็น การวิจัยและพัฒนา (Research and Development) ที่ใช้กรอบการวิจัยเชิงปริมาณ (Quantitative) โดยมีลักษณะเป็นการวิเคราะห์อนุกรมเวลาแบบย้อนหลัง (Retrospective Time Series Analysis) มุ่งเน้นการสร้างแบบจำลองเพื่อการพยากรณ์ (Predictive Modeling) สำหรับคาดการณ์ราคาทองคำต่ำสุด, สูงสุด และราคาปิดรายวัน ล่วงหน้า 1 วัน ท้ายที่สุดผลลัพธ์จากตัวแบบจำลองที่แม่นยำที่สุดจะถูกนำไปพัฒนาต่อยอดเป็นเว็บแอปพลิเคชัน เพื่อให้ผู้ใช้งานสามารถเข้าถึงผลการทำนายได้

3.2 แหล่งข้อมูลและช่วงเวลาศึกษา

3.2.1 ข้อมูลราคาสินทรัพย์และดัชนีการเงิน (Daily) จาก Yahoo Finance

ราคาทองคำตอนเปิดตลาด (Gold Open Price, USD/Oz)

ราคาทองคำสูงสุดของวัน (Gold High Price, USD/Oz)

ราคาทองคำต่ำสุดของวัน (Gold Low Price, USD/Oz)

ราคาทองคำตอนปิดตลาด (Gold Close Price, USD/Oz)

ปริมาณการซื้อขายทองคำ (Gold Volume, Volume Units) ราคาเงิน (Silver Price, USD/Oz)

ราคาน้ำมันดิบ (Crude Oil Price, USD/Barrel)

ดัชนี S&P 500 (Index Points)

อัตราผลตอบแทนพันธบัตรรัฐบาลสหรัฐฯ อายุ 10 ปี (US 10Y Treasury Yield, % p.a.)

ดัชนีดอลลาร์สหรัฐฯ (US Dollar Index, Index Points)

3.2.2 ข้อมูลเศรษฐกิจมหภาค จาก FRED

อัตราเงินเฟ้อ (CPI ใช้ระดับดัชนี/หรือ YoY)

ช่วงเวลาศึกษา ย้อนหลังประมาณ 10 ปี นับถึงวันปัจจุบัน เพื่อให้ครอบคลุมวัฏจักรเศรษฐกิจและสภาพตลาดที่หลากหลาย

3.3 การเข้าถึงข้อมูลและการสมัคร API

3.3.1 Yahoo Finance ผ่าน yfinance

3.3.1.1 ไม่ต้องสมัคร API โหลดฟรี yfinance สำหรับดึงข้อมูลตลาดการเงินจาก Yahoo Finance โดยตรง

3.3.1.2 ข้อควรทราบเรื่องสัญลักษณ์ (Ticker)

ราคาทองคำเปิด (Gold Open): XAUUSD=X

ราคาทองคำสูงสุด (Gold High): XAUUSD=X

ราคาทองคำต่ำสุด (Gold Low): XAUUSD=X

ราคาทองคำปิด (Gold Close): XAUUSD=X

ปริมาณการซื้อขายทองคำ (Gold Volume): GC=F

ราคาแร่เงิน: SI=F

ราคาน้ำมันดิบ WTI: CL=F

ดัชนี S&P 500: ^GSPC

ราคาแร่เหล็ก: TIO=F

10Y Treasury Yield Index: ^TNX

ดัชนีดอลลาร์สหรัฐ (ICE Dollar Index): DX-Y.NYB

3.3.2 FRED (กรณีใช้ข้อมูลเศรษฐกิจมหภาครายเดือน/รายไตรมาส)

3.3.2.1 ต้องสมัครคีย์ API ลงทะเบียนรับ API Key จาก FRED

3.3.2.2 การใช้งาน ติดตั้ง fredapi แล้วตั้งค่าคีย์เป็นตัวแปรแวดล้อม

3.3.2.3 การจัดความถี่เวลา ข้อมูลอย่าง CPI เผยแพร่รายเดือน เมื่อนำมาใช้กับข้อมูลรายวัน ให้ carry forward (ffill) ค่าล่าสุดของเดือนนั้นเพื่อให้สอดคล้องกับเฟรมเวลาแบบรายวัน

3.4 การสมัครใช้งาน GitHub และการจัดเก็บซอร์สโค้ดด้วย VS Code

3.4.1 การสมัครบัญชี GitHub

3.4.1.1 เข้าเว็บไซต์ github.com เลือก Sign up

3.4.1.2 กรอกอีเมล รหัสผ่าน และกำหนด Username

3.4.1.3 ยืนยันอีเมลตามลิงก์ที่ได้รับ

3.4.2 การเตรียมเครื่องมือ

3.4.2.1 ติดตั้ง Git จาก git-scm.com

3.4.2.2 ติดตั้ง Visual Studio Code (VS Code) จาก code.visualstudio.com

3.4.2.3 ลงชื่อเข้าใช้ GitHub ใน VS Code

3.4.3 การตั้งค่า Git ครั้งแรกบนเครื่อง

3.4.3.1 ตั้งชื่อผู้ใช้และอีเมลที่จะปรากฏในประวัติการ Commit

3.4.3.2 `git config --global user.name "Your Name"`

3.4.3.3 `git config --global user.email "your_email@example.com"`

3.4.4 การสร้างที่เก็บซอร์สโค้ด (Repository)

3.4.4.1 สร้าง Repository บน GitHub ก่อน แล้วค่อย Clone มาที่ VS Code

3.4.4.1.1 ที่ GitHub คลิก New repository → ตั้งชื่อ เช่น gold-forecasting

3.4.4.1.2 เลือก Private/Public, เพิ่ม README.md, ตั้ง .gitignore = Python → Create

3.4.4.1.3 ใน VS Code Clone Repository → เลือกรีโปฯ ที่เพิ่งสร้าง → เลือกโฟลเดอร์ปลายทางบนเครื่อง

3.4.4.1.4 คัดลอกไฟล์โครงการ เช่น gold_data_fetch.py, requirements.txt, eda.ipynb เข้าโฟลเดอร์ที่ Clone มา → ใช้ Source Control ทำ Stage → Commit → Push

3.4.4.2 มีโค้ดอยู่บนเครื่องแล้วและต้องการ “Publish to GitHub” จาก VS Code

3.4.4.2.1 เปิดโฟลเดอร์โครงการใน VS Code (File > Open Folder...)

3.4.4.2.2 ไปที่แถบ Source Control → คลิก Initialize Repository

3.4.4.2.3 เพิ่มไฟล์ .gitignore และ README.md

3.4.4.2.4 Stage ไฟล์ทั้งหมด → พิมพ์ข้อความ Commit

3.4.4.2.5 คลิกปุ่ม Publish to GitHub → เลือกชื่อรีโปฯ และสถานะ Private/Public → VS Code จะสร้างรีโปฯ บน GitHub และ Push ให้โดยอัตโนมัติ

3.4.5 ทางเลือกด้วยบรรทัดคำสั่ง

```
git init
git add .
git commit -m "chore: initial commit"
git branch -M main
git remote add origin git@github.com:USERNAME/REPO.git # หรือ HTTPS ตามสะดวก
git push -u origin main
```

3.4.6 การทำงานประจำวัน (Workflow พื้นฐานบน Branch หลัก)

เป็นขั้นตอนที่ทำเป็นประจำทุกวันเพื่ออัปเดตและบันทึกงานของตัวเอง

- 3.4.6.1 เริ่มต้นการทำงาน ดึงข้อมูลล่าสุดจาก Server เพื่อให้แน่ใจว่าโค้ดของเราเป็นเวอร์ชันล่าสุดเสมอ และป้องกันปัญหา โค้ดขัดแย้งกัน (Conflict) กับเพื่อนร่วมทีม

```
git pull
```

- 3.4.6.2 แก้ไขงานและบันทึกการเปลี่ยนแปลง เป็นวงจรการทำงานระหว่างวัน ประกอบด้วย 3 ขั้นตอนย่อย

3.4.6.2.1 แก้ไขไฟล์ ทำงานตามปกติในโปรแกรม VS Code

3.4.6.2.2 เลือกไฟล์ที่จะบันทึกในหน้า Source Control ของ VS Code เลือกเฉพาะไฟล์ที่แก้ไขเสร็จสมบูรณ์และพร้อมที่จะบันทึกเป็นเวอร์ชันใหม่

3.4.6.2.3 ยืนยันการบันทึก (Commit) บันทึกการเปลี่ยนแปลงลงในประวัติของโปรเจกต์ พร้อมใส่ข้อความที่สื่อความหมายชัดเจน (Commit Message) เพื่อให้ย้อนกลับมาดูได้ว่าการเปลี่ยนแปลงครั้งนี้เกี่ยวกับอะไร

- 3.4.6.3 ส่งการเปลี่ยนแปลงขึ้นไปยัง Server เมื่อทำงานเสร็จสิ้นในแต่ละส่วน หรือเมื่อสิ้นสัปดาห์ ควรส่งงานที่ Commit ไว้ทั้งหมดขึ้นไปเก็บที่ Server

```
git push
```

3.5 การเตรียมสภาพแวดล้อมและเครื่องมือ

3.5.1 ภาษา python แนะนำ version \geq python 3.11

3.5.2 ไลบรารีหลัก yfinance, pandas, numpy, fredapi

3.5.3 การติดตั้ง

3.5.3.1 สร้าง virtual environment

macOS/Linux python3 -m venv .venv andand source .venv/bin/activate

Windows py -m venv .venv andand .venv\Scripts\activate

3.5.3.2 ติดตั้งแพ็คเกจ pip install yfinance pandas numpy

3.5.3.3 บันทึกเวอร์ชัน pip freeze > requirements.txt

3.5.3.4 การควบคุมเวอร์ชัน ใช้ GitHub เก็บสคริปต์และ

3.6 การออกแบบตัวแปรและช่วงเวลา

- 3.6.1 กรอบเวลา 10 ปีย้อนหลัง เพื่อครอบคลุมวัฏจักรเศรษฐกิจหลายช่วง
- 3.6.2 ตัวแปรตาม ราคาทองคำ (Gold_Price_USD)
- 3.6.3 ตัวแปรอิสระ Silver, Crude Oil, S&P 500, 10Y Yield, Dollar Index , Iron
- 3.6.4 เหตุผลของการใช้ ราคาปิด (Close) คือ เป็นค่ามาตรฐานสำหรับเปรียบเทียบข้ามสินทรัพย์และข้ามวัน (daily bar) สะท้อนภาวะตลาด ณ เวลาที่สิ้นสุดวันซื้อขาย

3.7 ขั้นตอนการพัฒนาโปรแกรมดึงข้อมูล (อธิบายทีละส่วน)

- 3.7.1 นำเข้าไลบรารี yfinance สำหรับดาวน์โหลดข้อมูล, pandas สำหรับจัดการตาราง, datetime สำหรับกำหนดกรอบเวลา

```
import yfinance as yf

import pandas as pd

from datetime import datetime, timedelta
```

- 3.7.2 กำหนดกรอบเวลา start_date = วันนี้ - 3650 วัน: end_date = วันนี้

```
end_date = datetime.today()

start_date = end_date - timedelta(days=3650)
```

3.7.3 ออกแบบ symbols ใช้ dict เพื่อผูก ชื่อตัวแปร (คีย์) เข้ากับ Ticker จริง (ค่า) ทำให้อ่านง่ายและแก้ไขได้กลางที่เดียว

```
symbols = {

    'Gold_Open_Price': 'XAUUSD=X ',

    'Gold_High_Price': 'XAUUSD=X ',

    'Gold_Low_Price': 'XAUUSD=X ',

    'Gold_Close_Price': 'XAUUSD=X ',

    'Gold_Volume': 'GC=F',

    'Silver_Price_USD': 'SI=F',

    'Crude_Oil_Price': 'CL=F',

    'SP500_Index': '^GSPC',

    'US_10Y_Treasury_Yield': '^TNX',

    'US_Dollar_Index_DXY': 'DX-Y.NYB',

    'Iron_Ore_Price': 'TIO=F'

}
```

3.7.4 ฟังก์ชัน fetch_data

3.7.4.1 วนทีละสัญลักษณ์ → yf.download() → เลือกคอลัมน์ Close → rename เป็นชื่อตัวแปร เช่น Gold_Price_USD

3.7.4.2 เก็บลง data[name] เพื่อรวมภายหลัง

3.7.4.3 มี try/except สำหรับบันทึกข้อผิดพลาด

```
def fetch_data(symbols, start, end):

    data = {}

    print("Starting data fetch...")

    for name, ticker in symbols.items():

        print(f"Fetching: {name} ({ticker})")

        try:

            df = yf.download(ticker, start=start, end=end, progress=False)

            if not df.empty:

                df = df[['Close']].rename(columns={'Close': name})

                data[name] = df

            else:

                print(f" Warning: No data returned for {name} ({ticker})")

        except Exception as e:

            print(f" Error fetching {name} ({ticker}): {e}")

    return data

raw_data_dict = fetch_data(symbols, start_date, end_date)
```

3.7.5 รวมตาราง `pd.concat(raw_data_dict.values(), axis=1)` รวมทุกตัวแปรด้วยแกนเวลา (index วันที่ร่วมกัน)

```
df = pd.concat(raw_data_dict.values(), axis=1)
```

3.7.6 จัดการค่าว่าง `ffill()` เติมด้วยค่าก่อนหน้า เหมาะกับข้อมูลที่เผยแพร่ไม่พร้อมกัน/ต่างความถี่

```
df.ffill(inplace=True)
```

3.7.7 ย้าย Date มาเป็นคอลัมน์ `reset_index()` เพื่อให้ส่งออก CSV ได้ง่าย

```
df.reset_index(inplace=True)

df.rename(columns={'index': 'Date'}, inplace=True)
```

3.7.8 บันทึกผล to_csv

```
df.to_csv("file name", index=False)
```

3.8 การเตรียมข้อมูล (Data Preprocessing)

การเตรียมข้อมูลเป็นขั้นตอนสำคัญเพื่อให้ข้อมูลพร้อมสำหรับการนำไปสร้างตัวแบบ ประกอบด้วย

3.8.1 การดึงข้อมูลอัตโนมัติ

3.8.1.1 ใช้ภาษา Python ในการเขียนสคริปต์ (gold.py และ gold_data_fetch.py) เพื่อดึงข้อมูลจาก Yahoo Finance และ FRED โดยใช้ไลบรารี yfinance และ fredapi

3.8.1.2 ตั้งค่าการรันสคริปต์อัตโนมัติผ่าน GitHub Actions เพื่ออัปเดตข้อมูลใหม่ทุกวัน

ตัวอย่าง Code การตั้งค่ารันสคริปต์อัตโนมัติผ่าน GitHub Actions โดยใช้ภาษา yaml

```
name: Daily Data Update

on:

  schedule:

    - cron: '0 * * * *'

  workflow_dispatch:

jobs:

  update-data-file:

    runs-on: ubuntu-latest

    steps:

      - name: Checkout repository

        uses: actions/checkout@v4

      - name: Set up Python

        uses: actions/setup-python@v4

        with:

          python-version: '3.11'

      - name: Install dependencies

        run: pip install -r requirements.txt

      - name: Run data fetching script

        run: python gold_data_fetch.py

      - name: Commit and push changes

        env:

          GITHUB_TOKEN: ${ secrets.GITHUB_TOKEN }

        run: |

          git config --global user.name "github-actions[bot]"

          git config --global user.email "github-actions[bot]@users.noreply.github.com"

          git add gold_and_macro_data_final.csv

          git diff-index --quiet HEAD || git commit -m "Automated daily data update"

          git push https://x-access-token:${GITHUB_TOKEN}@github.com/${ github.repository }.git HEAD:${ github.ref_name }
```

3.8.2 การรวมข้อมูล (Data Merging)

3.8.2.1 รวมข้อมูลจากหลายแหล่งโดยใช้คอลัมน์วันที่ (Date) เป็น Index

3.8.2.2 ใช้วิธี Forward Fill (ffill) เติมค่าที่หายไปจากข้อมูลของวันก่อนหน้าเพื่อป้องกันช่องว่างของข้อมูล

3.8.3 การทำความสะอาดข้อมูล (Data Cleaning)

3.8.3.1 ลบข้อมูลที่เป็น Missing Values หลังจากรวมข้อมูล

3.8.3.2 จัดเรียงข้อมูลตามลำดับเวลาและปรับรูปแบบวันที่ให้อยู่ในมาตรฐาน YYYY-MM-DD

3.8.4 การสำรวจข้อมูลเบื้องต้น (Exploratory Data Analysis: EDA)

3.8.4.1 คำนวณค่าสถิติเชิงพรรณนา เช่น ค่าเฉลี่ย ค่ามัธยฐาน ค่าสูงสุด ค่าต่ำสุด ส่วนเบี่ยงเบนมาตรฐาน เพื่อทำความเข้าใจลักษณะของข้อมูล

3.8.4.2 วิเคราะห์ความสัมพันธ์ระหว่างตัวแปรด้วย Correlation Matrix เพื่อตรวจสอบความสัมพันธ์เชิงเส้น

3.9 การเตรียมข้อมูลก่อนทำตัวแบบและการคัดเลือกตัวแปรที่เหมาะสมสำหรับแต่ละตัวแบบ

3.9.1 หลักเกณฑ์รวม (Pre-screening)

3.9.1.1 เติมค่าที่หายไปด้วย ffill และลบแถวที่ยังคง Missing หลังรวมข้อมูล

3.9.1.2 ตัดคุณลักษณะที่มีความแปรปรวนต่ำมาก (near-zero variance)

3.9.1.3 จำกัดความซ้ำซ้อนเบื้องต้นด้วยเกณฑ์สหสัมพันธ์ หากตัวแปรสองตัวมี $|p| > 0.95$ ให้เก็บเพียงตัวที่สัมพันธ์กับเป้าหมายสูงกว่า

3.9.2 สำหรับแบบจำลองเชิงเส้น Linear Regression

3.9.2.1 มาตรฐานข้อมูลด้วย StandardScaler (เฉพาะตัวแปรอิสระ) เพื่อให้สเกลสอดคล้องกัน

3.9.2.2 ตรวจสอบ multicollinearity ด้วย VIF และตัดตัวแปรที่ $VIF > 10$ ออกแบบ iterative

3.9.2.3 ใช้ RFE (Recursive Feature Elimination) ร่วมกับ TimeSeriesSplit เพื่อเลือกชุดตัวแปรที่ให้ RMSE/MAE ต่ำที่สุดบนชุด Validation

3.9.3 สำหรับแบบจำลอง Tree-Base Model

3.9.3.1 ตัวแบบรับมือความสัมพันธ์ระหว่างตัวแปรได้ดี ไม่จำเป็นต้องตัดความสัมพันธ์ทั้งหมด แต่ลดตัวแปรซ้ำซ้อนเพื่อให้ตัวแบบทำงานได้เร็วขึ้น

3.9.4 สำหรับแบบจำลอง LSTM

3.9.4.1 แปลงข้อมูลเป็นลำดับความยาวหน้าต่าง (window) เช่น 30 วัน และมาตรฐานข้อมูลด้วย MinMax/StandardScaler ที่ fit บน Train เท่านั้น

3.9.4.2 เพื่อลด overfitting ให้ใช้ชุดตัวแปร เช่น Close, High_Low_Range, log_return_Close, Volume_zscore, และ macro หลักเพียง 2-3 ตัว เช่น DXY, Yield10Y, Oil พร้อม lag

3.10 การสร้างคุณลักษณะ Lag

สร้างคุณลักษณะชนิด lag (เลื่อนข้อมูลย้อนหลัง) โดยใช้ฟังก์ชัน `make_lag_features` ซึ่งจะสร้างข้อมูลย้อนหลังของตัวแปรเชิงตัวเลขทั้งหมด ตัวอย่างเช่น การสร้าง lag 1 วันของข้อมูลทั้งหมด ผลที่ได้คือจะมีคอลัมน์ใหม่ที่ชื่อว่า `<feature>_lag1` สำหรับแต่ละตัวแปรในชุดข้อมูล ซึ่งเป็นข้อมูลของวันก่อนหน้า ในขั้นตอนนี้ เราสามารถใช้คุณลักษณะ lag เหล่านี้เพื่อช่วยพยากรณ์ราคาเป้าหมายในวันถัดไปได้ โดยเรา จะสร้างจำนวน lag ให้เหมาะสมสำหรับแต่ละตัวแบบ เปรียบเทียบ lag หลายๆ ตัว เช่น lag 1 3 5 7 9 เพื่อเปรียบเทียบว่าแบบไหนให้ผลที่ดีที่สุด

3.11 การกำหนดตัวแปรเป้าหมาย

กำหนดตัวแปรเป้าหมาย (target variable) สำหรับการพยากรณ์ วันถัดไป ($t+1$) โดยสร้างคอลัมน์ใหม่ที่เลื่อนไประยะเวลา 1 วันล่วงหน้า (shift -1) สำหรับราคาทองคำ Close/High/Low ดังนี้

```
targets = ["Gold_Close", "Gold_High", "Gold_Low"]

for target in targets:

    df[target + "_t+1"] = df[target].shift(-1)

df = df.dropna(subset=[t + "_t+1" for t in targets])
```

3.12 การจัดการข้อมูลสูญหาย

หลังจากสร้างค่าเลื่อนข้อมูลแล้ว จะมีแถวบางส่วนที่เกิดค่าว่างเนื่องจากการ shift จึงต้องลบแถวที่มีค่า NaN ทั้ง จากนั้นเลือกเฉพาะคอลัมน์คุณลักษณะที่ต้องการใช้ ในที่นี้คือคอลัมน์ที่ลงท้ายด้วย `_lag1` ซึ่งรวมถึง lag ของเป้าหมายด้วย และจัดเตรียมข้อมูลสำหรับขั้นตอนถัดไป เช่น การ split ข้อมูล

```
df = df.dropna().reset_index(drop=True)

feature_cols = [c for c in df.columns if c.endswith("_lag1")]

X = df[feature_cols].copy()

y = df[target + "_t+1"].astype(float).copy()
```

หลังจากทำเช่นนี้แล้ว ตัวแปร X จะประกอบด้วยชุดของคุณลักษณะ lag ทั้งหมด และ y จะเป็นคอลัมน์ราคาทองคำของวันถัดไป พร้อมสำหรับการแบ่งชุดข้อมูลต่อไป

3.13 การแบ่งชุดข้อมูล (Train/Validation/Test)

แบ่งข้อมูลตามลำดับเวลาเป็นชุดฝึก (train), ชุดปรับจูนพารามิเตอร์ (validation) และชุดทดสอบ (test) ตามสัดส่วนที่กำหนด โดยใช้ฟังก์ชัน `time_based_split` เพื่อคืนตำแหน่ง index ของช่วงแบ่ง เช่น ถ้าใช้สัดส่วน train 70%, val 15%, test 15% จะได้ตำแหน่งจุดสิ้นสุดของชุด train และ val จากนั้นแบ่งข้อมูลดังนี้

```
n = len(df)
train_end, val_end = time_based_split(n, args.train_ratio, args.val_ratio)
X_train, y_train = X.iloc[:train_end], y.iloc[:train_end]
X_val, y_val = X.iloc[train_end:val_end], y.iloc[train_end:val_end]
X_test, y_test = X.iloc[val_end:], y.iloc[val_end:]
dates_test = dates.iloc[val_end:]
```

การแบ่งข้อมูลแบบนี้เหมาะสำหรับงานพยากรณ์เชิงอนุกรมเวลาและป้องกันการรั่วไหลของข้อมูล (data leakage)

3.14 การฝึกและปรับแต่งตัวแบบ (Training and Hyperparameter Tuning)

3.14.1 ระเบียบวิธีวิจัยภาพรวม (Walk-Forward + Grid Search)

3.14.1.1 ชั้นใน (Inner Tuning) ทำ GridSearch ด้วย TimeSeriesSplit บนช่วง Train 70% เพื่อหาพารามิเตอร์ที่ดีที่สุด

3.14.1.2 คงพารามิเตอร์ที่ดีที่สุด แล้ว refit บน Train+Val (85%)

3.14.1.3 ชั้นนอก (Outer Walk-Forward บน Test 15%) เดินหน้าแบบ one-step-ahead

3.14.3 พารามิเตอร์ Grid Search ตามตัวแบบ

3.14.2.1 XGBoost (XGBRegressor)

```
n_estimators: [300, 600, 1000]
learning_rate: [0.05, 0.1, 0.2]
max_depth: [3, 5, 7]
min_child_weight: [1, 3, 5]
subsample: [0.6, 0.8, 1.0]
colsample_bytree: [0.6, 0.8, 1.0]
gamma: [0, 0.1, 0.5]
reg_alpha: [0, 0.1, 1.0]
reg_lambda: [1, 5, 10]
```

Early stopping: ใช้ `early_stopping_rounds≈100` กับชุด `fold-val` ของ `TimeSeriesSplit`

3.14.2.2 LightGBM (LGBMRegressor)

`n_estimators`: [300, 600, 1000]
`learning_rate`: [0.05, 0.1, 0.2]
`num_leaves`: [31, 63, 127]
`max_depth`: [-1, 5, 7, 9]
`min_data_in_leaf` (หรือ `min_child_samples`): [20, 50, 100]
`feature_fraction`: [0.6, 0.8, 1.0]
`bagging_fraction`: [0.6, 0.8, 1.0]
`bagging_freq`: [0, 1, 5]
`lambda_l1`: [0, 0.1, 1.0]
`lambda_l2`: [0, 0.1, 1.0]
`min_split_gain`: [0, 0.1]
Early stopping: `early_stopping_rounds≈100`

3.14.2.3 CatBoost (CatBoostRegressor, `loss_function='RMSE'`)

`iterations`: [500, 1000, 1500]
`learning_rate`: [0.03, 0.06, 0.1]
`depth`: [4, 6, 8]
`l2_leaf_reg`: [1, 3, 5, 7]
`subsample`: [0.6, 0.8, 1.0]
`rsm (colsample)`: [0.6, 0.8, 1.0]
`bootstrap_type`: ['Bayesian', 'Bernoulli']
(ตัวเลือก) `grow_policy`: ['SymmetricTree']
Early stopping: `early_stopping_rounds≈100`

3.14.2.4 LSTM (Keras/TensorFlow)

`n_layers`: [1, 2]
`units_per_layer`: [32, 64, 128]
`dropout`: [0.2, 0.3, 0.5]
`learning_rate (Adam)`: [1e-4, 3e-4, 1e-3]
`batch_size`: [16, 32, 64]

epochs_max: [150, 300] (ใช้ EarlyStopping patience≈20

3.15 การประเมินตัวแบบด้วย Walk-Forward Validation

ประเมินความแม่นยำแบบใช้งานจริง โดยเลื่อนเวลาไปข้างหน้าทีละก้าว และทำนายอนาคตหนึ่งวันล่วงหน้าโดยไม่ให้ตัวแบบเห็นอนาคต

3.15.1 กำหนดจุดทำนาย

เลือกจุดเวลาแรกของช่วง Test เป็น t_{startt_start} และวนลูปไปจนถึงจุดสุดท้าย $t_{endtt_endtt_end}$

3.15.2 กำหนดหน้าต่างฝึกสำหรับก้าวนั้น

สร้าง หน้าต่างฝึก = ข้อมูลตั้งแต่ต้นชุดข้อมูลจนถึง $t-1$

3.15.3 สร้างและอัปเดตตัวแปร

ทำการเตรียมข้อมูลด้วยวิธีเดิมทั้งหมดเหมือนที่ทำในขั้นตอนการฝึกตัวแบบ

3.15.4 ทำนายจุดเวลา t และบันทึกผล

สร้างอินพุตของเวลา t ตามนิยามพีเจอร์ (ไม่มองอนาคต) แล้วให้ตัวแบบ ทำนายค่าของ t หรือ $t+1$ ตามการนิยามเป้าหมาย

3.15.5 เลื่อนไปยังจุดถัดไป

เพิ่ม t ทีละหนึ่งก้าว แล้วทำซ้ำขั้นตอนทั้งหมดจนจบช่วง Test ทั้งหมด

3.15.6 สรุปผลทั้งช่วง Test

รวมผลลัพธ์ค่าทำนายและค่าจริงตลอดช่วง Test คำนวณตัวชี้วัด และแสดงกราฟ ค่าจริง vs ค่าทำนาย

ทั้งหมดนี้คือกระบวนการ ประเมินแบบ Walk-Forward Validation (WFOV) ที่ออกแบบมาเพื่อวัดความแม่นยำเชิงใช้งานจริง โดยหลังจากเลือกพารามิเตอร์ที่ดีที่สุดแล้ว เราจะเดินเวลาไปข้างหน้า ทีละวัน บนช่วงทดสอบ โดยในแต่ละก้าว กำหนดหน้าต่างฝึกแบบ rolling ที่มีข้อมูล ถึง $t-1$ เท่านั้น จากนั้นทำการเตรียมข้อมูลด้วยวิธีเดิมทั้งหมดเหมือนที่ทำในขั้นตอนการฝึกตัวแบบ โดย fit เฉพาะข้อมูลถึง $t-1$ เพื่อกันการรั่วไหล แล้วจึงฝึกหรืออัปเดตตัวแบบด้วย พารามิเตอร์ที่คงไว้ และสร้างอินพุตของเวลาเพื่อทำนายค่า พร้อมบันทึกผลลัพธ์ ก่อนจะขยับไปยัง $t+1$ ทำซ้ำจนจบช่วงทดสอบ และสุดท้ายรวมผลทั้งช่วงเพื่อคำนวณตัวชี้วัด และแสดงกราฟ Actual vs Forecast ทั้งหมดนี้ทำ เพื่อให้ได้ค่าประเมินที่ไม่เอนเอียงและใกล้เคียงสถานการณ์ใช้งานจริงที่สุด

3.16 การเลือกตัวแบบที่ดีที่สุดและอธิบายด้วย SHAP

หลังจากประเมินด้วย Walk-Forward แล้ว จะเลือกตัวแบบที่ให้ผลลัพธ์ที่ดีที่สุด เช่น MAE ต่ำสุด RMSE ต่ำสุด และ R^2 สูงสุด มาเป็นตัวแบบหลักของระบบ เพื่อเพิ่มความน่าเชื่อถือและความโปร่งใส จะใช้เทคนิค SHAP (SHapley Additive exPlanations) เพื่ออธิบายว่า ในมุมมอง (Global) ตัวแปรใดมีความสำคัญกับตัวแบบมากที่สุด และในมุมมองเฉพาะจุด (Local) การพยากรณ์แต่ละครั้งได้รับอิทธิพลจากตัวแปรใดบ้าง และแต่ละตัวแปรผลักดันค่าทำนายให้สูงหรือต่ำจากค่าฐานอย่างไร การอธิบายผลลัพธ์นี้ช่วยให้ผู้ใช้งานเข้าใจกลไกการตัดสินใจของตัวแบบมากขึ้น และสามารถใช้อยู่ในการตัดสินใจลงทุนหรือวางแผนได้

```
import shap, numpy as np, pandas as pd
explainer = shap.TreeExplainer(model_tmp)
sample = X_test.tail(min(2000, len(X_test)))
shap_vals = explainer.shap_values(sample)

# Global importance
mean_abs = np.mean(np.abs(shap_vals), axis=0)
global_imp = pd.DataFrame({"feature": X.columns, "mean_abs_shap": mean_abs})\
    .sort_values("mean_abs_shap", ascending=False)
global_imp.to_csv("shap_global_importance.csv", index=False)

# Local (แถวล่าสุดของชุดทดสอบ)
x_row = X_test.tail(1)
local_sv = explainer.shap_values(x_row)[0]
local_df = pd.DataFrame({"feature": X.columns, "shap": local_sv, "value": x_row.values.flatten()})\
    .sort_values("shap", key=np.abs, ascending=False)
local_df.to_json("shap_local_lastrow.json", orient="records")

# (ถ้าต้องการภาพสรุป)
shap.summary_plot(shap_vals, sample, show=False)
plt.savefig("shap_summary.png", dpi=150, bbox_inches="tight"); plt.close()
```

3.17 การฝึกตัวแบบสุดท้ายเพื่อนำไปใช้งาน

ทำการฝึกตัวแบบสุดท้ายเพื่อใช้งานจริงด้วยการรวมข้อมูลที่มีทั้งหมดมาฝึกตัวแบบ โดยยึดแนวทาง Walk-Forward แบบ Dynamic ตลอดอายุการใช้งานของระบบ กล่าวคือ ภายหลังจากเลือกชนิดโมเดลและชุดไฮเปอร์พารามิเตอร์ที่ดีที่สุดแล้ว ระบบจะทำงานรายวันหรือทุก k วันตามที่กำหนด ด้วยการกำหนดหน้าต่างฝึกที่อัปเดตไปข้างหน้าอย่างต่อเนื่องโดยค่าเริ่มต้นใช้ Rolling window เช่น $L \approx 126/252/504$ วันทำการ เพื่อให้โมเดลเน้นข้อมูลล่าสุดและลดอิทธิพลของอดีตที่ล้าสมัย โดยขั้นตอนแรกจะทำการเตรียมข้อมูลเหมือนเดิมทั้งหมด จากนั้นฝึกหรืออัปเดตโมเดลด้วยพารามิเตอร์ที่ล็อกไว้และทำการทำนายราคาทองคำของวันถัดไป ระบบจะบันทึกผลพยากรณ์และค่าความคลาดเคลื่อนเพื่อใช้ติดตาม concept drift และประเมินคุณภาพเชิงเวลาของแบบจำลอง นอกจากนี้บันทึกอาร์ติแฟกต์ที่จำเป็นต่อการดีพลอยและการทำซ้ำ ได้แก่ ไฟล์โมเดล เช่น .pkl/.h5 ตัวแปลง (scaler/selector) รายการตัวแปร หน้าต่างที่ใช้ และ JSON metadata ของพารามิเตอร์

3.18 การพัฒนาเว็บแอปพลิเคชันสำหรับการพยากรณ์ราคาทองคำแบบอัตโนมัติ

3.18.1 ออกแบบระบบ

ระบบเว็บแอปพลิเคชันนี้ใช้สถาปัตยกรรมแบบ Client-Server โดยฝั่ง Server ทำหน้าที่ประมวลผลการพยากรณ์ราคาทองคำทั้งหมดแบบอัตโนมัติ ส่วนฝั่ง ทำหน้าที่เพียงแสดงผลลัพธ์ที่ได้รับ โดยไม่มีการป้อนข้อมูลใด ๆ จากผู้ใช้ ผ่านทางหน้าจอ ที่ออกแบบไว้ให้ดูผลลัพธ์อย่างเดียว เช่น กราฟและค่าพยากรณ์ที่อัปเดตเองตามข้อมูลล่าสุด สถาปัตยกรรมนี้ช่วยให้ระบบสามารถทำงานได้เองตั้งแต่การรับข้อมูลต้นทางไปจนถึงการแสดงผลลัพธ์

เทคโนโลยีหลักที่ใช้ในระบบประกอบด้วย FastAPI สำหรับฝั่ง Server (Backend) และ React.js สำหรับฝั่ง Client (Frontend) โดยมีการใช้ไลบรารี React Chart.js ร่วมด้วยสำหรับการแสดงกราฟข้อมูลบนหน้าเว็บ ตัวแบบการทำนายใช้วิธีการเรียนรู้ของเครื่องแบบ XGBoost ที่ได้รับการฝึกสอนมาก่อนล่วงหน้า และถูกบันทึกเก็บไว้เพื่อเรียกใช้งานในระบบจริง ฝั่ง Server จะโหลดตัวแบบ XGBoost ที่ฝึกไว้แล้วนี้ขึ้นมา พร้อมกับดึงข้อมูลล่าสุดจากไฟล์ข้อมูลที่ได้รับการอัปเดตทุกวัน เพื่อใช้ในการพยากรณ์ราคาทองคำโดยอัตโนมัติในแต่ละวัน

3.18.2 การพัฒนา Backend ด้วย FastAPI

สำหรับฝั่ง Backend ระบบใช้ FastAPI ซึ่งเป็น Web Framework ที่เน้นประสิทธิภาพสูงและรองรับการพัฒนา REST API ได้อย่างรวดเร็ว ในการทำงานของระบบอัตโนมัตินี้ ตัวแอปพลิเคชัน FastAPI จะทำการโหลดตัวแบบ XGBoost ที่ฝึกไว้แล้วเข้าสู่หน่วยความจำเมื่อ Server เริ่มทำงาน จากนั้นจึงเตรียมส่วนประมวลผลที่ใช้สร้างคำพยากรณ์ราคาทองคำโดยไม่ต้องรอคำร้องขอจากผู้ใช้ กล่าวคือ มีการออกแบบให้ Backend สร้างผลการพยากรณ์ล่วงหน้าโดยอัตโนมัติ เมื่อมีข้อมูลใหม่เข้ามา เช่น หลังจากระบบโหลดข้อมูลประจำวันที่อัปเดตล่าสุด ก็จะมีการคำนวณพยากรณ์ราคาทองคำทันที นอกจากนี้ ยังมีการจัดทำ Endpoint บน API ที่ให้บริการข้อมูลผลการพยากรณ์นี้แก่ฝั่ง Client ในลักษณะพร้อมใช้ เช่น กำหนดให้มี HTTP GET request ซึ่งเมื่อถูกเรียกใช้งานจะส่งคืนคำพยากรณ์ราคาทองคำล่าสุดในรูปแบบ JSON

การตรวจสอบและปรับปรุงตัวแบบอัตโนมัติ ภายใน Backend ยังได้ผนวกรวมกลไกการตรวจสอบประสิทธิภาพของตัวแบบและการปรับปรุงตัวแบบโดยอัตโนมัติเมื่อจำเป็น โดยระบบจะคอยตรวจสอบ ค่า R^2 ซึ่งเป็นตัวชี้วัดความแม่นยำในการพยากรณ์ของตัวแบบบนชุดข้อมูลล่าสุดหรือชุดตรวจสอบ หากพบว่า ค่า R^2 ของตัวแบบต่ำกว่า 0.97 ซึ่งหมายความว่าประสิทธิภาพของตัวแบบลดลงเกินเกณฑ์ที่ยอมรับได้ ระบบจะทำการเทรนตัวแบบใหม่โดยอัตโนมัติ (Retrain) ภายในกระบวนการของ Backend เองทันทีที่การ Retrain นี้จะใช้ชุดข้อมูลล่าสุดทั้งหมดที่มีอยู่ในระบบในการฝึกตัวแบบ XGBoost ขึ้นใหม่ เพื่อปรับพารามิเตอร์ของตัวแบบให้เหมาะสมกับแนวโน้มข้อมูลปัจจุบันมากที่สุด เมื่อฝึกตัวแบบใหม่เสร็จ ระบบจะสลับไปใช้ตัวแบบที่ปรับปรุงแล้วนั้นสำหรับการพยากรณ์ครั้งถัดไปทันที ซึ่งทั้งหมดนี้เกิดขึ้นเบื้องหลังโดยไม่ส่งผลกระทบต่อการทำงานของระบบต่อผู้ใช้อย่างไรก็ตาม

3.18.3 การพัฒนา Frontend ด้วย React.js

ฝั่งหน้าเว็บพัฒนาโดยใช้ React.js ในรูปแบบของ single-page application (SPA) เมื่อผู้ใช้เปิดหน้าเว็บ แอป React จะทำการ เรียกข้อมูลผลการพยากรณ์จาก Backend โดยอัตโนมัติ เช่น ผ่านการใช้คำสั่งในฟังก์ชัน use Effect ที่จะส่ง HTTP GET request ไปยัง API ของ FastAPI ทันทีเมื่อโหลดหน้าจ่อ เพื่อดึงค่าพยากรณ์ล่าสุดและข้อมูลที่เกี่ยวข้องมาแสดงผล การเชื่อมต่อกับ API ฝั่ง Server นี้สามารถกำหนดค่า URL ปลายทางผ่านตัวแปรสภาพแวดล้อม (Environment Variable) ของ React ที่ขึ้นต้นด้วย REACT_APP_ เช่น REACT_APP_API_URL เพื่อความสะดวกและความปลอดภัย ทำให้โค้ดฝั่ง Client ไม่ต้องระบุ URL ตรง ๆ ภายในโปรแกรม หลังจากได้รับข้อมูลผลการพยากรณ์จาก Server แล้ว แอป React จะทำการอัปเดตสถานะภายใน (state) และ แสดงผลข้อมูลดังกล่าวบนหน้าจอผู้ใช้ทันที

ในการนำเสนอผลลัพธ์บนหน้าเว็บ ฝั่ง Frontend ใช้ไลบรารี React Chart.js เพื่อสร้างกราฟและองค์ประกอบภาพต่าง ๆ ที่ช่วยให้ผู้ใช้เข้าใจข้อมูลได้ง่าย React Chart.js ถูกใช้ในการวาดกราฟแสดงแนวโน้มราคาทองคำและค่าที่ตัวแบบพยากรณ์ได้ในรูปแบบ interactive ที่สวยงามและตอบสนองต่อผู้ใช้ได้ดี การผสมผสานระหว่าง React.js กับ React Chart.js ทำให้ส่วนติดต่อผู้ใช้สามารถแสดงกราฟเส้นของข้อมูลราคาทองคำได้อย่างชัดเจน พร้อมทั้งปรับปรุงการแสดงผลได้ทันทีเมื่อข้อมูลใหม่ถูกดึงเข้ามาจาก Backend

3.18.4 การแสดงผลการทำนายและการอธิบายตัวแบบ

หลังจากที่ Backend สร้างผลลัพธ์การพยากรณ์ราคาทองคำและส่งมายัง Frontend แล้ว ส่วนติดต่อผู้ใช้จะแสดงผลการทำนายดังกล่าวในลักษณะที่เข้าใจง่ายและเป็นระบบ เพื่อให้ผู้ใช้รับทราบข้อมูลที่สำคัญได้อย่างรวดเร็ว ข้อมูลที่แสดงประกอบด้วยราคาทองคำที่พยากรณ์ไว้ล่าสุดเทียบกับข้อมูลราคาทองคำจริงในช่วงที่ผ่านมา เป็นตัวลขและนำเสนอในรูปแบบกราฟเส้น (line chart) ที่แสดงแนวโน้มตามเวลา บนกราฟนี้ ข้อมูลราคาทองคำจริง และข้อมูลการพยากรณ์จะถูกแสดงด้วยสีหรือลักษณะของเส้นที่แตกต่างกันอย่างชัดเจน เพื่อให้ผู้ใช้สามารถแยกแยะระหว่างส่วนที่เป็นข้อมูลจริงกับส่วนที่เป็นการทำนายอนาคตได้อย่างสะดวก การจัดแสดงผลเช่นนี้ช่วยให้ผู้ใช้มองเห็นภาพรวมของแนวโน้มราคาและ เปรียบเทียบค่าที่พยากรณ์กับแนวโน้มจริงที่ผ่านมาได้อย่างมีประสิทธิภาพ ซึ่งเป็นประโยชน์ในการวิเคราะห์แนวโน้มและความแม่นยำของตัวแบบในบริบทของข้อมูลจริงที่ผ่านมา

นอกจากนี้ ระบบยังมี Dashboard SHAP สำหรับอธิบายการทำงานของตัวแบบเพิ่มเติมเพื่อความโปร่งใสและความเข้าใจที่ลึกซึ้งยิ่งขึ้น Dashboard SHAP นี้นำเสนอการอธิบายตัวแบบทั้งในระดับ Global และ Local เพื่อให้ครอบคลุมมุมมองการตีความผลการพยากรณ์ที่แตกต่างกัน ดังนี้

Global Explanation แสดง ค่าความสำคัญของคุณลักษณะ (Feature Importance) ในภาพรวมของตัวแบบ XGBoost ที่ใช้ โดยพิจารณาจากค่า SHAP เฉลี่ยของแต่ละตัวแปรอินพุตทั่วทั้งชุดข้อมูล การแสดงผลในส่วนนี้อยู่ตารางที่จัดอันดับปัจจัย เช่น อัตราดอกเบี้ย ราคาสินค้าโภคภัณฑ์อื่น ตัวชี้วัดเศรษฐกิจ เป็นต้น ตามระดับความสำคัญที่มีต่อการพยากรณ์ราคาทองคำ ผู้ใช้หรือผู้วิจัยจะสามารถมองเห็นได้อย่างชัดเจนว่าปัจจัยใดมีอิทธิพลมากที่สุดต่อการพยากรณ์ของตัวแบบในภาพรวม ซึ่งช่วยยืนยันความสอดคล้องกับความรู้ทางการเงินหรือเศรษฐศาสตร์ที่เกี่ยวข้องได้

Local Explanation แสดงการวิเคราะห์แบบเจาะจงสำหรับ ผลการพยากรณ์ในแต่ละวันหรือแต่ละครั้ง โดยใช้ค่า SHAP ในการบ่งชี้ว่าคุณลักษณะแต่ละตัวส่งผลต่อค่าที่ตัวแบบพยากรณ์อย่างไรสำหรับกรณีนั้น ๆ ตัวอย่างเช่น สำหรับการพยากรณ์ราคาทองคำของวันล่าสุด Dashboard จะแสดงให้เห็นว่าแต่ละปัจจัย เช่น ค่าเงินดอลลาร์ อัตราผลตอบแทนพันธบัตร ราคาน้ำมัน มีส่วน ผลักดันให้ค่าที่พยากรณ์สูงขึ้นหรือต่ำลง การอธิบายเชิงเฉพาะกรณีในลักษณะนี้นำเสนอผ่านกราฟหรือแผนภูมิที่แสดงค่า SHAP ของแต่ละตัวแปรสำหรับการทำนายจุดนั้น ๆ ทำให้สามารถเห็นภาพได้ว่าปัจจัยใดส่งผลบวกหรือลบต่อราคาตัวแบบทำนาย และประมาณขนาดของผลกระทบนั้นๆ ด้วยการมี Dashboard SHAP ดังกล่าว ระบบจึงเพิ่มความโปร่งใสในการทำงานของตัวแบบ ช่วยให้ผู้ใช้งานและนักวิจัยสามารถ เข้าใจเหตุผลเบื้องหลังการทำนายของตัวแบบ ได้ดียิ่งขึ้น สิ่งนี้มีความสำคัญในเชิงวิชาการและการนำไปใช้จริง เนื่องจากผู้ใช้งานสามารถตรวจสอบได้ว่าตัวแบบให้ความสำคัญกับปัจจัยที่สมเหตุสมผลหรือไม่ และสามารถไว้วางใจผลการพยากรณ์เหล่านั้นมากน้อยเพียงใด เมื่อพิจารณาจากการอธิบายเชิงสาเหตุที่ระบบนำเสนอให้

3.18.5 การจัดการข้อมูลและการอัปเดตข้อมูลอัตโนมัติ

การจัดการข้อมูลอย่างมีประสิทธิภาพเป็นปัจจัยสำคัญทั้งในการฝึกตัวแบบและการใช้งานระบบพยากรณ์จริง ในระบบนี้ ชุดข้อมูลต้นทางที่ใช้สำหรับการพยากรณ์ จะถูกอัปเดตโดยอัตโนมัติทุกวัน ผ่านกระบวนการใน GitHub repository ของโครงการ ได้มีการตั้งค่ากระบวนการอัตโนมัติให้รันสคริปต์ดึงข้อมูลรายวัน ซึ่งสคริปต์ดังกล่าวจะทำหน้าที่เชื่อมต่อไปยังแหล่งข้อมูลภายนอกที่เกี่ยวข้อง ได้แก่บริการข้อมูลการเงินต่าง ๆ แล้วดึงค่าล่าสุดของแต่ละตัวแปรมาเพิ่มเติมลงในชุดข้อมูล เมื่อสคริปต์ทำงานเสร็จ ระบบ GitHub Actions จะทำการ commit ไฟล์ CSV ที่ปรับปรุงแล้วกลับไปยัง repository โดยอัตโนมัติพร้อมข้อความระบุว่า เป็นการอัปเดตข้อมูลประจำวัน ด้วยกลไกนี้ ฐานข้อมูลที่ใช้ในตัวแบบพยากรณ์จะได้รับการเติมเต็มให้ทันสมัยอยู่เสมอ โดยไม่ต้องพึ่งพาการรวบรวมข้อมูลด้วยมือ ลดความเสี่ยงของข้อผิดพลาดและภาระงานในการบำรุงรักษาข้อมูลลงอย่างมาก

สำหรับฝั่ง Backend นั้น การนำข้อมูลที่อัปเดตแล้วมาใช้งาน หลังจากโหลดข้อมูลเข้าสู่ระบบแล้ว โปรแกรมจะทำการจัดเรียงข้อมูลตามลำดับเวลาและดำเนินการทำความสะอาดข้อมูลที่จำเป็น เช่น การแปลงชนิดข้อมูล, การแก้ไขค่าที่ผิดปกติ และการเติมค่าที่ขาดหาย ตามขั้นตอนที่ได้อธิบายไว้ในบทก่อนหน้า จากนั้น ข้อมูลล่าสุดเหล่านี้จะถูกป้อนเข้าสู่กระบวนการพยากรณ์ของตัวแบบ XGBoost โดยอัตโนมัติ การที่กระบวนการดึงและเตรียมข้อมูลเป็นไปแบบอัตโนมัติทั้งหมดทำให้มั่นใจได้ว่าข้อมูลที่ใช้ในการคำนวณพยากรณ์ในแต่ละวันนั้นเป็นข้อมูลชุดใหม่ล่าสุดที่ถูกต้องและสอดคล้องกับความเป็นจริงเสมอ การจัดการข้อมูล

อัตโนมัติรูปแบบนี้ ช่วยลดความผิดพลาดที่อาจเกิดจากมนุษย์และช่วยรักษาความสมบูรณ์ของชุดข้อมูลเมื่อเวลาผ่านไป ซึ่งส่งผลให้ตัวแบบสามารถสร้างผลการพยากรณ์ที่น่าเชื่อถือและทันต่อสถานการณ์ปัจจุบันอยู่ตลอดเวลา

3.18.6 การนำไปใช้งานจริง (Deploy) ด้วย Render

การนำระบบเว็บแอปพลิเคชันนี้ไปใช้งานจริงทำได้อย่างสะดวกและรวดเร็วด้วยบริการคลาวด์ Render.com ซึ่งรองรับทั้งการติดตั้งส่วน Backend และ Frontend บนแพลตฟอร์มเดียวกัน สำหรับฝั่ง Backend ที่พัฒนาด้วย FastAPI สามารถสร้าง Web Service ใหม่บน Render โดยผูกกับ repository ของซอร์สโค้ด Backend และกำหนดค่าการ Deploy ดังนี้ กำหนด runtime เป็น Python 3 และตั้งค่าคำสั่งสำหรับการ Build และการ Start แอปพลิเคชันตามคำแนะนำของ Render ตัวอย่างเช่น ในขั้นตอน Build ให้ใช้คำสั่ง `pip install -r requirements.txt` เพื่อติดตั้งไลบรารีที่จำเป็นทั้งหมด และในขั้นตอน Start ให้ใช้คำสั่ง `uvicorn main:app --host 0.0.0.0 --port $PORT` เพื่อรัน Server FastAPI ผ่าน Uvicorn โดยระบุพอร์ตที่ Render กำหนด เมื่อดำเนินการดีพลอยเสร็จสิ้น Render จะสร้าง URL สำหรับบริการ Backend นี้โดยอัตโนมัติ ซึ่งเป็นปลายทางที่ Frontend จะใช้เรียก API ต่อไป

สำหรับฝั่ง Frontend ที่พัฒนาด้วย React.js สามารถ Deploy เป็น Static Site บน Render ได้โดยการเชื่อมต่อกับ repository ของโค้ด React ของโครงการ ขั้นตอนการตั้งค่าประกอบด้วยการกำหนดคำสั่ง Build เช่น `yarn build` หรือ `npm run build` ขึ้นอยู่กับเครื่องมือจัดการแพ็คเกจที่ใช้ และระบุ Publish Directory เป็นโฟลเดอร์ build ที่ได้จากการ build ของ React เมื่อสั่ง Deploy Render จะทำการ Build โค้ด React และเผยแพร่ไฟล์ static ของแอปพลิเคชันบนระบบเครือข่ายของตน พร้อมกับจัดหา CDN และ URL สำหรับเข้าใช้งานหน้าเว็บนั้นโดยอัตโนมัติ

ด้วยกระบวนการนำขึ้นใช้งานดังกล่าว ระบบเว็บแอปพลิเคชันพยากรณ์ราคาทองคำแบบอัตโนมัติของงานวิจัยนี้จึงพร้อมให้บริการผ่านอินเทอร์เน็ต โดยผู้ใช้งานสามารถเข้าถึงส่วน Frontend ได้ผ่าน URL ของ static site ที่ Render กำหนด และ Frontend จะเชื่อมต่อกับ Backend ผ่าน URL ของ API ที่ได้รับจาก Render เช่นเดิม ทั้งนี้ การผสมรวมระหว่าง GitHub และ Render ทำให้เกิดกระบวนการ Deploy แบบต่อเนื่อง (continuous deployment) กล่าวคือ เมื่อใดก็ตามที่ repository บน GitHub มีการเปลี่ยนแปลง เช่น ไฟล์ข้อมูล CSV ได้รับการอัปเดตประจำวันจากกระบวนการที่กล่าวถึงในหัวข้อก่อนหน้า ระบบ Render จะตรวจจับการ commit ใหม่และดำเนินการ re-deploy เวอร์ชันล่าสุดของทั้ง Backend และ Frontend โดยอัตโนมัติ ด้วยวิธีนี้ แอปพลิเคชันที่เผยแพร่บน Render จะได้รับการปรับปรุงให้ใช้ข้อมูลและตัวแบบที่ใหม่ที่สุดอยู่เสมอ

3.19 การประเมินผลการใช้งานเว็บแอปพลิเคชัน

เพื่อประเมินประสิทธิภาพและความพึงพอใจของผู้ใช้งานที่มีต่อ "เว็บแอปพลิเคชันทำนายราคาทองคำ" ที่พัฒนาขึ้น ผู้วิจัยได้ดำเนินการประเมินผลโดยใช้แบบสอบถาม (Questionnaire) ซึ่งมีขั้นตอนดังนี้

3.19.1 การสร้างเครื่องมือประเมินผล

ผู้วิจัยได้สร้างแบบสอบถามออนไลน์ (Google Forms) เพื่อวัดความพึงพอใจในด้านต่างๆ ของเว็บแอปพลิเคชัน โดยแบ่งโครงสร้างแบบสอบถามออกเป็น 5 ส่วนหลัก ได้แก่

ส่วนที่ 1 ข้อมูลทั่วไปของผู้ใช้งาน เช่น ประสบการณ์การลงทุน อุปกรณ์ที่ใช้

ส่วนที่ 2 การประเมินด้านการออกแบบ (UI) และความง่ายในการใช้งาน (Usability) เช่น ความสวยงาม การค้นหาข้อมูล

ส่วนที่ 3 การประเมินตัวแปรหลัก (Functionality) เช่น ความชัดเจนของผลทำนาย ประโยชน์ของกราฟเปรียบเทียบ และความเข้าใจง่ายของตารางปัจจัยขับเคลื่อน (SHAP)

ส่วนที่ 4 การประเมินคุณภาพข้อมูลและความน่าเชื่อถือ เช่น ความเร็วในการโหลด ความน่าเชื่อถือของผลการทำนาย

ส่วนที่ 5 ความพึงพอใจและข้อเสนอแนะโดยรวม เช่น สิ่งที่ชอบ, สิ่งที่ต้องปรับปรุง

3.19.2 การเก็บรวบรวมข้อมูล ผู้วิจัยจะทำการแจกจ่ายแบบสอบถามไปยังกลุ่มผู้ใช้งานเป้าหมาย เช่น นักศึกษา นักลงทุนทั่วไป หรือกลุ่มเพื่อนที่ทดลองใช้งาน และรวบรวมคำตอบเพื่อนำมาวิเคราะห์ผล

3.19.3 การวิเคราะห์ข้อมูล ข้อมูลที่ได้จากแบบสอบถามจะถูกนำมาวิเคราะห์โดยใช้สถิติเชิงพรรณนา (Descriptive Statistics) เช่น ค่าเฉลี่ย (Mean), ค่าร้อยละ (Percentage) เพื่อสรุปผลความพึงพอใจในแต่ละด้าน และนำข้อเสนอแนะไปเปิดมาวิเคราะห์เชิงเนื้อหา (Content Analysis) เพื่อใช้เป็นแนวทางในการพัฒนาและปรับปรุงเว็บแอปพลิเคชันต่อไป

บทที่ 4

ผลการดำเนินงาน

4.1 ภาพรวมชุดข้อมูลและผลการเตรียมข้อมูล

การศึกษานี้รวบรวมข้อมูลอนุกรมเวลาหลายตัวแปร (multivariate time series) เพื่อใช้พัฒนาและเปรียบเทียบตัวแบบพยากรณ์ราคาทองคำรายวันแบบเรียลไทม์ โดยบูรณาการข้อมูลราคาทองคำแบบ OHLCV ร่วมกับตัวชี้วัดเศรษฐกิจมหภาคและตัวชี้วัดตลาดการเงินจากแหล่งข้อมูลมาตรฐานสากล ได้แก่ Yahoo Finance และ Federal Reserve Economic Data (FRED) ตามขอบเขตและหลักการจัดการความถี่ที่กำหนดไว้ในบทที่ 1-3 ทั้งนี้ ได้ดำเนินการจัดรูปแบบข้อมูลให้อยู่ในกรอบความถี่รายวันเดียวกัน จัดการค่าว่าง (missing values) และตรวจสอบความสอดคล้องของข้อมูล เพื่อให้ชุดข้อมูลพร้อมสำหรับการฝึกตัวแบบและประเมินผลแบบคำนึงถึงลำดับเวลาในขั้นตอนถัดไป

4.1.1 ช่วงเวลาและจำนวนตัวอย่างของข้อมูล

ชุดข้อมูลครอบคลุมช่วงเวลา ตั้งแต่วันที่ 21 มกราคม 2016 ถึง 16 มกราคม 2026 (ย้อนหลังประมาณ 10 ปี) ซึ่งเป็นข้อมูลรายวันตาม “วันทำการ/วันซื้อขาย” ของตลาดที่เกี่ยวข้อง (trading days) ภายหลังการรวมและทำความสะอาดข้อมูล ได้จำนวนตัวอย่างทั้งหมด 2,556 ระเบียบ (observations) โดยแต่ละระเบียบแทนข้อมูลหนึ่งวันในลำดับเวลา และมีการจัดเรียงตามวันที่จากอดีตไปปัจจุบันโดยไม่พบวันที่ซ้ำซ้อน (duplicate dates)

4.1.2 รายการตัวแปรที่ใช้ในการวิเคราะห์

ตัวแปรที่ใช้ในการวิเคราะห์และพยากรณ์กำหนดตามกรอบแนวคิดในบทที่ 2 และตารางตัวแปรในบทที่ 1 (ตารางที่ 1) โดยจำแนกได้เป็น 2 กลุ่มหลัก ได้แก่ ตัวแปรราคาทองคำแบบ OHLCV (Gold OHLCV) ประกอบด้วย Gold_Open, Gold_High, Gold_Low, Gold_Close และ Gold_Volume ซึ่งเป็นข้อมูลมาตรฐานสำหรับการวิเคราะห์เชิงอนุกรมเวลาทางการเงิน โดยใช้เป็นฐานสำหรับสะท้อนแนวโน้มและความผันผวนรายวัน รวมถึงใช้เป็นอินพุตหลักในการสร้างตัวแบบพยากรณ์ตัวแปรเศรษฐกิจมหภาคและตลาดการเงิน (Macroeconomic & Market Indicators) ได้แก่ Silver_Price_USD, Crude_Oil_Price, Iron_Ore_Price, SP500_Index, US_10Y_Treasury_Yield, US_Dollar_Index_DXY และ Inflation_CPI เพื่อสะท้อนสภาพเศรษฐกิจมหภาค ภาวะตลาดทุน ค่าเงิน และเงินเฟ้อ ซึ่งตามวรรณกรรมในบทที่ 2 ระบุว่ามีความเกี่ยวข้องกับการเคลื่อนไหวของราคาทองคำในหลายมิติ แหล่งข้อมูลและสัญลักษณ์ที่ใช้ดึงข้อมูลเป็นไปตามที่ระบุในรายงาน ได้แก่ Yahoo Finance (เช่น XAUUSD=X, GC=F, SI=F, CL=F, ^GSPC, ^TNX, DX-Y.NYB เป็นต้น) FRED (เช่น CPIAUCSL สำหรับ CPI)

4.1.3 ผลการจัดการค่าว่าง/ความถี่เวลา และผลหลังทำความสะอาด

เนื่องจากข้อมูลที่นำมาบูรณาการมีความถี่ต่างกัน (รายวันและรายเดือน) จึงดำเนินการจัดการความถี่และค่าว่างเพื่อให้ชุดข้อมูลอยู่ในกรอบเดียวกันก่อนการสร้างตัวแบบ โดยมีขั้นตอนหลักดังนี้

การจัดการความถี่ (Frequency Alignment)

ข้อมูลด้านการเงินและสินค้าโภคภัณฑ์ส่วนใหญ่มีความถี่รายวัน ขณะที่ตัวแปรเศรษฐกิจมหภาคบางรายการเผยแพร่เป็นรายเดือน เช่น Inflation_CPI จึงทำการจัดให้อยู่ในกรอบรายวันด้วยวิธี forward fill เพื่อให้สามารถวิเคราะห์ร่วมกับข้อมูลรายวันได้อย่างสอดคล้อง

การจัดการค่าว่าง (Missing Values Handling)

ภายหลังการรวมข้อมูลจากหลายแหล่ง ได้ตรวจสอบค่าว่างของแต่ละตัวแปรและดำเนินการเติมค่าตามหลักการเดียวกัน เช่น forward fill สำหรับตัวแปรความถี่ต่ำกว่า จากนั้นจึงคัดเลือกข้อมูลที่สมบูรณ์เพื่อให้สามารถฝึกตัวแบบได้โดยไม่เกิดปัญหาค่าว่างแทรกในอินพุต

ผลหลังทำความสะอาดข้อมูล (Post-cleaning Results)

เมื่อสิ้นสุดการเตรียมข้อมูล ชุดข้อมูลสุดท้ายมีจำนวน 2,556 ระเบียบ และ 12 ตัวแปรเชิงตัวเลข และไม่พบค่าว่างในทุกตัวแปร ซึ่งสะท้อนว่าชุดข้อมูลอยู่ในสภาพพร้อมสำหรับการนำไปฝึกตัวแบบและประเมินผลในขั้นตอนการทดลอง

4.1.4 สถิติเชิงพรรณนา (Descriptive Statistics)

เพื่อตรวจสอบภาพรวมการกระจายตัวของข้อมูล ความผันผวน และพฤติกรรมเชิงสถิติของแต่ละตัวแปร จึงคำนวณสถิติ

เชิงพรรณนา ได้แก่ Mean, Median, Maximum, Minimum, Std. Dev, Skewness, Kurtosis และ Observations

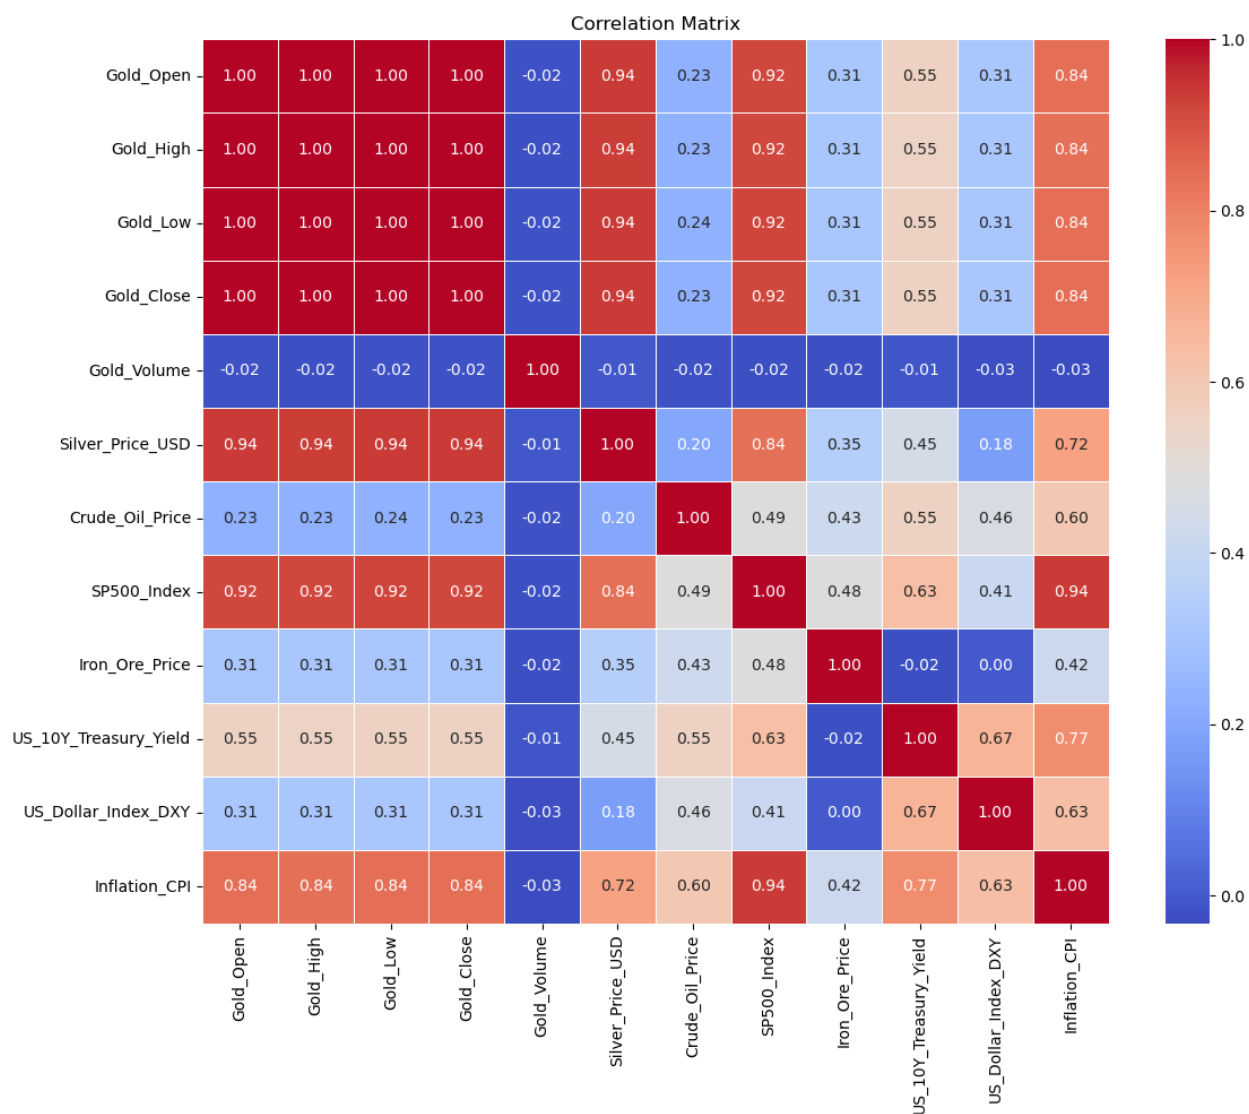
ตารางที่ 4.1 Descriptive statistics (All variables)

	Gold Open	Gold High	Gold Low	Gold Close	Gold Volume	Silver Price USD	Crude Oil Price	SP500 Index	Iron Ore Price	US 10Y Treasur y Yield	US Dollar Index DXY	Inflatio n CPI
Mean	1,847.92	1,857.53	1,838.98	1,848.52	5,322.21	22.84	63.71	3,796.95	101.34	2.70	98.52	275.96
Median	1,763.55	1,771.30	1,756.05	1,762.70	214.00	21.42	63.41	3,701.71	100.07	2.56	97.81	262.64
Maximum	4,621.60	4,635.00	4,612.90	4,626.30	386,334.00	91.88	123.70	6,977.27	219.77	4.99	114.11	326.03
Minimum	1,098.00	1,103.20	1,094.10	1,097.20	0.00	11.73	-37.63	1,829.08	41.09	0.50	88.59	237.34
Std. Dev	688.19	694.03	683.38	689.29	29,210.87	8.92	17.34	1,305.69	33.35	1.18	5.03	28.99
Skewne ss	1.71	1.71	1.71	1.71	7.36	2.81	0.23	0.59	1.00	0.05	0.37	0.36
Kurtosis	5.90	5.91	5.89	5.90	62.50	15.57	3.88	2.40	4.55	1.83	2.57	1.56
Observ ations	2556	2556	2556	2556	2556	2556	2556	2556	2556	2556	2556	2556

จากผลการวิเคราะห์สถิติเชิงพรรณนาของชุดข้อมูลรายวันตลอดระยะเวลา 10 ปี รวมทั้งสิ้น 2,556 ตัวอย่าง พบว่าชุดข้อมูลนี้สะท้อนให้เห็นถึงพลวัตและความผันผวนของตลาดการเงินในระยะยาวได้อย่างชัดเจน โดยราคาทองคำ (Gold Prices) มีการเคลื่อนไหวในช่วงกว้าง ตั้งแต่ราคาต่ำสุดที่ 1,097.20 ดอลลาร์สหรัฐ ไปจนถึงราคาสูงสุดที่ 4,635.00 ดอลลาร์สหรัฐ ซึ่งค่าความเบี่ยงเบนมาตรฐาน (Standard Deviation) ที่ระดับ 689.29 บ่งชี้ว่าราคาทองคำมีความผันผวนสูงตลอดช่วงทศวรรษที่ผ่านมา ในขณะเดียวกัน ข้อมูลราคาน้ำมันดิบ (Crude Oil Price) ที่ปรากฏค่าต่ำสุดติดลบ (-37.63) เป็นหลักฐานเชิงประจักษ์ที่บันทึกสถานะวิกฤตการณ์ของตลาดในช่วงเวลาดังกล่าวไว้ได้อย่างครบถ้วน สำหรับตัวแปรปริมาณการซื้อขาย (Gold Volume) พบค่าความเบ้ (Skewness) และความโด่ง (Kurtosis) ในระดับสูง ซึ่งเป็นลักษณะตามธรรมชาติของข้อมูลอนุกรมเวลาทางการเงิน (Financial Time Series) ในระยะยาว ที่มักมีการกระจายตัวแบบไม่ปกติ (Non-normal Distribution) อันเกิดจากสถานะตลาดที่ผันผวนหรือเหตุการณ์สำคัญทางเศรษฐกิจ

4.1.5 การวิเคราะห์ความสัมพันธ์ระหว่างตัวแปร (Correlation Matrix/Heatmap) และข้อสังเกตสำคัญ

เพื่อสำรวจความสัมพันธ์เชิงเส้นเบื้องต้นระหว่างตัวแปร จึงคำนวณค่าสหสัมพันธ์แบบเพียร์สัน (Pearson correlation) และนำเสนอในรูปแบบทริกซ์สหสัมพันธ์/แผนภาพความร้อน (Correlation heatmap)



ผลการวิเคราะห์พบข้อสังเกตสำคัญดังนี้

4.1.5.1 กลุ่มตัวแปร Gold_Open, Gold_High, Gold_Low และ Gold_Close มีสหสัมพันธ์สูงมากเกือบสมบูรณ์ (ใกล้ 1) ซึ่งเป็นผลจากการเป็นราคาภายในวันของสินทรัพย์เดียวกัน สะท้อนภาวะ multicollinearity ที่อาจกระทบตัวแบบเชิงเส้นบางชนิดได้ (แต่โดยทั่วไปกระทบน้อยกว่าในกลุ่ม tree-based models)

4.1.5.2 Gold_Close มีความสัมพันธ์เชิงบวกสูงกับ Silver_Price_USD และ SP500_Index ในชุดข้อมูลนี้ ซึ่งสะท้อนการเคลื่อนไหวร่วมกันในระดับแนวโน้มระยะยาว (long-run co-movement) ภายใต้ช่วงเวลาที่ศึกษาตัวแปรมหภาคอย่าง Inflation_CPI มีความสัมพันธ์เชิงบวกในระดับสูงกับราคาทองคำ สอดคล้องกับกรอบแนวคิดใน

4.1.5.3 บทที่ 2 ที่ทองคำมักถูกมองเป็นสินทรัพย์ป้องกันเงินเฟ้อในบางบริบท US_10Y_Treasury_Yield, US_Dollar_Index_DXY, Iron_Ore_Price และ Crude_Oil_Price มีความสัมพันธ์กับราคาทองคำในระดับต่ำถึงปานกลาง ขณะที่ Gold_Volume มีความสัมพันธ์เชิงเส้นต่ำมากกับระดับราคา (ใกล้เคียงศูนย์)

4.1.5.4 อย่างไรก็ตาม “ค่าสหสัมพันธ์” เป็นการวัดเชิงเส้นและอาจได้รับอิทธิพลจากแนวโน้มตามเวลา (trend) จึงใช้เพื่อการสำรวจเบื้องต้นเท่านั้น การสรุปเชิงสาเหตุจะอาศัยผลการทดลองแบบ out-of-sample และการอธิบายตัวแบบด้วย SHAP ในหัวข้อถัดไป

4.2 ผลการออกแบบตัวแปรและชุดข้อมูลสำหรับการพยากรณ์ (Results of Variable Design and Data Preparation)

การเตรียมข้อมูลสำหรับการฝึกสอนตัวแบบ (Model Training) ดำเนินการผ่านขั้นตอนวิธี (Algorithm) ที่พัฒนาขึ้นในสคริปต์ xgb_build_final_artifacts.py โดยมีรายละเอียดการจัดการข้อมูลและผลลัพธ์การออกแบบตัวแปรดังนี้

4.2.1 การกำหนดตัวแปรเป้าหมาย (Target Variable Definition)

งานวิจัยนี้ประเมินแบบจำลอง เพื่อพยากรณ์ราคาทองคำล่วงหน้า 1 วัน ($t+1$) โดยใช้แนวคิดการพยากรณ์บนสเกล Log Return เพื่อลดความผันผวนและปรับข้อมูลให้เหมาะสมกับการวิเคราะห์อนุกรมเวลา โดยกำหนดสมการของตัวแปรเป้าหมาย (\hat{Y}_t) ดังนี้:

$$Y_t = \ln(P_{t+1}/P_t)$$

โดยที่:

P_{t+1} คือราคาทองคำ ณ วันที่ $t + 1$

P_t คือ ราคาทองคำ ณ วันที่ t

ภายหลังจากที่ตัวแบบทำการพยากรณ์ค่า Log Return (\hat{Y}_t) ได้แล้ว จะดำเนินการแปลงค่ากลับให้เป็นหน่วยของราคา (Reconstruct to Price) เพื่อนำไปใช้ในการประเมินผลและเปรียบเทียบ โดยใช้สมการดังนี้:

$$\hat{P}_{t+1} = P_t \cdot \exp(\hat{Y}_t)$$

การแปลงค่ากลับนี้ช่วยให้สามารถวัดประสิทธิภาพของตัวแบบด้วยตัวชี้วัดมาตรฐานในหน่วย "ราคา" ได้อย่างถูกต้อง ซึ่งประกอบด้วยค่าความคลาดเคลื่อนกำลังสองเฉลี่ย (RMSE), ค่าเฉลี่ยความคลาดเคลื่อนสัมบูรณ์ (MAE), ค่าเฉลี่ยร้อยละความคลาดเคลื่อนสัมบูรณ์ (MAPE) และสัมประสิทธิ์การตัดสินใจ (SR^2)

4.2.2 การสร้างคุณลักษณะและเตรียมข้อมูล (Feature Engineering & Preprocessing)

กระบวนการสร้างคุณลักษณะ (Feature Engineering) มุ่งเน้นไปที่การสร้างตัวแปรย้อนหลัง (Lag Features) เพื่อให้ตัวแบบสามารถเรียนรู้รูปแบบการเคลื่อนไหวของราคาในอดีตได้ โดยมีขั้นตอนการประมวลผลข้อมูลดังนี้

4.2.2.1 การจัดการข้อมูลสูญหาย (Missing Values Handling): ใช้วิธีการเติมค่าไปข้างหน้า (Forward Fill) เพื่อรักษาความต่อเนื่องของข้อมูลอนุกรมเวลา และลบแถวข้อมูลที่ไม่สมบูรณ์ (Drop NA) ในขั้นตอนสุดท้าย

4.2.2.2 การปรับปรุงข้อมูลอัตราผลตอบแทนพันับัตร (Data Correction): สำหรับตัวแปร US_10Y_Treasury_Yield ได้มีการตรวจสอบค่าผิดปกติ (Outlier) หากพบว่าค่าสูงกว่า 20 (ซึ่งเป็นไปได้อย่างยากในสภาวะปกติแต่มักเกิดจากความผิดพลาดของหน่วยข้อมูล) จะทำการหารด้วย 10 เพื่อปรับให้อยู่ในสเกลที่ถูกต้อง

4.2.2.3 การสร้างตัวแปรย้อนหลัง (Lag Generation): สร้างตัวแปรอิสระ (X) โดยการนำข้อมูลรายวันของทุกปัจจัย (เช่น ราคาทองคำ, ราคาน้ำมัน, ดัชนีหุ้น) มาเลื่อนเวลา (Shift) ย้อนหลัง ตามจำนวนวันที่กำหนด (Lag Days) เช่น Lag 1 หมายถึงการใช้ข้อมูลของ "เมื่อวาน" เพื่อทำนาย "วันนี้"

ผลจากการดำเนินการดังกล่าว ทำให้ชุดข้อมูลที่ใช้ฝึกสอนประกอบด้วยตัวแปร Lag ทั้งหมด และไม่มีตัวแปรของวันปัจจุบันปะปนอยู่ (No Look-ahead Bias)

4.2.3 ผลการแบ่งชุดข้อมูล (Data Splitting)

ข้อมูลถูกแบ่งออกเป็น 3 ส่วนตามลำดับเวลา (Chronological Split) เพื่อจำลองสถานการณ์การพยากรณ์จริง โดยอ้างอิงจากช่วงเวลาของข้อมูลที่มีอยู่จริง (2016-2026) ดังสรุปในตารางที่ 4.2

ตารางที่ 4.2: สรุปจำนวนข้อมูลและช่วงเวลาของชุดข้อมูล (Dataset Splits)

ชุดข้อมูล (Dataset)	สัดส่วนโดยประมาณ	ช่วงวันที่ (Period)	จำนวนตัวอย่าง (Samples)
Training Set	70%		
Validation Set	15%		
Testing Set	15%		

4.3 ผลการฝึกและปรับแต่งตัวแบบพยากรณ์ (Training & Tuning Results)

การทดลองนี้ได้ดำเนินการฝึกสอนและปรับแต่งพารามิเตอร์ (Hyperparameter Tuning) ของตัวแบบทั้งกลุ่ม Baseline, Machine Learning และ Deep Learning โดยใช้ข้อมูลชุด Training (70%) สำหรับเรียนรู้ และ Validation (15%) สำหรับการปรับปรุง เพื่อวัดผลประสิทธิภาพบนชุด Testing (15%) ที่ไม่เคยถูกใช้งานมาก่อน ผลการทดลองจำแนกตามรายโมเดลมีดังนี้

4.3.1 ผลการฝึกตัวแบบฐาน (Baseline Models)

เพื่อให้การประเมินประสิทธิภาพของโมเดลเชิงเรียนรู้มีความน่าเชื่อถือ งานวิจัยนี้กำหนด **ตัวแบบฐาน (Baseline)** สำหรับการพยากรณ์ราคาทองคำล่วงหน้า 1 วัน ($t+1$) จำนวน 3 วิธี ได้แก่ **Naïve (Random Walk/NaivePrice)**, **Moving Average (MA)** และ **ARIMA**

4.3.1.1 Naïve

แนวคิดของตัวแบบฐาน Naïve (Random Walk) คือการพยากรณ์ราคาวันถัดไปให้เท่ากับราคาวันปัจจุบัน

($\hat{y}_{t+1} = y_t$) ซึ่งเป็น baseline มาตรฐานสำหรับอนุกรมเวลาที่มีความต่อเนื่อง

ตาราง 4.xx ผลการประเมิน Naïve baseline (Random Walk) บนชุด Train/Validation/Test

Target Variable	Model	Train (n=1,729)				Validation (n=383)				Test (n=384)			
		RMSE	MAE	MAPE	R ²	RMSE	MAE	MAPE	R ²	RMSE	MAE	MAPE	R ²
Gold_Close	Naive												
	Price	14.8265	9.9418	0.6344	0.9968	18.0577	13.2107	0.6366	0.9887	41.8591	28.9609	0.8774	0.9951
Gold_High	Naive												
	Price	13.8937	9.4783	0.6059	0.9972	17.6761	12.4705	0.6004	0.9894	35.6232	24.8633	0.7483	0.9965
Gold_Low	Naive												
	Price	13.832	9.3014	0.5978	0.9972	16.3324	11.8292	0.5753	0.9905	35.929	26.1229	0.7966	0.9963

ผลการทดลองพบว่า Naïve baseline ให้ค่าความคลาดเคลื่อน (RMSE/MAE) อยู่ในระดับต่ำมากเมื่อเทียบกับสเกลของราคา และให้ค่า R^2 สูงในทุก target สะท้อนลักษณะของอนุกรมเวลา “ราคาทองคำรายวัน” ที่มีความต่อเนื่องสูง (high persistence) กล่าวคือ ราคาวันถัดไปมักใกล้เคียงราคาวันปัจจุบัน ทำให้การทำนายแบบ Random Walk เป็น baseline ที่แข็งแกร่งและเหมาะสมต่อการใช้เป็นเกณฑ์อ้างอิง (benchmark) ในการยืนยันว่าโมเดลเชิงเรียนรู้ (เช่น XGBoost, LSTM) ให้ประโยชน์เพิ่มขึ้นจริง ไม่ใช่เพียงการ “ตามราคาเดิม”

อย่างไรก็ตาม เมื่อพิจารณาชุดทดสอบ (Test) พบว่า RMSE เพิ่มขึ้นอย่างชัดเจนในทุกตัวแปร (Gold_Close = 41.8591, Gold_High = 35.6232, Gold_Low = 35.9290) สะท้อนว่าช่วงเวลาทดสอบอาจมีความผันผวน/การเปลี่ยนแปลงระดับราคาแรงกว่าช่วง Train/Val ซึ่งเป็นพฤติกรรมปกติของข้อมูลการเงิน และเป็นเหตุผลสำคัญที่งานวิจัยควรเปรียบเทียบโมเดลกับ baseline ที่เข้มแข็งในชุด Test เพื่อยืนยันความสามารถในการทั่วไป (generalization) ภายใต้สภาวะตลาดที่เปลี่ยนแปลง

4.3.1.2 Moving Aveerage (MA)

แนวคิดของ MA คือการทำนายราคาวัดไปด้วยค่าเฉลี่ยย้อนหลัง w วัน การแบ่งข้อมูลใช้ time-based split ตามลำดับเวลาเป็น Train/Validation/Test เท่ากับ 70% / 15% / 15% ทั้งนี้การเลือกหน้าต่าง MA (w) ทำโดย ปรับค่าพารามิเตอร์จากชุด Validation เท่านั้น จาก $w \in \{5,10,20,50,100,200\}$ และเลือก w ที่ให้ค่า Validation RMSE ต่ำสุด

ตารางที่ 4.xx สรุปผลการพยากรณ์ด้วย Moving Average (MA) (Train/Validation/Test)

Target Variable	Best Window	Train (n=1,729)				Validation (n=383)				Test (n=384)			
		RMSE	MAE	MAPE	R ²	RMSE	MAE	MAPE	R ²	RMSE	MAE	MAPE (%)	R ²
Gold_Close	5	21.7132	15.4515	0.9938	0.9931	26.086	20.0667	0.9693	0.9764	58.9283	44.9688	1.3516	0.9903
Gold_High	5	21.5513	15.3911	0.9849	0.9934	26.8409	20.4603	0.987	0.9755	59.7155	45.2447	1.3432	0.9902
Gold_Low	5	21.4825	15.1001	0.9751	0.9931	24.962	19.4288	0.9438	0.9777	55.5084	42.6834	1.2916	0.9912

จากการวิเคราะห์ผลการทดสอบตัวแบบ Moving Average (MA) พบข้อสังเกตที่สำคัญประการแรกในด้านการกำหนดพารามิเตอร์หน้าต่างเวลา (Window Size) โดยพบว่าค่า $w=5$ ให้ผลลัพธ์ที่เหมาะสมที่สุดสำหรับทุกตัวแปรเป้าหมาย สิ่งนี้สะท้อนให้เห็นว่าสำหรับสินทรัพย์ที่มีความผันผวนสูงเช่นทองคำ การใช้ข้อมูลค่าเฉลี่ยย้อนหลังในระยะสั้นมีประสิทธิภาพในการพยากรณ์ดีกว่าการใช้หน้าต่างเวลาที่ยาวนาน เช่น 10–200 วัน ซึ่งมักส่งผลให้ตัวแบบเกิดความเฉื่อย (Lag) และตอบสนองต่อการเปลี่ยนแปลงของราคาได้ล่าช้าอย่างมีนัยสำคัญ เมื่อเปรียบเทียบประสิทธิภาพระหว่างชุดข้อมูล พบว่าค่าความคลาดเคลื่อน RMSE และ MAE ในชุดทดสอบ (Test Set) ปรับตัวสูงขึ้นอย่างมีนัยสำคัญเมื่อเทียบกับชุดข้อมูลฝึกสอน (Train) และชุดตรวจสอบ (Validation) ยกตัวอย่างเช่น กรณี Gold_Close ค่า RMSE ในชุดตรวจสอบอยู่ที่ประมาณ 26.09 แต่เพิ่มขึ้นเป็น 58.93 ในชุดทดสอบ ปรากฏการณ์นี้บ่งชี้ถึงความเป็นไปได้ที่จะเกิดการเปลี่ยนแปลงโครงสร้างพฤติกรรมของราคา (Regime Change) หรือการกระจุกตัวของความผันผวน (Volatility Clustering) ในช่วงเวลาทดสอบ ซึ่งถือเป็นข้อจำกัดตามธรรมชาติของตัวแบบพื้นฐานอย่าง MA ที่อาศัยเพียงข้อมูลราคาย้อนหลังของตนเองในการพยากรณ์

4.3.1.3 AutoRegressive Integrated Moving Average (ARIMA)

การประเมินตัวแบบ ARIMA ในการพยากรณ์ราคาทองคำดำเนินการด้วยวิธี Walk-forward validation (one-step ahead) เพื่อให้สอดคล้องกับลักษณะอนุกรมเวลาที่มีการไหลของข้อมูลตามเวลา

ในขั้นตอนปรับแต่งพารามิเตอร์ (tuning) ได้ทำการค้นหาแบบ grid search ภายในช่วงค่า $p \in \{0,1,2\}$, $d \in \{1,2\}$, $q \in \{1,2\}$ รวม 12 ชุดค่าพารามิเตอร์ และเลือกค่าที่ให้ผลดีที่สุดบน Validation ตามเกณฑ์ MSE โดยผลการทดลองพบว่า ทั้งสามเป้าหมาย (Gold_Close, Gold_High, Gold_Low) ได้พารามิเตอร์ที่เหมาะสมเหมือนกัน คือ ARIMA(0,1,1)

ตารางที่ 4.x สรุปผลการฝึกและทดสอบตัวแบบ ARIMA ด้วยวิธี Walk-forward (Train/Val/Test)

Target Variable	Best Parameter (p, d, q)	Train (n=1,729)				Validation (n=383)				Test (n=384)			
		RMSE	MAE	MAPE	R ²	RMSE	MAE	MAPE	R ²	RMSE	MAE	MAPE	R ²
Gold_Close	(0, 1, 1)	14.8483	9.9585	0.6355	0.9968	18.0501	13.2054	0.6364	0.9887	41.9126	29.0022	0.8788	0.9951
Gold_High	(0, 1, 1)	13.8895	9.4907	0.6069	0.9972	17.6537	12.5803	0.6057	0.9894	35.0903	24.5087	0.7377	0.9966
Gold_Low	(0, 1, 1)	13.8102	9.2731	0.5962	0.9972	16.3493	11.8623	0.5769	0.9904	35.9294	26.1921	0.7983	0.9963

ผลการประเมินตัวแบบ ARIMA ด้วยวิธี Walk-forward พบว่าโมเดลที่เหมาะสมที่สุดสำหรับทั้งสามเป้าหมายคือ ARIMA(0,1,1) ซึ่งสะท้อนว่าอนุกรมเวลาราคาในชุดข้อมูลมีลักษณะไม่อยู่กับที่ (non-stationary) และต้องอาศัยการทำ differencing หนึ่งครั้ง ($d=1$) โดยใช้โครงสร้างค่าเฉลี่ยเคลื่อนที่ระดับหนึ่ง ($q=1$) เพื่ออธิบายส่วนของความคลาดเคลื่อนในอดีต

เมื่อพิจารณาค่าความคลาดเคลื่อน พบว่า Train และ Validation ให้ค่า RMSE อยู่ในระดับใกล้เคียงกัน แสดงว่าโมเดลสามารถเรียนรู้รูปแบบในอดีตและยังคงทำงานได้พอสมควรบนช่วง Validation อย่างไรก็ตาม เมื่อประเมินบนชุดทดสอบ (Test) พบว่า ค่า RMSE เพิ่มขึ้นอย่างชัดเจน ในทุกเป้าหมาย สะท้อนว่าในช่วงเวลาทดสอบอาจมีการเปลี่ยนแปลงโครงสร้างของข้อมูล (regime change) หรือมีความผันผวนสูงขึ้น ส่งผลให้แบบจำลองเชิงเส้นอย่าง ARIMA มีข้อจำกัดในการตามทันสภาวะตลาดที่เปลี่ยนไป

4.3.2 ผลการฝึกตัวแบบ Linear Regression (OLS) + Stepwise Selection

แบบจำลองนี้ใช้ **OLS Regression** ร่วมกับ **Stepwise Selection** (คัดเลือกตัวแปรด้วย p-value) โดยทำ **การแปลงตัวแปรเป้าหมายเป็น Log Return** ก่อนฝึก และเมื่อทำนายจะ **แปลงกลับเป็นราคา (Reconstruct to Price)**

ตารางที่

Target Variable	Step wise	Train (n=1,727)				Validation n (n=383)				Test (n=384)			
		RMSE	MAE	MAPE	R ²	RMSE	MAE	MAPE	R ²	RMSE	MAE	MAPE	R ²
Gold_Close	Silver_Price_USD_lag1	14.9088	10.1123	0.6445	0.9968	18.0979	13.2889	0.6399	0.9886	41.8649	29.0265	0.8805	0.9951
Gold_High	Gold_Volume_lag1, Gold_High_lag1	13.8605	9.4653	0.6059	0.9972	17.5389	12.3412	0.5943	0.9895	34.8951	24.2968	0.7313	0.9967
Gold_Low	Gold_Volume_lag1, Gold_Low_lag1	13.8047	9.2621	0.5959	0.9972	16.2857	11.7888	0.5738	0.9905	35.6427	25.8876	0.7898	0.9964

ผลการทดลอง OLS ร่วมกับ Stepwise (p-value) ภายใต้การแปลงเป้าหมายเป็น log return พบว่าโมเดลเลือกตัวแปรจำนวนไม่มาก โดยส่วนใหญ่เป็นตัวแปร lag ของราคาและปริมาณซื้อขาย ซึ่งสะท้อนลักษณะ persistence ของอนุกรมเวลาและความซับซ้อนสูงของกลุ่ม OHLC lag features

Stepwise มีแนวโน้มเลือกฟีเจอร์น้อย เมื่อ (i) เกณฑ์ p-value เข้ม (เข้า <0.01) และ (ii) ฟีเจอร์มีความซับซ้อนกันสูง (multicollinearity) โดยเฉพาะกลุ่ม OHLC lag1 ที่สัมพันธ์กันมาก ทำให้โมเดลมักเลือก “ตัวแทน” เพียง 1–2 ตัวที่อธิบายได้ดีที่สุด เช่น Gold_High_lag1 / Gold_Low_lag1 และในกรณี Gold_Close ตัวที่โดดเด่นในชุด Train คือ Silver_Price_USD_lag1 ซึ่งเป็นสินทรัพย์ที่มีความเชื่อมโยงกับทองคำเชิงตลาด (precious metals linkage)

4.3.3 ผลการฝึกตัวแบบ XGBoost Regression + Hyperparameter Tuning (Optuna)

งานวิจัยนี้ประเมินแบบจำลอง **XGBoost Regressor** สำหรับการพยากรณ์ราคาทองคำล่วงหน้า 1 วัน ($t+1$) โดยทดสอบจำนวนวันล่าช้า (lag_days) ของตัวแปรอธิบายจำนวน 3 ค่า ได้แก่ 1, 3 และ 5 วัน การปรับแต่งพารามิเตอร์ทำด้วย **Optuna** จำนวน 120 trials และใช้แนวทาง **early stopping** เพื่อควบคุมการเกิด overfitting และเพิ่มเสถียรภาพของโมเดล

4.3.3.1 สรุปผลการทดลอง เปรียบเทียบ lag_days ของแต่ละ Target (Train/Validation/Test)

(1) Gold_Close

ตารางที่ 4.xx ผลการพยากรณ์ Gold_Close ด้วย XGBoost เมื่อเปลี่ยนค่า lag_days

Lag Days	Train Set					Validation (n=383)				Test (n=384)			
	n	RMSE	MAE	MAPE (%)	R ²	RMSE	MAE	MAPE (%)	R ²	RMSE	MAE	MAPE (%)	R ²
1	1,787	14.8364	9.9723	0.6433	0.9968	18.024	13.1948	0.6362	0.9887	41.6682	28.7676	0.8717	0.9951
3	1,785	14.8398	9.9701	0.6429	0.9968	18.0245	13.1939	0.6361	0.9887	41.6713	28.7719	0.8719	0.9951
5	1,783	14.8453	9.9791	0.6433	0.9968	18.0276	13.1952	0.6362	0.9887	41.6778	28.7793	0.8721	0.9951

จากตารางที่ ผลลัพธ์ของ lag_days ทั้ง 3 ค่าแตกต่างกันน้อยมาก และเมื่อเลือกตาม **Validation RMSE ต่ำสุด** พบว่า **lag_days = 1** เหมาะสมที่สุด

(2) Gold_High

ตารางที่ 4.xx ผลการพยากรณ์ Gold_High ด้วย XGBoost เมื่อเปลี่ยนค่า lag_days

Lag Days	Train Set					Validation (n=383)				Test (n=384)			
	n	RMSE	MAE	MAPE	R²	RMSE	MAE	MAPE	R²	RMSE	MAE	MAPE	R²
1	1,787	13.9346	9.5459	0.6169	0.9972	17.6462	12.456	0.5999	0.9894	35.4006	24.7372	0.7447	0.9966
3	1,785	13.9387	9.5462	0.6166	0.9972	17.6465	12.4565	0.6	0.9894	35.4055	24.7397	0.7447	0.9966
5	1,783	13.9042	9.5554	0.6171	0.9973	17.6463	12.456	0.5999	0.9894	35.4031	24.738	0.7447	0.9966

จากตารางที่ ค่า error ใกล้เคียงกันทุก lag_days และเมื่อเลือกตาม Validation RMSE ต่ำสุด พบว่า lag_days = 1 เหมาะสมที่สุด

(3) Gold_Low

ตารางที่ 4.xx ผลการพยากรณ์ Gold_Low ด้วย XGBoost เมื่อเปลี่ยนค่า lag_days

Lag Days	Train Set					Validation (n=383)				Test (n=384)			
	n	RMSE	MAE	MAPE (%)	R²	RMSE	MAE	MAPE (%)	R²	RMSE	MAE	MAPE (%)	R²
1	1,787	13.8093	9.3045	0.6042	0.9972	16.2988	11.8158	0.5751	0.9905	35.7174	25.8389	0.7884	0.9964
3	1,785	13.8122	9.3076	0.6042	0.9972	16.2984	11.814	0.5749	0.9905	35.7206	25.8427	0.7885	0.9964
5	1,783	13.8222	9.308	0.6042	0.9972	16.2967	11.8184	0.5752	0.9905	35.7183	25.8392	0.7885	0.9964

จากตารางที่ แม้ Gold_Low จะได้ค่า RMSE ต่ำสุดที่ lag_days=5 แต่ส่วนต่างเมื่อเทียบกับ lag_days=1 มีขนาดเล็กมากและไม่ส่งผลกระทบต่อผลของระบบ ดังนั้นเพื่อความสอดคล้องของระบบ ลดความซับซ้อน และเพิ่มความเร็วในการนำไปใช้งานจริง งานวิจัยจึงเลือกใช้ lag_days=1 สำหรับทุก target

4.3.3.2 สรุปโมเดลที่เลือกใช้ (Best by Validation RMSE)

จากเกณฑ์ RMSE ต่ำสุด จึงเลือกโมเดลสุดท้ายดังนี้

Gold_Close: lag_days = 1

Gold_High: lag_days = 1

Gold_Low: lag_days = 1

แม้ผลการปรับแต่งพารามิเตอร์จะพบว่า lag_days = 5 ให้ค่า Validation RMSE ต่ำที่สุด สำหรับ Gold_Low แต่ความแตกต่างเมื่อเทียบกับ lag_days = 1 มีขนาดเล็กมาก ต่างกันเพียงประมาณ 0.0021 หน่วย RMSE หรือราว 0.013% ของค่า RMSE บน Validation และเมื่อพิจารณาผลบนชุดทดสอบ (Test) พบว่า ค่า Test RMSE ของ lag=1 และ lag=5 ต่างกันเพียงประมาณ 0.0009 หน่วย สะท้อนว่าผลประโยชน์จากการใช้ lag ที่ยาวกว่าในกรณี Gold_Low มีน้อยมาก

ดังนั้น งานวิจัยจึงเลือกใช้ lag_days = 1 สำหรับ Gold_Low เพื่อให้สอดคล้องกับ Gold_Close และ Gold_High และเพื่อเพิ่มความเหมาะสมเชิงระบบ (system-level suitability) โดยมีเหตุผลหลักดังนี้

(1) ความสอดคล้องของสถาปัตยกรรมและการดูแลรักษาระบบ (Consistency / Maintainability)

การกำหนด lag ให้เหมือนกันทุก target ทำให้กระบวนการสร้างฟีเจอร์ การ deploy และการอัปเดตข้อมูลรายวันเป็นมาตรฐานเดียว ลดความซับซ้อนของ pipeline และลดความเสี่ยงของข้อผิดพลาดที่เกิดจากการมี logic หลายรูปแบบในระบบจริง ซึ่งสอดคล้องกับแนวปฏิบัติในกรอบคิด MLOps ที่เน้น “ความน่าเชื่อถือและการทำงานซ้ำได้ของระบบ ML” ผ่านการทำงานแบบอัตโนมัติและมาตรฐานเดียวกัน (Google Cloud, 2024; Salama et al., 2021)

(2) หลักความเรียบง่ายของแบบจำลอง (Parsimony) และการลดความเสี่ยง overfitting

เมื่อความแตกต่างของผลลัพธ์มีขนาดเล็กมาก การเลือกโครงสร้างฟีเจอร์ที่เรียบง่ายกว่า (ใช้ lag สั้นกว่า) เป็นการตัดสินใจตามหลัก parsimony และสอดคล้องกับแนวคิด bias-variance tradeoff ที่ชี้ว่า “ความซับซ้อนที่เพิ่มขึ้น” อาจเพิ่มความแปรปรวนและนำไปสู่ overfitting ได้ โดยเฉพาะในข้อมูลการเงินที่มี noise และสถานะตลาดเปลี่ยนแปลงได้ (Hastie et al., 2009)

(3) ต้นทุนคำนวณและ latency ที่ต่ำลง เหมาะกับการใช้งานเชิงระบบ

การใช้ lag=1 ทำให้จำนวนฟีเจอร์และการประมวลผลลดลง ส่งผลให้การอัปเดตระบบ (retrain/refresh) และการพยากรณ์ทำได้รวดเร็วขึ้น ซึ่งเป็นปัจจัยสำคัญในระบบที่ต้องการความทันเวลา และโดยทั่วไปการลดความซับซ้อนของงานอนุมาน (inference) เป็นแนวทางหลักในการลด latency ของระบบโมเดล (OpenAI, n.d.)

(4) การตัดสินใจแบบ system-optimized แทน metric-optimized

ด้วยเป้าหมายของงานวิจัยที่ต้องการระบบพยากรณ์ที่ใช้งานได้จริง มีความสม่ำเสมอ และดูแลรักษาได้ง่าย การเลือกพารามิเตอร์จึงพิจารณาความคุ้มค่าเชิงระบบร่วมกับ metric เมื่อ improvement บน validation มีขนาดเล็กมากและไม่ชัดเจนบน test จึงเลือกค่า lag ที่ทำให้ระบบมีมาตรฐานเดียวทั้ง pipeline (Google Cloud, 2024; Salama et al., 2021)

4.3.3.3 รายงานพารามิเตอร์ที่ดีที่สุดของโมเดลที่ถูกเลือก (Best Hyperparameters)

ตารางที่ 4.xx Best Hyperparameters ของ XGBoost (Selected model per Target)

Target Variable (Lag)	max_depth	learning_rate	subsample	colsample_bytree	min_child_weight	gamma	reg_alpha	reg_lambda
Gold_Close (lag=1)	6	0.1736	0.6966	0.8863	13.7848	3.1462	0.0000735	0.0000012
Gold_High (lag=1)	9	0.0271	0.7144	0.7676	9.7401	2.9433	1.90E-08	0.004248
Gold_Low (lag=1)	3	0.1994	0.6157	0.6642	10.1460	4.9639	0.0000295	0.0000117

จากการวิเคราะห์ค่าพารามิเตอร์ที่เหมาะสมที่สุด (Hyperparameters) สำหรับแต่ละตัวแปรเป้าหมาย พบประเด็นสำคัญที่สะท้อนถึงโครงสร้างข้อมูลที่แตกต่างกัน โดยเฉพาะในด้าน **ความซับซ้อนของตัวแบบ (Model Complexity)** พบว่าตัวแปร **Gold_High** ต้องการค่าความลึกของต้นไม้ (max_depth) สูงถึง 9 ระดับ ซึ่งบ่งชี้ว่าพฤติกรรมของราคาสูงสุดมีความซับซ้อนสูง จึงจำเป็นต้องใช้อัตราการเรียนรู้ (learning_rate) ในระดับต่ำเพียง 0.0271 เพื่อให้กระบวนการปรับจูนน้ำหนักเป็นไปอย่างละเอียดและค่อยเป็นค่อยไป ซึ่งเป็นการป้องกันปัญหาการเรียนรู้เกิน (Overfitting) ที่มักเกิดกับโครงสร้างต้นไม้ที่มีความลึกมาก ในทางตรงกันข้าม **Gold_Low** กลับมีประสิทธิภาพสูงสุดเมื่อใช้โครงสร้างต้นไม้แบบตื้น (Shallow Tree) ที่ความลึกเพียง 3 ระดับ ซึ่งอาจเกิดจากรูปแบบของราคาต่ำสุดมีความซับซ้อนน้อยกว่า หรือเพื่อหลีกเลี่ยงความเสี่ยงต่อการ Overfitting จึงสามารถใช้อัตราการเรียนรู้ในระดับปานกลาง (ประมาณ 0.17 - 0.20) เช่นเดียวกับ **Gold_Close** เพื่อให้ตัวแบบเข้าสู่ค่าตอบได้รวดเร็วยิ่งขึ้น

นอกจากนี้ ในด้าน **เสถียรภาพและการควบคุมความแปรปรวน (Stability & Regularization)** ตัวแบบทั้งหมดยังแสดงลักษณะร่วมกันในการกำหนดค่า **min_child_weight** ไว้ในระดับค่อนข้างสูง (ระหว่าง 9.7 - 13.8) ซึ่งเป็นกลไกสำคัญที่ช่วยป้องกันไม่ใหตัวแบบสร้างโหนดใหม่จากจำนวนข้อมูลตัวอย่างที่น้อยเกินไป ส่งผลให้ตัวแบบมีความทนทานและลดความอ่อนไหวต่อข้อมูลที่เป็นสัญญาณรบกวน (Noise) หรือค่าผิดปกติ (Outliers) ได้ดียิ่งขึ้น สอดคล้องกับการกำหนดค่า **gamma** (เกณฑ์ขั้นต่ำในการลดค่าความสูญเสีย) ไว้ในช่วง 2.9 - 4.9 ซึ่งถือเป็นมาตรการตัดแต่งกิ่ง (Pruning) ที่มีความเข้มงวด เพื่อให้มั่นใจว่าตัวแบบที่สร้างขึ้นจะมีความสามารถในการทำนายข้อมูลชุดใหม่ได้อย่างมีประสิทธิภาพ (Generalization) ในสถานการณ์จริง

4.4 Shap

4.5 web

4.6 ผลแบบสอบถาม

4.3.1 ผลการฝึกตัวแบบฐาน (Baseline Models)

เพื่อใช้เป็นเกณฑ์มาตรฐานในการเปรียบเทียบประสิทธิภาพ งานวิจัยได้ทดสอบตัวแบบพื้นฐาน 2 ประเภท ได้แก่:

1. **ARIMA (AutoRegressive Integrated Moving Average):** ใช้สำหรับการพยากรณ์อนุกรมเวลาเชิงเส้น โดยกำหนดพารามิเตอร์ (p, d, q) ที่เหมาะสมที่สุดจากการวิเคราะห์ค่า AIC/BIC
2. **Linear Regression (OLS):** ใช้ตัวแปร Lag Features ชุดเดียวกับที่เตรียมให้ Machine Learning เพื่อทดสอบความสัมพันธ์เชิงเส้นตรงของข้อมูล

ตารางที่ 4.4: ประสิทธิภาพของตัวแบบฐาน (Baseline) บนชุดข้อมูลทดสอบ

ราคาสูงสุด

โมเดล (Model)	MSE	RMSE	MAE	MAPE	R ²
ARIMA	1031.4794	32.1166	22.7824	0.7219	0.9964
Linear Regression	733.9386	27.0913	19.9782	0.6339	0.9974

ราคาต่ำสุด

โมเดล (Model)	MSE	RMSE	MAE	MAPE	R ²
ARIMA	1076.0213	32.8027	23.6596	0.7533	0.9962
Linear Regression	939.5230	30.6516	22.0574	0.7055	0.9966

ราคาปิด

โมเดล (Model)	MSE	RMSE	MAE	MAPE	R ²
ARIMA	1497.02416	38.69139	26.9650	0.8579	0.9948

Linear Regression	1521.459	39.0058	27.2420	0.8661	0.9946
----------------------	----------	---------	---------	--------	--------

4.3.2 ผลการฝึก XGBoost (Extreme Gradient Boosting)

ตัวแบบ XGBoost ถูกฝึกสอนด้วยข้อมูล **Log Returns** เพื่อลดปัญหาความไม่นิ่งของข้อมูล (Non-stationary) โดยใช้ฟังก์ชันสูญเสียแบบ `reg:squarederror` และปรับจูนพารามิเตอร์ด้วย Optuna ผลการทดสอบพบว่า XGBoost สามารถจับจังหวะการเปลี่ยนแปลงของราคาได้ดี โดยเฉพาะในช่วงที่มีความผันผวนสูง

Lag ที่เลือกใช้: Lag [...ดูใน metrics_XGB...] วัน

Early Stopping: หยุดการฝึกเมื่อค่า Loss บน Validation Set ไม่ลดลงติดต่อกัน [...ดู early_stopping_rounds...]

รอบ

ผลลัพธ์บนชุดทดสอบ (Test Set):

RMSE: [...ใส่ค่า RMSE...] USD

MAPE: [...ใส่ค่า MAPE...] %

4.3 ผลการพัฒนาและประเมินประสิทธิภาพโมเดล (Model Evaluation Results)

ในการทดลองนี้ ได้เปรียบเทียบประสิทธิภาพของโมเดล Machine Learning จำนวน โมเดล ได้แก่ **Linear Regression**, **LightGBM**, และ **XGBoost Regressor** ทำการวัดผลด้วยค่าสถิติ ด้าน คือ Mean Absolute Error (MAE), Root Mean Squared Error (RMSE), และ R-squared (R^2)

ผลการทดสอบประสิทธิภาพบนข้อมูลชุดทดสอบ (Test Set) ปรากฏผลดังตารางที่ 4.1

High

โมเดล (Model)	MSE	RMSE	MAE	MAPE	R^2
ARIMA	1031.4794	32.1166	22.7824	0.7219	0.9964
XGBoost	2052.1526	45.3006	32.1428	1.0042	0.9930
LSTM	1495.26	38.67	26.45	0.81	0.995
Linear Regression	733.9386	27.0913	19.9782	0.6339	0.9974
LightGBM	3805.1362	61.6857	43.1097	1.3121	0.9870

Low

โมเดล (Model)	MSE	RMSE	MAE	MAPE	R ²
ARIMA	1076.0213	32.8027	23.6596	0.7533	0.9962
XGBoost	1980.1414	44.4987	33.1096	1.0479	0.9928
LSTM					
Linear Regression	939.5230	30.6516	22.0574	0.7055	0.9966
LightGBM	3156.3328	56.1812	40.3672	1.2566	0.9886

Close

โมเดล (Model)	MSE	RMSE	MAE	MAPE	R ²
ARIMA	1497.02416	38.69139	26.9650	0.8579	0.9948
XGBoost	2560.0734	50.5971	37.7239	1.19731	0.99105
LSTM					
Linear Regression	1521.459	39.0058	27.2420	0.8661	0.9946
LightGBM	3727.8568	61.0561	44.6430	1.38953	0.98697

อ้างอิง

- Chandar, S., Govindasamy, V., and Sharma, K. (2020). Forecasting gold price using hybrid ELM and ARIMA models with macroeconomic variables. *International Journal of Emerging Markets*, 15(5), 885–902. <https://doi.org/10.1108/IJOEM-02-2019-0157>
- Federal Reserve Bank of Chicago. (2013). Is gold a hedge against inflation? Retrieved from <https://www.chicagofed.org>
- Jabeur, S. B., Mefteh-Wali, S., and Viviani, J. L. (2024). Forecasting gold price with the XGBoost algorithm and SHAP interaction values. *Annals of Operations Research*, 334, 679–699. <https://doi.org/10.1007/s10479021-04187-w>
- Li, Y. (2024). A comparative study of XGBoost and deep learning for gold price prediction. *Finance and Technology Review*, 8(2), 110–127
- Shafiee, S., and Topal, E. (2010). An overview of global gold market and gold price forecasting. *Resources Policy*, 35(3), 178–189. <https://doi.org/10.1016/j.resourpol.2010.05.004>

- Wang, Y., Wang, L., and Li, Y. (2023). Macro-financial variables and gold price dynamics: Evidence from explainable machine learning. *Resources Policy*, 85, 103563.
<https://doi.org/10.1016/j.resourpol.2023.103563>
- Weng, B., Ahmed, M. U., and Megahed, F. M. (2020). Forecasting gold prices using machine learning models and economic indicators. *Expert Systems with Applications*, 157, 113477.
<https://doi.org/10.1016/j.eswa.2020.113477>
- Zhang, M., and Li, X. (2022). Comparison of machine learning models for precious metal price forecasting using walk-forward validation. *Journal of Forecasting*, 41(5), 846–860. <https://doi.org/10.1002/for.2807>
- Akhtaruzzaman, M., Boubaker, S., and Sensoy, A. (2021). Financial contagion during COVID–19 crisis. *Finance Research Letters*, 38, 101604. <https://doi.org/10.1016/j.frl.2020.101604>
- Baur, D. G., and McDermott, T. K. (2010). Is gold a safe haven? International evidence. *Journal of Banking and Finance*, 34(8), 1886–1898. <https://doi.org/10.1016/j.jbankfin.2009.12.008>
- Chen, T., and Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785–794).
<https://doi.org/10.1145/2939672.2939785>
- Dorogush, A. V., Ershov, V., and Gulin, A. (2018). CatBoost: Gradient boosting with categorical features support. *arXiv preprint arXiv:1810.11363*. <https://arxiv.org/abs/1810.11363>
- Guo, Y., Zhang, Y., Wang, Y., and Huang, W. (2024). A hybrid intelligent system for gold price forecasting: VMD-CEEMDAN-WOA-XGBoost model. *Applied Soft Computing*, 145, 110882.
- Hochreiter, S., and Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735–1780.
<https://doi.org/10.1162/neco.1997.9.8.1735>
- Ji, Q., Zhang, D., and Zhao, Y. (2020). Searching for safe-haven assets during the COVID-19 pandemic. *International Review of Financial Analysis*, 71, 101526. <https://doi.org/10.1016/j.irfa.2020.101526>
- Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., ... and Liu, T. Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems*, 30.
- Kushwaha, A., Purohit, H., and Joshi, R. (2023). A novel ensemble approach for forecasting gold prices using XGBoost and Random Forest. *Expert Systems with Applications*, 213, 119130.
- Lundberg, S. M., and Lee, S. I. (2017). A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems*, 30, 4765–4774.

- Montgomery, D. C., Peck, E. A., and Vining, G. G. (2021). Introduction to linear regression analysis (6th ed.). Wiley.
- Nagata, K., Yamamoto, Y., and Tanaka, S. (2024). Forecasting gold prices using LSTM neural networks with multi-frequency data. *Journal of Forecasting*, 43(1), 21–40.
- Philip Fliers. (2024). Is gold a safe haven in turbulent times? Economics Observatory.
<https://www.economicsobservatory.com>
- Shapley, L. S. (1953). A value for n-person games. In H. W. Kuhn and A. W. Tucker (Eds.), *Contributions to the Theory of Games II* (pp. 307–317). Princeton University Press.
- Willmott, C. J., and Matsuura, K. (2005). Advantages of the mean absolute error (MAE) over the root mean square error (RMSE) in assessing average model performance. *Climate Research*, 30(1), 79–82.
<https://doi.org/10.3354/cr030079>
- Zhang, M., and Li, X. (2022). Comparison of machine learning models for precious metal price forecasting using walk-forward validation. *Journal of Forecasting*, 41(5), 846–860. <https://doi.org/10.1002/for.2807>
- Parkinson, M. (1980). The extreme value method for estimating the variance of the rate of return. *Journal of Business*, 53(1), 61–65. <https://doi.org/10.1086/296071>
- Garman, M. B., & Klass, M. J. (1980). On the estimation of security price volatilities from historical data. *Journal of Business*, 53(1), 67–78. <https://doi.org/10.1086/296072>
- Investing.com. (2024). *Gold price technical analysis tools*. Retrieved from <https://www.investing.com>
- TradingView. (2024). *Gold (XAUUSD) price chart and technical indicators*. Retrieved from
<https://www.tradingview.com>
- Yahoo Finance. (2024). *Gold price (XAUUSD=X) and market data*. Retrieved from <https://finance.yahoo.com>
- WalletInvestor. (2025). *Gold price forecast and predictions using machine learning*. Retrieved from
<https://walletinvestor.com>
- Dalimunthe, R. A., Adek, R. T., & Agusniar, C. (2025). Gold price prediction using long-short term memory algorithm based on web application. *International Journal of Engineering, Science and Information Technology*, 5(1), 329–339. <https://doi.org/10.52088/ijesty.v5i1.724ijesty.org>
- Nurjananti, F. (2025). Website-based gold price movement prediction system using the long short-term memory (LSTM) method. *Journal of Research in Artificial Intelligence for Systems and Applications*, 1(2), 21–28. <https://doi.org/10.19184/raisa.v1i2.6257>

- Google Cloud. (2024). *MLOps: Continuous delivery and automation pipelines in machine learning* (Cloud Architecture Center; Last reviewed August 28, 2024).
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction* (2nd ed.). Springer.
- OpenAI. (n.d.). *Latency optimization* (OpenAI API documentation).
- Salama, K., Kazmierczak, J., & Schut, D. (2021). *Practitioners guide to MLOps: A framework for continuous delivery and automation of machine learning* (White paper). Google Cloud.

ภาคผนวก

ตารางการดำเนินโครงการ

	เทอม 1														เทอม 2																														
	June				July			August			September		October		November			December			January			February			March																		
กิจกรรม	1-Jun	7-Jun	14-Jun	21-Jun	28-Jun	5-Jul	12-Jul	19-Jul	26-Jul	2-Aug	9-Aug	16-Aug	23-Aug	30-Aug	6-Sep	13-Sep	20-Sep	27-Sep	4-Oct	11-Oct	18-Oct	25-Oct	1-Nov	8-Nov	15-Nov	22-Nov	29-Nov	6-Dec	13-Dec	20-Dec	27-Dec	3-Jan	10-Jan	17-Jan	24-Jan	31-Jan	7-Feb	14-Feb	21-Feb	28-Feb	7-Mar	14-Mar	21-Mar	28-Mar	
กำหนดหัวข้อโครงการ																																													
นำเสนอหัวข้อโครงการกับอาจารย์ที่ปรึกษา																																													
ศึกษาปัจจัยที่มีอิทธิพลต่อราคาทองคำ																																													
กำหนดวัตถุประสงค์																																													
กำหนดขอบเขตของงานวิจัยและปัจจัยที่ใช้ในการวิเคราะห์																																													
ระบุแหล่งข้อมูล																																													
ศึกษางานวิจัยที่																																													
นำเสนอความคืบหน้าอาจารย์ที่ปรึกษา																																													
สมัครและตั้งค่า FRED API Key																																													
พัฒนาข้อมูลระบบแบบเรียลไทม์																																													
พัฒนาประมวลผลข้อมูลเบื้องต้น																																													
จัดทำเค้าโครงบทที่ 1																																													
ตั้งค่าสภาพแวดล้อม (Python Virtual Environment)																																													

	เดือน 1																								เดือน 2																			
	June				July				August				September		October		November				December		January			February		March																
กิจกรรม	1-Jun	7-Jun	14-Jun	21-Jun	28-Jun	5-Jul	12-Jul	19-Jul	26-Jul	2-Aug	9-Aug	16-Aug	23-Aug	30-Aug	6-Sep	13-Sep	20-Sep	27-Sep	4-Oct	11-Oct	18-Oct	25-Oct	1-Nov	8-Nov	15-Nov	22-Nov	29-Nov	6-Dec	13-Dec	20-Dec	27-Dec	3-Jan	10-Jan	17-Jan	24-Jan	31-Jan	7-Feb	14-Feb	21-Feb	28-Feb	7-Mar	14-Mar	21-Mar	28-Mar

	รอบ 1														รอบ 2																													
	June		July		August		September		October		November		December		January		February		March																									
กิจกรรม	1-Jun	7-Jun	14-Jun	21-Jun	28-Jun	5-Jul	12-Jul	19-Jul	26-Jul	2-Aug	9-Aug	16-Aug	23-Aug	30-Aug	6-Sep	13-Sep	20-Sep	27-Sep	4-Oct	11-Oct	18-Oct	25-Oct	1-Nov	8-Nov	15-Nov	22-Nov	29-Nov	6-Dec	13-Dec	20-Dec	27-Dec	3-Jan	10-Jan	17-Jan	24-Jan	31-Jan	7-Feb	14-Feb	21-Feb	28-Feb	7-Mar	14-Mar	21-Mar	28-Mar

Preliminary data and results

1. ฟังก์ชันดึงข้อมูลอัตโนมัติ

The screenshot shows the GitHub Actions interface. On the left, the 'Actions' tab is selected, showing a list of workflows. The 'Daily Data Update' workflow is highlighted, with its file path '.github/workflows/daily-update.yml' and status 'Disabled'. On the right, the 'All workflows' tab is selected, displaying a list of 2,290 workflow runs. The runs are filtered by 'Event' (Scheduled), 'Status' (Completed), 'Branch' (main), and 'Actor' (github-actions[bot]). The runs are sorted by time, showing the most recent run at 12:10 PM. Each run entry includes a green checkmark, the workflow name 'Daily Data Update', the run number (e.g., #2282), the status 'Scheduled', the branch 'main', and the time taken (e.g., 1m 24s).

The screenshot shows the GitHub commit page for commit `cc9ebb2`. The commit was made by `github-actions[bot]` 11 minutes ago. The commit message is 'Automated daily data update'. The commit is linked to the parent commit `2b15ea2`. The file `gold_and_macro_data_final.csv` is shown as changed, with 1 file changed and 1 line changed. The diff shows a single line change in the file `gold_and_macro_data_final.csv`, where a new line was added at line 2559. The diff content is as follows:

```
@@ -2556,4 +2556,4 @@ Date,Crude_Oil_Price,US_Dollar_Index_DXY,Gold_Price_USD,Silver_Price_USD,Iron_Or
2556 2556 2025-10-27,61.310001373291016,98.77999877929688,4001.89990234375,46.5620002746582,105.56999969482422,6875.16015625,3.996999979019165,324.368
2557 2557 2025-10-28,60.150001525878906,98.69000244140625,3966.199951171875,47.125,105.55999755859375,6890.89013671875,3.9830000400543213,324.368
2558 2558 2025-10-29,60.47999954223633,99.22000122070312,3983.699951171875,47.72100067138672,105.66000366210938,6890.58984375,4.058000087738037,324.368
2559 - 2025-10-30,60.08000183105469,99.10099792480469,3984.699951171875,47.60499954223633,105.66000366210938,6890.58984375,4.058000087738037,324.368
2559 + 2025-10-30,59.93000030517578,99.12300109863281,3973.0,47.415000915527344,105.66000366210938,6890.58984375,4.058000087738037,324.368
```

2. Descriptive Statistics

Variable	Mean	Median	Maximum	Minimum	Std. Dev	Skewness	Kurtosis (excess)
Crude_Oil_Price	62.9946	63.2150	123.7000	-37.6300	17.8767	0.2439	0.5951
US_Dollar_Index_DXY	98.4739	97.6500	114.1100	88.5900	5.0437	0.3899	-0.4354
Gold_Price_USD	1735.45	1723.25	3542.00	1050.80	538.7860	1.2723	1.3880
Silver_Price_USD	21.3079	19.6725	41.4900	11.7350	5.8427	0.8261	-0.0146
Iron_Ore_Price	99.1416	97.4250	219.7700	38.5400	34.9025	0.9172	1.2378
SP500_Index	3617.14	3366.08	6501.86	1829.08	1208.49	0.5164	-0.7602
US_10Y_Treasury_Yield	2.6312	2.4185	4.9880	0.4990	1.1514	0.1776	-1.0347
Inflation_CPI	272.6348	259.6565	322.1320	237.3360	28.1507	0.4508	-1.3438

3. Correlation Matrix

	Crude_Oil_Price	US_Dollar_Index_DXY	Gold_Price_USD	Silver_Price_USD	Iron_Ore_Price	SP500_Index	US_10Y_Treasury_Yield	Inflation_CPI
Crude_Oil_Price	1	0.46**	0.38*	0.40*	0.47*	0.60**	0.58**	0.67**
US_Dollar_Index_DXY	0.46**	1	0.40*	0.27	0.01	0.45*	0.69**	0.66**
Gold_Price_USD	0.38*	0.40*	1	0.94**	0.43*	0.93**	0.54*	0.88**
Silver_Price_USD	0.40*	0.27	0.94**	1	0.55*	0.90**	0.45*	0.81**
Iron_Ore_Price	0.47*	0.01	0.43*	0.55*	1	0.56*	-0.01	0.47*
SP500_Index	0.60**	0.45*	0.93**	0.90**	0.56*	1	0.60**	0.94**
US_10Y_Treasury_Yield	0.58**	0.69**	0.54*	0.45*	-0.01	0.60**	1	0.75**
Inflation_CPI	0.67**	0.66**	0.88**	0.81**	0.47*	0.94**	0.75**	1

4. ตัวอย่างผลลัพธ์ของตัวแบบ


4.1 XGBoost

```

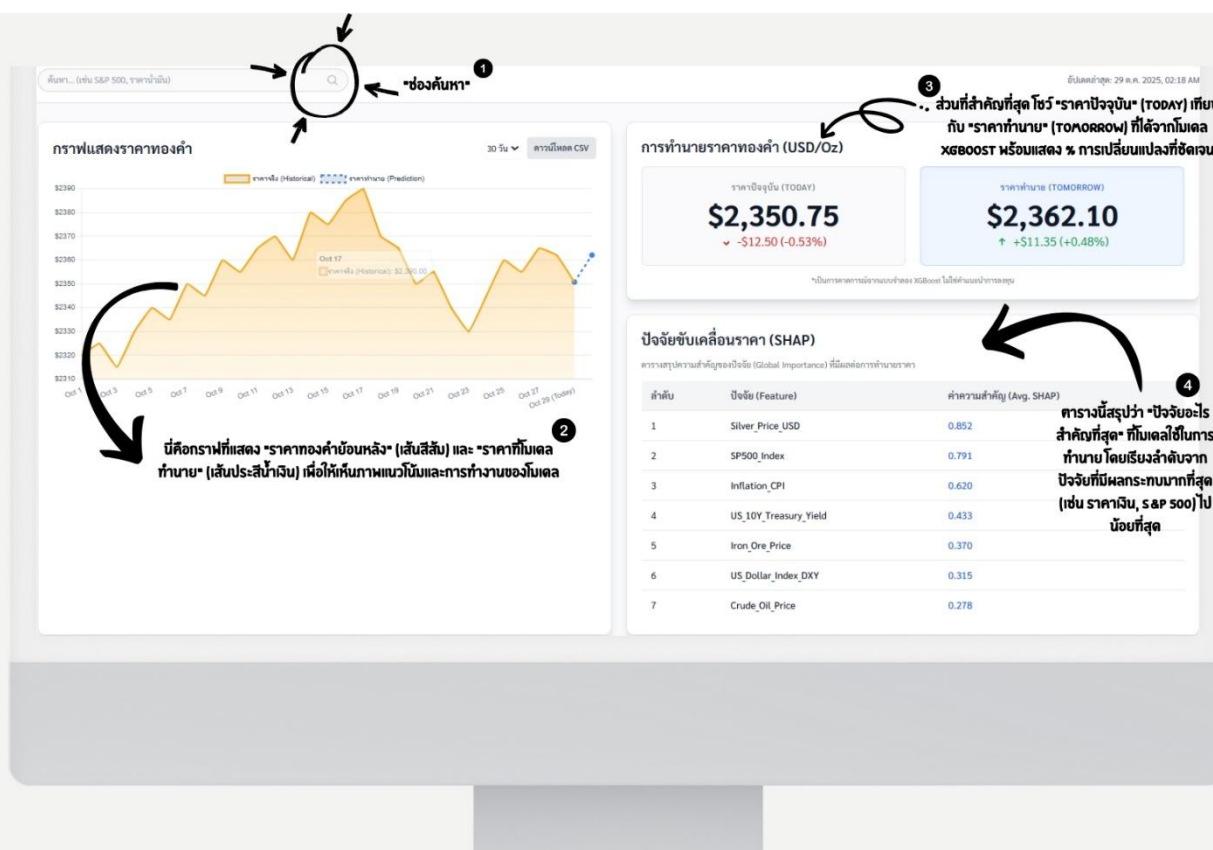
1  {
2    "train": {
3      "RMSE": 8.638194551546214,
4      "MAE": 6.744829669903293,
5      "R2": 0.998983124467477,
6      "MAPE": 0.4609633724757996
7    },
8    "val": {
9      "RMSE": 78.92024794416433,
10     "MAE": 62.87385005303521,
11     "R2": 0.568767663892002,
12     "MAPE": 3.1642150680768886
13   },
14   "test_walk_forward": {
15     "RMSE": 48.48961864812231,
16     "MAE": 36.78495979309082,
17     "R2": 0.9861201423914872,
18     "MAPE": 1.2802498008941012
19   },
20   "best_params": {
21     "max_depth": 4,
22     "learning_rate": 0.05,
23     "n_estimators": 600,
24     "subsample": 0.9,
25     "colsample_bytree": 0.9

```

4.2 กราฟ ผลพยากรณ์ราคาทองคำล่วงหน้า 1 วันแบบบนชุดทดสอบ ด้วยตัวแบบ XGBoost



5. ตัวอย่างเว็บไซต์ (Mock Up)



1. แถบข้อมูลด้านบน (Top Bar)

เป็นองค์ประกอบส่วนหัว (Header) ของพื้นที่แสดงเนื้อหาหลัก ทำหน้าที่ 2 ส่วนสำคัญ: 1) ช่องค้นหา (Search Bar) (จำลอง) เพื่อแสดงถึงศักยภาพในการต่อยอดการค้นหาสินทรัพย์อื่น และ 2) การแสดงเวลาอัปเดตข้อมูลล่าสุด (Data Timestamp) ซึ่งเป็นส่วนที่ขาดไม่ได้สำหรับแอปพลิเคชันด้านการเงิน เพื่อยืนยันความสดใหม่ (Recency) และสร้างความน่าเชื่อถือ (Credibility) ของข้อมูลที่แสดงผล

2. กราฟแสดงราคาทองคำ

ส่วนแสดงผลข้อมูลอนุกรมเวลา (Time Series Visualization) ที่เปรียบเทียบข้อมูล 2 ชุด: 1) ราคาทองคำที่เกิดขึ้นจริง (Actual Price) (เส้นทึบสีส้ม) และ 2) ราคาที่ตัวแบบ XGBoost พยากรณ์ (Predicted Price) (เส้นประสีน้ำเงิน) กราฟนี้ช่วยในการประเมินประสิทธิภาพของตัวแบบเชิงประจักษ์ (Visual Evaluation) ว่าสามารถจับทิศทางและแนวโน้ม (Trend) ของราคาได้แม่นยำเพียงใด

3. การทำนายราคาทองคำ

ส่วนแสดงผลหลัก (Key Output) ของโครงการ นำเสนอผลการพยากรณ์ราคาทองคำล่วงหน้า 1 วัน (1-Step Ahead Forecast) โดยแสดง 'ราคาปิดล่าสุด' (Latest Price) เทียบกับ 'ราคาที่ตัวแบบพยากรณ์' (Predicted Price) สำหรับวันทำการถัดไป พร้อมทั้งคำนวณเปอร์เซ็นต์ (ร้อยละ) การเปลี่ยนแปลง เพื่อให้ผู้ใช้สามารถตีความผลลัพธ์ได้อย่างรวดเร็ว

4. ปังจัยขับเคลื่อนราคา (SHAP)

ส่วนนี้แสดง 'ความสามารถในการอธิบายได้' (Explainability) ของตัวแบบ โดยนำเสนอผลลัพธ์จากเทคนิค SHAP (SHapley Additive exPlanations) ในรูปแบบตาราง 'Global Importance' ซึ่งเป็นการจัดอันดับตัวแปร (Features) ที่มีอิทธิพลต่อการตัดสินใจของตัวแบบมากที่สุดโดยเฉลี่ย ช่วยให้ผู้ใช้ทราบว่าปัจจัยใด (เช่น ราคาเงิน, S&P 500) เป็นตัวขับเคลื่อนหลักในการทำนายราคา

6. ตัวอย่างเว็บไซต์ที่ใช้ Render เป็น Web Hosting (Free)



แบบสอบถามประเมินความพึงพอใจเว็บแอปพลิเคชัน

แบบสอบถามนี้เป็นส่วนหนึ่งของการรวบรวมข้อมูลสำหรับ "โครงการทางสถิติ: เว็บแอปพลิเคชันทำนายราคาทองคำรายวันแบบเรียลไทม์" โดยมีวัตถุประสงค์เพื่อประเมินความพึงพอใจและรวบรวมข้อเสนอแนะจากผู้ใช้งาน เพื่อใช้เป็นแนวทางในการพัฒนาและปรับปรุงเว็บแอปพลิเคชัน

แบบสอบถามประเมินความพึงพอใจ "เว็บแอปพลิเคชันทำนายราคาทองคำ"

ส่วนที่ 1: ข้อมูลทั่วไปของผู้ใช้งาน

1. ท่านมีประสบการณ์ด้านการลงทุนในสินทรัพย์ (เช่น ทองคำ หุ้น) มากน้อยเพียงใด?

() ไม่มีประสบการณ์เลย

() มีประสบการณ์น้อย (น้อยกว่า 1 ปี)

() มีประสบการณ์ปานกลาง (1-3 ปี)

() มีประสบการณ์สูง (มากกว่า 3 ปี)

2. ท่านเข้าใช้งานเว็บแอปพลิเคชันผ่านอุปกรณ์ใดเป็นหลัก?

() คอมพิวเตอร์/โน้ตบุ๊ก

() โทรศัพท์มือถือ

() แท็บเล็ต

ส่วนที่ 2: การประเมินด้านการออกแบบ (UI) และความง่ายในการใช้งาน (Usability)

คำชี้แจง: โปรดให้คะแนนความพึงพอใจในหัวข้อต่อไปนี้

(ระดับคะแนน: 5 = มากที่สุด, 4 = มาก, 3 = ปานกลาง, 2 = น้อย, 1 = น้อยที่สุด)

รายการประเมิน	5	4	3	2	1
3. การออกแบบและหน้าตาโดยรวมของเว็บไซต์มีความสวยงาม ชัดเจน	()	()	()	()	()
4. ท่านสามารถค้นหาข้อมูลที่ต้องการ (เช่น ราคาปัจจุบัน, ราคาทำนาย) ได้ง่าย	()	()	()	()	()

5. ข้อเสนอแนะเพิ่มเติมด้านการออกแบบ (ถ้ามี):

.....

ส่วนที่ 3: การประเมินตัวแปรหลัก (Functionality)

คำชี้แจง: โปรดให้คะแนนความพึงพอใจในหัวข้อต่อไปนี้

(ระดับคะแนน: 5 = มากที่สุด, 4 = มาก, 3 = ปานกลาง, 2 = น้อย, 1 = น้อยที่สุด)

รายการประเมิน	5	4	3	2	1
6. ความชัดเจนในการแสดงผล "ราคาปัจจุบัน (TODAY)" เทียบกับ "ราคาทำนาย (TOMORROW)"	(((((
7. "กราฟแสดงราคาทองคำย้อนหลัง" เทียบกับ "ราคาในตัวแบบทำนาย" มีประโยชน์ในการช่วยให้เห็นแนวโน้ม	(((((
8. ตาราง "ปัจจัยขับเคลื่อนราคา (SHAP)" ช่วยให้ท่านเข้าใจการตัดสินใจของตัวแบบได้มากขึ้น	(((((

9. ท่านต้องการให้มีตัวแปร หรือข้อมูลใดเพิ่มเติมในหน้าเว็บอีกหรือไม่?

ส่วนที่ 4: การประเมินคุณภาพข้อมูลและความน่าเชื่อถือ

คำชี้แจง: โปรดให้คะแนนความพึงพอใจในหัวข้อต่อไปนี้

(ระดับคะแนน: 5 = มากที่สุด, 4 = มาก, 3 = ปานกลาง, 2 = น้อย, 1 = น้อยที่สุด)

รายการประเมิน	5	4	3	2	1
10. ความเร็วในการโหลดหน้าเว็บและการตอบสนองของระบบ	(((((
11. ข้อมูลที่แสดงผล (ตัวเลข, กราฟ) มีความชัดเจนและเข้าใจง่าย	(((((
12. โดยรวม ท่าน "เชื่อมั่น" ในผลการทำนายของตัวแบบที่นำเสนอบนเว็บไซต์นี้เพียงใด	(((((

ส่วนที่ 5: ความพึงพอใจและข้อเสนอแนะโดยรวม

13. ท่านพึงพอใจต่อเว็บแอปพลิเคชันนี้โดยรวมเพียงใด?

() 5 (มากที่สุด)

() 4 (มาก)

() 3 (ปานกลาง)

() 2 (น้อย)

() 1 (น้อยที่สุด)

14. สิ่งที่ท่าน "ชอบมากที่สุด" ในการใช้งานเว็บไซต์นี้คืออะไร?

15. สิ่งที่ท่าน "อยากให้ปรับปรุง" หรือปัญหาที่พบเจอในการใช้งานคืออะไร?